融合多分支残差与仿射变换的低照度图像增强*

黄仁婧，崔　虎，陈青梅，黄初华†
（贵州大学 计算机科学与技术学院，贵阳 550025）

摘　要： 针对现有低照度图像增强算法难以同时处理亮度、对比度、伪影和噪声等因素，提出了多分支残差与仿射变换低光增强网络，其核心思想是运用不同模块处理不同的任务。首先通过光照估计模块获得低光图像的光照变量，然后使光照仿射变换模块与光照编码参数融合恢复图像的光照，最后通过细节重建模块融合更多的图像细节获得最终输出。实验结果表明，该方法有效地丰富了图像的纹理细节，同时增强了亮度和对比度，并具有更少的伪影和噪声。通过与其他主流方法进行比较，定量和定性地证明了提出方法对低光图像增强的效果更好。

关键词： 低照度图像增强；光照估计；仿射变换；图像融合；多分支独立并行残差结构
中图分类号： TP391.41　　**文献标志码：** A　　**文章编号：** 1001-3695(2021)12-048-3786-05
doi：10.19734/j.issn.1001-3695.2021.03.0126

Low-light image enhancement based on multi-branch residual and affine transformation

Huang Renjing, Cui Hu, Chen Qingmei, Huang Chuhua†
(*College of Computer Science & Technology, Guizhou University, Guiyang* 550025, *China*)

Abstract: The existing algorithms cannot deal with brightness, contrast, artifact and noise at the same time. This paper proposed the low-light enhancement network based on multi-branch residual and affine transformation. The key idea was to exert different modules to handle different tasks. Firstly, the illumination estimation module obtained the illumination variable of the low-light image. Secondly, it combined the illumination affine transformation module with the illumination encoding parameters to restore the illumination of the image. Finally, the detail reconstruction module fused more image details to obtain the final output. The experimental results show that the proposed method effectively enriches the image texture details, enhances brightness and contrast while suppressing the artifact and noise generated. Compared with popular methods, the results quantitatively and qualitatively prove that the method is better for low-light image enhancement.

Key words: low-light image enhancement; illumination estimation; affine transformation; image fusion; multi-branch independent parallel residual structure

增强现实(augmented reality，AR)是将计算机生成的虚拟物体或关于真实物体的非几何信息叠加到真实世界的场景之上来实现对真实世界的增强，很好地把真实世界与数字世界融合起来。目前，虚拟物体与真实环境拥有一致的光照效果是该技术的难点之一[1]。为保证增强现实技术的光照一致性，需要通过光照估计技术获取真实场景的光照信息，从而使虚拟物体和真实场景能够融合。光照估计一般依赖于提取诸如阴影和阴影的提示，并将它们与场景几何形状的估计相结合以恢复照明。但是由于图像在拍摄过程中受到光线微弱、逆光、噪声等因素的影响，难以满足需求。因为低光照图像几乎没有可见的细节、对比度低、颜色暗淡，所以将低照度图像增强能更准确地获取图像的阴影信息。

研究者们提出了许多方法来提高低照度图像的主客观质量。传统的方法[2~5]主要关注图像的对比度增强，不能解决图像的颜色和细节恢复问题，并且每次只能对单张图像进行处理。近期基于深度学习的方法[6~9]采取数据驱动的方式同时学习和调整颜色、对比度、亮度和饱和度以产生更有效的结果。现有基于深度学习的低照度图像增强方法弥补了传统方法每次只能对单张图像进行处理的不足，但仍有很大的改进空间。例如，现有方法往往依赖于关于像素统计或视觉机制的某些假设，然而，这些假设可能并不适用于某些实际场景。其次，除了亮度、对比度优化外，还应更仔细地处理其他因素，如暗区中的伪影和由于低光捕获而产生的图像噪声。受图像降噪问题[10]、细节保留[11]以及照明估计[12]的启发，本文借鉴了最新的深度学习技术[13]的成功，提出了一种用于低光图像增强的方法。本文方法的核心是针对不同的问题运用不同的模块来处理，即多分支残差与仿射变换低光增强网络。该网络由三种类型的模块组成，分别是光照估计模块、光照仿射变换模块和细节重建模块。该方法的思路是：a) 通过光照估计模块获得低光图像的光照变量；b) 通过光照仿射变换模块多次与光照编码参数融合恢复图像的光照；c) 通过细节重建模块从原图像中学习更多的图像细节获得最终输出。以这种方式，本文网络能从不同方面改善图像质量，并充分地完成低光增强任务。

1　相关工作

传统的低照度图像增强主要有直方图均衡化(histogram equalization，HE)方法和基于 Retinex 算法。HE 是一种广泛应用的灰度变换方法，将输出图像的直方图归一化从而使输出图像的整个灰度值分布近似于均匀分布，HE 及其变体可以有效地提高图像的对比度并且均衡化后图像的灰度范围更宽，有助于图像直方图的延展，但是该方法主要只针对对比度增

收稿日期：2021-03-30；修回日期：2021-05-07　基金项目：贵州省自然科学基金资助项目(黔科合基础[2019]1088)；贵州大学引进人才科研项目(贵大人基合字(2017)31 号；贵大人基合字(2015)52 号)

作者简介：黄仁婧(1996-)，女，贵州毕节人，硕士研究生，主要研究方向为计算机视觉、增强现实；崔虎(1987-)，男，陕西西安人，硕士研究生，主要研究方向为计算机视觉、增强现实；陈青梅(1995-)，女，贵州仁怀人，硕士研究生，主要研究方向为计算机视觉、增强现实；黄初华(1978-)，男(通信作者)，贵州盘州人，副教授，硕导，博士，主要研究方向为移动增强现实、机器学习(chhuang@gzu.edu.cn).

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

强[2~4]。Retinex 理论基于视觉系统，其假设彩色图像可以分解为照明图（或阴影）和反射率的像素级乘积。王萍等人[14]设置不同的滤波参数，获取表征图像不同尺度信息的反射分量和照度分量。Fu 等人[12]提出了一个在正则化项中加入先验表示的新加权变分模型，该方法用高斯分布和拉普拉斯分布来拟合光照图像和反射率图像的分布规律，以弱光照图像的 V 通道图像为初始光照图像，经乘子交替方向算法迭代求得光照图像和反射率图像的最优解，然后与 LIME[15]相似，使用伽马变换得到增强的光照图像。由于物体外观受内部和外部属性的影响，物体的内在属性包括形状和纹理，而场景中的照明是一个外部属性，Cai 等人[16]将模型表示为带有形状、纹理和照明约束的能量最小化问题。黄慧等人[17]对输入图像进行平滑聚类并使用 max-RGB 技术初始化输入图像的光照图，然后运用自适应 Gamma 矫正来增强图像的对比度，最后通过细节融合方式丰富细节。传统方法对低照度图像的增强在对比度方面取得了不错的成果，但增强后的图像容易出现颜色失真和边缘模糊等问题，且对于大规模的图像处理速度慢。

为了弥补传统方法在低照度图像处理方面的不足，大批基于深度学习处理低照度图像的方法涌现。深度学习方法利用大量数据来训练模型，使得深度学习的模型获得低照度图像增强的能力。Cai 等人[9]提出了一个大规模的多曝光率图像数据集，包含不同曝光率的低照度图像及其对应的高质量图像。由于低照度图像与其相应高质量图像的图像内容是一致的，Gharbi 等人[8]假设增强后的图像是由低照度图像的局部仿射变换得到的，分别学习低照度图像的局部特征和全局特征，并将它们融合后转到双边网格之中。DeepUDP 方法[18]也学习局部和全局特征，并融合后传到双边网格上采样，与之不同的是 DeepUDP 要进行照明估计。Ignatov 等人[19]使用生成对抗网络来学习从手机到 DSLR 相机的特征映射，以改善低照度图像的色彩和清晰度。EnlightenGAN 方法[20]提出了使用非配对训练的方法，使用对称的编解码器网络作为生成器，判别器使用了全局判别器和局部判别器。LLNet 方法[6]使用叠加稀疏去噪自动编码器的变体，从合成暗色和加噪训练实例中学习，同时进行低光增强和降噪。GLADNet 方法[11]与 LLNet 方法有相似之处，都是将低照度的图片输入编解码器中进行训练，但 LLNet 网络含有降噪模块，而 GLADNet 网络在编解码器中采用对称跳级连接的方式估计照明图，并在编解码器后还跟着细节重建模块。GLADNet 的作者在同年还提出了 RetinexNet 方法[7]，其主要包括 DecomNet 和 RelightNet 网络。DecomNet 用于分解图片为反射分量和光照分量，RelightNet 用于将光照分量修正，再与反射分量重建，得到修正后的图像，该方法将深度学习方法与 Retinex 方法相结合，处理图像的速度很快，但增强后的图像中存在大量的伪影，使得图像更像是风格画。虽然以上研究取得了显著的进展，但是都无法同时处理亮度、对比度增强、伪影和图像去噪，低照度图像增强的精度也有待提升。

2　本文方法

本文以多模块方式设计网络结构，将图像增强问题分解为不同的子问题，可以通过多模块融合分别解决这些子问题以产生最终输出。网络的输入是弱光彩色图像，而输出是相同大小的增强型清晰图像。整个网络体系结构和数据处理流程如图 1 所示。图像增强网络由光照估计模块、光照仿射变换模块和细节重建模块三种类型的模块组成。

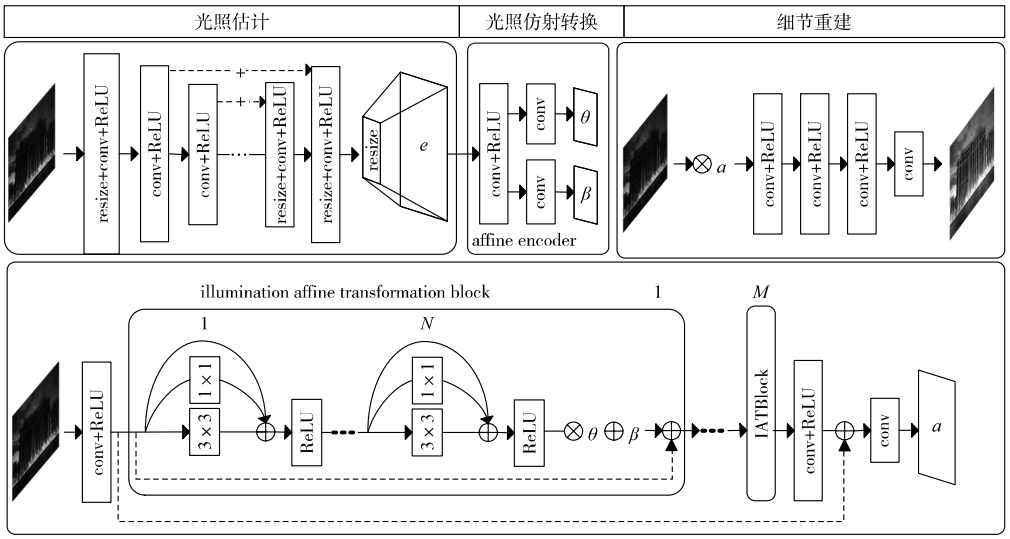

图1　融合多分支残差与仿射变换的低照度图像增强模型

Fig.1　Low-illumination image enhancement model that fuses multi-branch residuals with affine transformations

2.1　光照估计模块

光照估计包括三个子步骤：将输入图像缩放到特定分辨率，再将其通过残差连接编解码器网络进行照度预测，最后将其重新缩放到原始分辨率并获得光照变量。

首先，通过双线性插值将输入降采样为 96×96 的特征图。随后是带有 ReLU 的卷积层。然后，特征图通过一系列级联的下采样块。根据降采样后特征图的宽和高来设计下采样块的数量，以便编解码器网络瓶颈层的接收场可以覆盖整个图像。所以共用到了六个降采样块，这种设计可以减少所需的存储空间，并有助于提高网络效率。在一系列对称的上采样块之后，获得用于照明预测的 96×96 特征图。通过另一个上采样块，将特征图重新缩放到原始输入的大小。

残差跳层连接从下采样模块引入到其相应的镜像上采样模块。下采样块的输出被传递到上采样块的特征图并与之累加，这迫使网络学习残差而不是预测实际像素值。

下采样块由步长为 2 的卷积层和 ReLU 组成。在上采样块中，调整大小卷积层[21]来替换常规的反卷积层。与正常的反卷积层不同，调整大小卷积层避免了伪影的棋盘格图案，图像平滑，并且对输入图像的大小没有限制。调整大小卷积层包括一个双线性插值操作，一个步长为 1 的卷积层和一个 ReLU。该模块的所有层采用 3×3 卷积层，除最后一层的通道数为 3 外，通道都是 64。

2.2　光照仿射变换模块

光照仿射变换模块由仿射编码部分和主干部分组成。

主干部分首先使用一个卷积层提取特征，并将其送入 M 个级联的光照仿射变换块，随后与第一个卷积层输出的特征图

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

采用残差学习方案[10]，这主要是学习噪声而不是清晰的图像，最后输出 3 通道的光照仿射变换图。该部分除了特殊说明的卷积层外，都采用 3×3 且步长为 1 的 64 通道卷积层。

仿射编码部分采用 1×1 且步长都为 1 的卷积层，第一个卷积层带有 ReLU 且其通道数为 128，接下来是两个并列通道数为 64 的卷积层，两层加起来刚好是 128。它接受来自光照估计模块输出的光照变量，并输出光照仿射参数 θ 和 β。

主干主要是基于 M 个级联的光照仿射变换块。为了有效合并光照信息，本文使用了光照仿射变换，它可以将仿射变换应用于特征图，表示为

$$F_o=\theta\otimes F_i+\beta \tag{1}$$

其中：F_i 和 F_o 分别表示变换前后的特征图；$\otimes$ 表示逐元素相乘。在光照仿射变换块中，通过参数 θ 和 β 进行仿射变换来调整最后一个卷积层的输出特征图，并将仿射参数与其他光照仿射变换块共享。类似的方法已经应用于各种任务[22~26]。

光照仿射变换块由 N 个级联多分支独立并行残差结构[13]组成。该光照仿射变换块采用残差跳层连接来绕过长短期信息，训练时的多分支残差块是由 3×3 卷积分支、1×1 卷积分支和输入本身构造，表示为

$$y=x+f_{1\times1}(x)+f_{3\times3}(x) \tag{2}$$

但是通过重构参数化可以删除分支，经过训练后，可以用简单的代数进行变换，等价地转换为 $y=f(x)$，因为一个恒等分支可以看做是退化的 1×1 卷积，而 1×1 的卷积可以看做是退化的 3×3 卷积，所以可以构造一个单一的 3×3 卷积具有原始的 3×3 卷积、1×1 卷积和输入本身的训练参数。其中 f 由一个卷积层实现，其参数由一系列代数训练后的卷积层导出。多分支独立并行残差结构不仅内存消耗低，因为每个分支的结果都需要保留到加法或级联之后，这大大提高了内存占用的峰值，而且其简单的体系结构可以自由地配置每个卷积层，并进行修剪以获得更好的性能效率折中。

2.3 细节重建模块

原始输入包含更多的细节，因此可以为细节恢复提供信息，并且将浅层和深层的特征图融合，可以进行信息互补，从而增强特征的表达能力。使用级联而不是跳层连接来组合光照仿射变换模块输出的特征图和输入图像的特征图，以便可以完全保留原始信息和光照仿射变换信息，并将其传输到下一步。级联层之后是除最后一层外都具有 ReLU 的四个 3×3 且通道为 128 的卷积层，它将输入的图像信息与仿射变换后得到的照明信息组合在一起，最终生成具有更多细节的增强结果。

2.4 损失函数

为了从主观和客观方面改善图像质量，使用 MSE 和 MAE 等常见误差指标不足以解决问题。因此，进一步考虑结构信息、人眼感知和图像的区域差异，其计算公式为

$$loss=L(E,G)+L_{Str}+L_{VGG/i,j}+L_{Region} \tag{3}$$

其中：$L(E,G)$、L_{Str}、$L_{VGG/i,j}$ 和 L_{Region} 分别表示绝对误差距离、结构损失、感知损失和区域损失，这些损失将在下面作进一步解释。

2.4.1 绝对误差距离

$L(E,G)$ 学习低照度图像 I 的增强后图像 E 与相应的正常曝光 ground-truth 图像 G 之间的差距，损失函数可以写成

$$L(E,G)=\frac{1}{N}\sum_{i=1}^{N}\|E_i,G_i\|_1 \tag{4}$$

其中：N 表示训练样本的数量；$\|\cdot\|_1$ 表示 L_1 范数。

2.4.2 结构损失

在低光增强下，不需要增强的图像处于特定的光照条件下。例如，给定在白天拍摄的自然图像，可以通过添加或减去少量数字来更改所有像素值，在这种情况下，结构几乎不会改变，而 PSNR 会报告很大的差异。对于低光图像增强，保留纹理更为重要，并且允许亮度随 ground-truth 情况而波动。因此，SSIM 值应该更适合该任务，像素 p 的 SSIM 值为

$$\mathrm{SSIM}(p)=\frac{2\mu_x\mu_y+C_1}{\mu_x^2+\mu_y^2+C_1}\cdot\frac{2\sigma_{xy}+C_2}{\sigma_x^2+\sigma_y^2+C_2} \tag{5}$$

SSIM 值在 $(0,1]$，值 1 表示两张图片完全相同，因此，使用 1-SSIM 计算像素 p 的损失，LLCNN[27] 也采用了类似的策略，关于 SSIM 的结构损失函数定义为

$$L_{Str}=\frac{1}{N}\sum_{p\in img}1-\mathrm{SSIM}(p) \tag{6}$$

其中：N 为训练样本的数量。

2.4.3 感知损失

像 MSE 和 SSIM 这样的评价指标与人眼感知的图像质量并不匹配，恢复出来的图像往往细节表现不好。因此，参考 SRGAN[28] 中的想法，并使用类似的策略来指导网络的训练。基本思想是采用特征提取，如果增强图像和 ground-truth 是相似的，则特征提取它们相应的输出也应该相似。

合适的特征提取器可以是在大型数据集上训练的神经网络。由于 VGG 网络[29] 具有良好的结构和行为表现，所以选择 VGG 网络作为特征提取器。特别地，基于预训练的 VGG-19 网络的 ReLU 激活层的输出来定义感知损失。为了测量增强图像的表征与 ground-truth 之间的差异，本文计算了它们的误差平方和。感知损失的定义为

$$L_{VGG/i,j}=\frac{1}{W_{i,j}H_{i,j}C_{i,j}}\sum_{x=1}^{W_{i,j}}\sum_{y=1}^{H_{i,j}}\sum_{z=1}^{Ci,j}\|\varphi_{i,j}(E)_{x,y,z}-\varphi_{i,j}(G)_{x,y,z}\|_2 \tag{7}$$

其中：E 和 G 分别表示增强图像和 ground-truth；$W_{i,j}$、$H_{i,j}$、$C_{i,j}$ 描述了 VGG-19 网络中各个特征图的尺寸；$\varphi_{i,j}$ 表示 VGG-19 网络中第 i 个块中第 j 个卷积层获得的特征图，这里 i 取 3，j 取 4，而 $\|\cdot\|_2$ 表示 L_2 范数。

2.4.4 区域损失

上述损失函数都是将图像作为一个整体，但对于弱光增强任务，需要更多地关注那些弱光区域。参考了 MBLLEN[30] 的想法并定义区域感知函数如下：

$$L_{Region}=w_L\frac{1}{m_Ln_L}\sum_{i=1}^{m_L}\sum_{j=1}^{m_L}\|E_L(i,j)-G_L(i,j)\|_1+w_H\cdot\frac{1}{m_Hn_H}\sum_{i=1}^{m_H}\sum_{j=1}^{m_H}\|E_H(i,j)-G_H(i,j)\|_1 \tag{8}$$

其中：E_L 和 G_L 是增强图像和 *ground-truth* 的弱光区域；E_H 和 G_H 是图像的其余部分且 $w_L=4$，$w_H=1$。

3 实验结果与分析

3.1 实验环境、参数设置及数据集

实验所使用的 GPU 配置为 A100-SXM4，操作系统为 Ubuntu 18.04。训练所使用的深度学习架构为 TensorFlow-GPU 2.4，epochs 为 50，batch-size 为 16，patch-size 为 256。模型均使用 Adam 优化器进行优化，学习率为 10^{-3}，每经过 1 个 epoch 后，学习率降低为原来的 0.99 倍。对于数据增强，随机地镜像和旋转来增加训练图像的多样性。经过多次实验后设置光照仿射变换模块中的 $N=5$，$M=5$。

通过大量的实验，对本文方法进行了评估，并与现有方法进行了比较。为了更好地进行比较，本文使用现有的已经公开源码的方法。本文实验的数据集使用 MBLLEN[30] 基于 PASCAL VOC 图像数据集[31] 合成的大量低光图像。其中训练集有 16 925 张、验证集 56 张和测试集 144 张，合成数据集尺寸为 $256\times256\times3$。为了测试模型的有效性，实验选用的数据集还有 MIT-Adobe FiveK[32]。该数据集场景多样，使用专家 B 调整的照片作为 ground-truth，随机地挑选 700 张作为测试集和验证集，测试集和验证集各占 350 张，剩下的 4 300 张作为训练集，MIT-Adobe FiveK 中所有图像均被裁剪为 400×600 并转换为便携式网络图形(portable network graphics，png)格式。两个数据集输入图像的值均被规范至 $[0,1]$。

3.2 客观评估及与主流方法比较

为了验证本文模型的有效性，将本文方法与最近基于深度

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

学习的方法 GLADNet[11]、RetinexNet[7]、MBLLEN[30]、Deep-UDP[18]，KinD++[33] 和 Zero-DCE[34] 进行比较。为了更加公平地比较，本文使用作者提供的公开源码和推荐的参数设置来生成结果。对于 GLADNet[11]、RetinexNet[7]、MBLLEN[30] 和 Zero-DCE[34]，本文进一步在合成数据集或麻省理工学院提供的 MIT-Adobe FiveK 数据集[32] 上重新训练其模型，以产生可能的最佳结果。对于 DeepUDP 方法[18]，因为作者公开的源码中没有训练代码，所以本文下载其训练好的模型进行测试。对于 KinD++[33] 方法，虽然公开的源码中包含训练代码，但其训练代码主要针对 RetinexNet[7] 提供的 LOL 数据集，所以该方法也是下载其训练好的模型进行测试。

3.2.1　主观评价

图 2～5 比较了本文方法和其他六种最新方法的结果。图 2、3 是在合成数据集上的结果，图 4、5 是在 MIT-Adobe FiveK 数据集上的结果。为了表示本文方法能够去除噪声，在数据集中加入了噪声级别为 5 的高斯噪声，其中图 3、5 分别表示在合成数据集和 MIT-Adobe FiveK 数据集上加入噪声后的结果。通过检查细节，本文方法可以实现更好的视觉效果，包括更自然的颜色，良好的亮度、对比度和更少的伪影和噪声。

图2　对合成低光图像增强的视觉比较

Fig.2　Visual comparison of synthetic low-light images enhancement

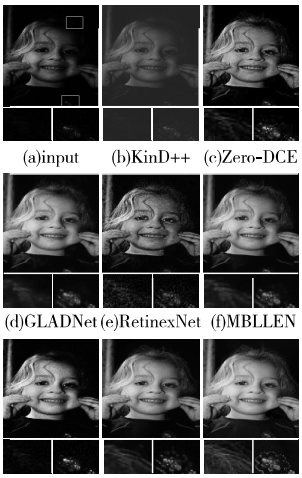

图3　对合成低光图像(带有噪声)增强的视觉比较

Fig.3　Visual comparison of synthetic low-light images(with additional noise) enhancement

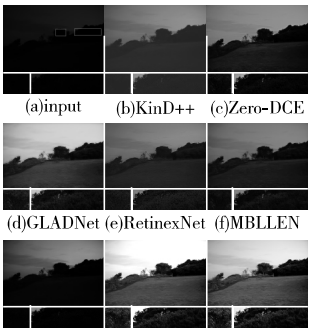

图4　对MIT-Adobe FiveK增强的视觉比较

Fig.4　Visual comparison of MIT-Adobe FiveK enhancement

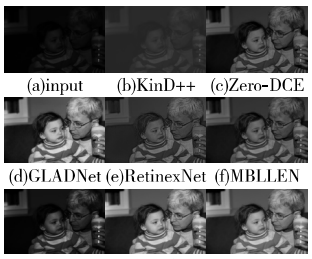

图5　对MIT-Adobe FiveK(带噪声)增强的视觉比较

Fig.5　Visual comparison of MIT-Adobe FiveK(with additional noise) enhancement

在图 2 中，本文方法增强后的图像从放大图像中可以看出，左侧的自行车和右侧的椅子与原图像更加相近。在图 3 中小女孩的头发和衣服上的花朵相对于其他方法来说更加清晰，并且含有的噪声更少。在图 4 中，虽然与专家渲染过的图像有一些颜色差异，这是因为输入的光照极其微弱，肉眼已经很难看清楚图像的内容，但是本文方法还是能很好地恢复树的分支和树丛的叶片。在图 5 中，图像的整体颜色与专家渲染的更相近，无论是前景中的人物还是背景，并且背景中含有更少的噪声。

3.2.2　客观评价

为了更公正地评估不同方法的性能，本文使用了各种不同的指标，包括峰值信噪比 PSNR、结构相似性 SSIM、均方误差 MSE、信息保真度准则 IFC[35]、视觉信息保真度 VIF[36] 以及不需要参考图像的主现评价分数 NIQE[37]，结果如表 1～4 所示。表 1～4 中↑表示越高结果越好，↓表示越低结果越好，加粗、下画线分别表示最佳、次佳结果。

表 1　对合成低光图像增强的定量评价

Tab. 1　Quantitative evaluation of synthetic low-light images enhancement

方法	PSNR↑	SSIM↑	IFC↑	VIF↑	NIQE↓	MSE↓
KinD++	15.378	0.699	2.517	0.306	5.535	0.031 9
Zero-DCE	20.279	0.736	3.079	0.407	5.245	0.011 2
GLADNet	26.111	0.868	3.649	0.503	4.231	0.003 1
RetinexNet	18.832	0.691	2.628	0.334	5.552	0.014 3
MBLLEN	25.603	0.902	3.739	0.519	4.065	0.005
DeepUPE	17.484	0.626	2.963	0.399	5.267	0.020
本文算法	26.724	0.908	3.879	0.526	4.008	0.002 7

表 2　对合成低光图像(带噪声)增强的定量评价

Tab. 2　Quantitative evaluation of synthetic low-light images(with additional noise) enhancement

方法	PSNR↑	SSIM↑	IFC↑	VIF↑	NIQE↓	MSE↓
KinD++	14.991	0.682	2.298	0.276	6.356	0.033 3
Zero-DCE	15.207	0.558	2.294	0.256	7.511	0.032 2
GLADNet	25.601	0.883	3.282	0.476	4.345	0.003 3
RetinexNet	18.414	0.612	2.358	0.298	9.537	0.015 5
MBLLEN	25.533	0.888	3.360	0.486	4.008	0.003 5
DeepUPE	17.413	0.641	2.651	0.357	5.550	0.020 4
本文算法	26.103	0.892	3.439	0.496	4.141	0.003 1

表 3　对 MIT-Adobe FiveK 增强的定量评价

Tab. 3　Quantitative evaluation of MIT-Adobe FiveK enhancement

方法	PSNR↑	SSIM↑	IFC↑	VIF↑	NIQE↓	MSE↓
KinD++	14.567	0.721	5.342	0.367	5.160	0.040
Zero-DCE	18.601	0.889	6.54	0.456	4.959	0.018 1
GLADNet	24.575	0.920	5.634	0.483	4.562	0.004
RetinexNet	18.013	0.853	4.540	0.403	5.299	0.018 3
MBLLEN	20.165	0.810	7.212	0.527	4.358	0.012 9
DeepUPE	17.801	0.802	6.406	0.478	4.872	0.025 9
本文算法	26.502	0.949	8.177	0.576	4.473	0.002 6

表 4　对 MIT-Adobe FiveK(带噪声)增强的定量评价

Tab. 4　Quantitative evaluation of MIT-Adobe FiveK(with additional noise) enhancement

方法	PSNR↑	SSIM↑	IFC↑	VIF↑	NIQE↓	MSE↓
KinD++	14.568	0.721	5.343	0.367	5.173	0.039 9
Zero-DCE	16.814	0.857	6.125	0.520	4.837	0.022 6
GLADNet	24.445	0.918	5.521	0.476	4.541	0.004 1
RetinexNet	17.119	0.842	4.798	0.405	5.334	0.022 2
MBLLEN	20.074	0.909	7.178	0.526	4.399	0.013 6
DeepUPE	17.800	0.802	6.406	0.477	4.871	0.025 9
本文算法	25.861	0.946	8.177	0.576	4.547	0.003 2

从表 1～4 中可以看出，无论是在合成的低光图像数据集还是 MIT-Adobe FiveK 数据集，本文方法在各个指标下几乎取得了最好的结果，唯一效果没有完全取得最佳的是在无参考评价指标 NIQE 下，但是与最佳结果的差别并不大。

表 5　内存性能表现和测试运行时间

Tab. 5　Memory performance and test running time

方法	params/M	time/s	方法	params/M	time/s
KinD++	8.274	0.966 8	MBLLEN	0.450	0.075 3
Zero-DCE	0.079	0.016 2	DeepUPE	0.998	0.047
GLADNet	0.931	0.032 8	**本文算法**	1.801	0.091 8
RetinexNet	0.444	0.028 8			

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

除了对结果质量的比较，本文还在 MIT-Adobe FiveK 数据集[32] 上对比不同算法的测试运行时间以及内存性能表现，通过参数量来描述所需内存，结果如表 5 所示。本文方法的参数量和运行时间虽然都没有达到最优，但其参数量和时间的增加在可接受范围内。

3.3 消融实验

本文网络模型共有光照估计、光照仿射变换和细节重建三个模块，为了了解到底是哪一个模块对低照度图像增强的贡献大，本文在 MIT-Adobe FiveK 数据集[32] 上依次对各个模块融合进行了实验，实验结果如表 6 所示。其中本文方法 1 表示仅使用光照估计模块的结果；本文方法 2 表示光照估计模块加上光照仿射变换模块的结果；本文方法表示所有模块共同的结果。此外，还控制了光照仿射变换块的数量 M，本文设置的 M 为 5，从实验中可以看出，光照仿射变换模块对整个网络起到了很大的作用。

表 6 本文方法不同模块对 MIT-Adobe FiveK 增强的定量评价

Tab. 6 Quantitative evaluation of different modules of proposed methods on MIT-Adobe FiveK enhancement

方法	PSNR ↑	SSIM ↑	IFC ↑	VIF ↑	NIQE ↓	MSE ↓
本文方法 1	20.448	0.683	0.735	0.254	12.776	0.010 3
本文方法 2($M=1$)	26.089	0.947	8.083	0.575	4.559	0.003 0
本文方法 2($M=2$)	26.132	0.947	8.197	0.577	4.552	0.003 0
本文方法 2($M=3$)	26.249	0.948	8.204	0.579	4.57	0.003 0
本文方法 2($M=4$)	26.325	0.947	8.262	0.574	4.556	0.002 9
本文方法 2	26.351	0.948	8.272	0.579	4.549	0.002 8
本文方法	26.502	0.949	8.178	0.576	4.473	0.002 6

4 结束语

针对现有低照度图像增强算法难以同时处理各种因素，本文提出了融合多分支残差与仿射变换的低光增强网络。该网络由残差跳层连接编解码器构成的光照估计模块、级联多分支独立残差结构与仿射变换构成的光照仿射变换模块和学习原图像的细节重建模块三个模块组成。它旨在能够从光照估计模块获得光照变量并分解为光照编码参数，并通过光照仿射变换模块多次融合光照编码参数以恢复更好的光照，最后再通过细节重建模块将浅层和深层的特征图融合恢复图像纹理细节，来实现更高的图像质量。低光图像经本文方法增强后色彩自然，具有更好的亮度、对比度以及更少的伪影和噪声，与其他主流方法相比，在保证增强质量的同时运用多个评价指标进行评价都相对较好。下一步工作是将低照度图像与增强图像结合获取图像的更多阴影信息和场景几何，并将其运用到移动增强现实系统中。

参考文献:

[1] 刘万奎，刘越. 用于增强现实的光照估计研究综述 [J]. 计算机辅助设计与图形学学报，2016，28(2)：197-207. (Liu Wankui, Liu Yue. Review on illumination estimation in augmented reality [J]. Journal of Computer-Aided Design & Computer Graphics, 2016, 28(2): 197-207.)

[2] CelikT, Tjahjadi T. Contextual and variational contrast enhancement [J]. IEEE Trans on Image Processing, 2011, 20(12): 3431-3441.

[3] Lee C, Kim C S. Contrast enhancement based on layered difference representation [C] //Proc of IEEE International Conference on Image Processing. Piscataway, NJ: IEEE Press, 2012: 965-968.

[4] Liu Yunfu, Guo Jingming, Lai B S, *et al*. High efficient contrast enhancement using parametric approximation [C] //Proc of IEEE International Conference on Acoustics, Speech and Signal Processing. Piscataway, NJ: IEEE Press, 2013: 2444-2448.

[5] Ying Zhenqiang, Li Ge, Gao Wen. A bio-inspired multi-exposure fusion framework for low-light image enhancement [EB/OL]. (2017-11-02). https://arxiv.org/abs/1711.00591.

[6] Lore K G, Akintayo A, Sarkar S. LLNet: a deep autoencoder approach to natural low-light image enhancement [J]. Pattern Recognition, 2017, 61: 650-662.

[7] Chen Wei, Wang Wenjing, Yang Wenhan, *et al*. Deep retinex decomposition for low-light enhancement [C] //Proc of the 29th British Machine Vision Conference. Surrey: BMVA Press, 2018: 155-167.

[8] Gharbi M, Chen Jiawen, Barron J T, *et al*. Deep bilateral learning for real-time image enhancement [J]. ACM Trans on Graphics, 2017, 36(4): 1835-1849.

[9] Cai Jianrui, Gu Shuhang, Zhang Lei. Learning a deep single image contrast enhancer from multi-exposure images [J]. IEEE Trans on Image Processing, 2018, 27(4): 2049-2062.

[10] Zhang Kai, Zuo Wangmeng, Chen Yunjin, *et al*. Beyond a Gaussian denoiser: residual learning of deep CNN for image denoising [J]. IEEE Trans on Image Processing, 2017, 26(7): 3142-3155.

[11] Wang Wenjing, Chen Wei, Yang Wenhan, *et al*. GLADNet: low-light enhancement network with global awareness [C] //Proc of IEEE International Conference on Automatic Face & Gesture Recognition. Piscataway, NJ: IEEE Press, 2018: 751-755.

[12] Fu Xueyang, Zeng Delu, Huang Yue, *et al*. A weighted variational model for simultaneous reflectance and illumination estimation [C] //Proc of IEEE Conference on Computer Vision and Pattern Recognition. Washington DC: IEEE Computer Society, 2016: 2782-2790.

[13] Ding Xiaohan, Zhang Xiangyu, Ma Ningning, *et al*. RepVGG: making VGG-style convnets great again [EB/OL]. (2021-03-29). https://arxiv.org/abs/2101.03697.

[14] 王萍，孙振明. 多级分解的 Retinex 低照度图像增强算法 [J]. 计算机应用研究，2020，37(4)：1204-1209. (Wang Ping, Sun Zhenming. Multi-level decomposition Retinex low-light image enhancement algorithm [J]. Application Research of Computers, 2020, 37(4): 1204-1209.)

[15] Guo Xiaojie, Li Yu, Ling Haibin. LIME: low-light image enhancement via illumination map estimation [J]. IEEE Trans on Image Processing, 2017, 26(2): 982-993.

[16] Cai Bolun, Xu Xianming, Guo Kailing, *et al*. A joint intrinsic-extrinsic prior model for retinex [C] //Proc of IEEE International Conference on Computer Vision. Washington DC: IEEE Computer Society, 2017: 4020-4029.

[17] 黄慧，董林鹭，刘小芳，等. 改进 Retinex 的低光照图像增强 [J]. 光学精密工程，2020，28(8)：1835-1849. (Huang Hui, Dong Linlu, Liu Xiaofang, *et al*. Improved Retinex low light image enhancement method [J]. Optics and Precision Engineering, 2020, 28(8): 1835-1849.)

[18] Wang Ruixing, Zhang Qing, Fu Chiwing, *et al*. Underexposed photo enhancement using deep illumination estimation [C] //Proc of IEEE Conference on Computer Vision and Pattern Recognition. Washington DC: IEEE Computer Society, 2019: 6849-6857.

[19] Ignatov A, Kobyshev N, Timofte R, *et al*. DSLR-quality photos on mobile devices with deep convolutional networks [C] //Proc of IEEE International Conference on Computer Vision. Washington DC: IEEE Computer Society, 2017: 3297-3305.

[20] Jiang Yifan, Gong Xinyu, Ding Liu, *et al*. EnlightenGAN: deep light enhancement without paired supervision [J]. IEEE Trans on Image Processing, 2021, 30: 2340-2349.

[21] Odena A, Dumoulin V, Olah C. Deconvolution and checkerboard artifacts [J/OL]. Distill. (2016-10-17) [2021-02-22]. https://distill.pub/2016/deconv-checkerboard.

[22] Soh J W, Cho N I. Deep universal blind image denoising [C] //Proc of the 25th International Conference on Pattern Recognition. Piscataway, NJ: IEEE Press, 2021: 747-754.

[23] Wang Xintao, Ke Yu, Chao Dong, *et al*. Recovering realistic texture in image super-resolution by deep spatial feature transform [C] //Proc of IEEE Conference on Computer Vision and Pattern Recognition. Washington DC: IEEE Computer Society, 2018: 606-615.

[24] Park T, Liu Mingyu, Wang Tingchun, *et al*. Semantic image synthesis with spatially-adaptive normalization [C] //Proc of IEEE Conference on Computer Vision and Pattern Recognition. Washington DC: IEEE Computer Society, 2019: 2332-2341.

(下转第 3807 页)

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

[11] Zhang Xingcheng, Li Zhizhong, Loy C C, *et al*. PolyNet: a pursuit of structural diversity in very deep networks [C] //Proc of IEEE Conference on Computer Vision and Pattern Recognition. Washington DC: IEEE Computer Society, 2017: 3900–3908.

[12] Cai Sijia, Zuo Wangmeng, Zhang Lei, *et al*. Support vector guided dictionary learning [C] //Proc of the 13th European Conference on Computer Vision. Cham: Springer, 2014: 624–639.

[13] 陈子鎏，胡高鹏，王晓明，等. 基于局部类内结构的鉴别性字典学习方法 [J]. 计算机应用研究，2021，38(2)：489–494，500.（Chen Ziliu, Hu Gaopeng, Wang Xiaoming, *et al*. Discriminative dictionary learning based on locality intra-class structure [J]. Application Research of Computers, 2021, 38(2): 489–494, 500.）

[14] Soomro K, Zamir A R, Shah M. UCF101: a dataset of 101 human actions classes from videos in the wild, CRCV-TR-12-01 [R/OL]. (2012-11). https://www.crcv.ucf.edu/papers/UCF101_CRCV-TR-12-01.pdf.

[15] 周志华. 机器学习 [M]. 北京：清华大学出版社，2016：23–47.（Zhou Zhihua. Machine learning [M]. Beijing: Tsinghua University Press, 2016: 23–47.）

[16] He Tong, Zhang Zhi, Zhang Hang, *et al*. Bag of tricks for image classification with convolutional neural networks [C] //Proc of IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE Press, 2019: 558–567.

[17] Van Der Maaten L, Hinton G. Visualizing data using t-SNE [J]. Journal of Machine Learning Research, 2008, 9(86): 2579–2605.

[18] Schuldt C, Laptev I, Caputo B. Recognizing human actions: a local SVM approach [C] //Proc of the 17th International Conference on Pattern Recognition. Washington DC: IEEE Computer Society, 2004: 32–36.

[19] Kuehne H, Jhuang H, Garrote E, *et al*. HMDB: a large video database for human motion recognition [C] //Proc of IEEE International Conference on Computer Vision. Washington DC: IEEE Computer Society, 2011: 2556–2563.

[20] Feichtenhofer C, Pinz A, Zisserman A. Convolutional two-stream network fusion for video action recognition [C] //Proc of IEEE Conference on Computer Vision and Pattern Recognition. Washington DC: IEEE Computer Society, 2016: 1933–1941.

[21] Feichtenhofer C, Pinz A, Wildes R P. Spatiotemporal residual networks for video action recognition [C] //Proc of IEEE Conference on Computer Vision and Pattern Recognition. Washington DC: IEEE Computer Society, 2017: 7445–7454.

[22] Sun Lin, Jia Kui, Yeung D Y, *et al*. Human action recognition using factorized spatio-temporal convolutional networks [C] //Proc of IEEE International Conference on Computer Vision. Washington DC: IEEE Computer Society, 2015: 4597–4605.

[23] Wang Limin, Xiong Yuanjun, Wang Zhe, *et al*. Temporal segment networks: towards good practices for deep action recognition [C] //Proc of the 14th European Conference on Computer Vision. Cham: Springer, 2016: 20–36.

[24] Wang Heng, Schmid C. Action recognition with improved trajectories [C] //Proc of IEEE International Conference on Computer Vision. Washington DC: IEEE Computer Society, 2013: 3551–3558.

[25] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition [EB/OL]. (2014-12-19). https://arxiv.org/pdf/1409.1556v4.pdf.

[26] Wang Limin, Qiao Yu, Tang Xiaoou. Action recognition with trajectory-pooled deep-convolutional descriptors [C] //Proc of IEEE Conference on Computer Vision and Pattern Recognition. Washington DC: IEEE Computer Society, 2015: 4305–4314.

[27] Tran D, Ray J, Shou Zheng, *et al*. ConvNet architecture search for spatiotemporal feature learning [EB/OL]. (2017-08-16). https://arxiv.org/pdf/1708.05038.pdf.

[28] Dong Min, Fang Zhenglin, Li Yongfa, *et al*. AR3D: attention residual 3D network for human action recognition [J]. Sensors, 2021, 21(5): 1656.

[29] Cai Jiahui, Hu Jianguo. 3D RANs: 3D residual attention networks for action recognition [J]. Visual Computer, 2020, 36(6): 1261–1270.

[30] Diba A, Sharma V, Van Gool L, *et al*. DynamoNet: dynamic action and motion network [C] //Proc of IEEE/CVF International Conference on Computer Vision. Piscataway, NJ: IEEE Press, 2019: 6191–6200.

[31] Liu Kun, Liu Wu, Ma Huadong, *et al*. A real-time action representation with temporal encoding and deep compression [J]. IEEE Trans on Circuits and Systems for Video Technology, 2021, 31(2): 647–660.

[32] 邱钊凡. 视频时空特征学习方法研究 [D]. 合肥：中国科学技术大学，2020.（Qiu Zhaofan. Video spatio-temporal representation learning methods [D]. Hefei: University of Science and Technology of China, 2020.）

（上接第 3790 页）

[25] Huang Xun, Belongie S. Arbitrary style transfer in real-time with adaptive instance normalization [C] //Proc of IEEE International Conference on Computer Vision. Washington DC: IEEE Computer Society, 2017: 1510–1519.

[26] Perez E, Strub F, Vries H D, *et al*. Film: visual reasoning with a general conditioning layer [C] //Proc of AAAI Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2018: 3942–3951.

[27] Tao Li, Zhu Chuang, Xiang Guoqing, *et al*. LLCNN: a convolutional neural network for low-light image enhancement [C] //Proc of IEEE Visual Communications and Image Processing. Piscataway, NJ: IEEE Press, 2017: 1–4.

[28] Ledig C, Theis L, Ferenc H, *et al*. Photo-realistic single image super-resolution using a generative adversarial network [C] //Proc of IEEE Conference on Computer Vision and Pattern Recognition. Washington DC: IEEE Computer Society, 2017: 105–114.

[29] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition [C] //Proc of the 3rd International Conference on Learning Representations. La Jolla, CA: ICLR Press, 2015: 1–14.

[30] Lyu Feifan, Lu Feng, Wu Jianhua, *et al*. MBLLEN: low-light image/video enhancement using CNNs [C] //Proc of British Machine Vision Conference. Surrey: BMVA Press, 2018: 220–232.

[31] Everingham M, Van Gool L, Williams C, *et al*. The pascal visual object classes (VOC) challenge [J]. International Journal of Computer Vision, 2010, 88(2): 303–338.

[32] Bychkovsky V, Paris S, Chan E, *et al*. Learning photographic global tonal adjustment with a database of input/output image pairs [C] //Proc of IEEE Conference on Computer Vision and Pattern Recognition. Washington DC: IEEE Computer Society, 2011: 97–104.

[33] Zhang Yonghua, Guo Xiaojie, Ma Jiayi, *et al*. Beyond brightening low-light images [J]. International Journal of Computer Vision, 2021, 129(4): 1013–1037.

[34] Guo Chunle, Li Chongyi, Guo Jichang, *et al*. Zero-reference deep curve estimation for low-light image enhancement [C] //Proc of IEEE Conference on Computer Vision and Pattern Recognition. Washington DC: IEEE Computer Society, 2020: 1777–1786.

[35] Sheikh H R, Bovik A C, Veciana G. An information fidelity criterion for image quality assessment using natural scene statistics [J]. IEEE Trans on Image Processing, 2005, 14(12): 2117–2128.

[36] Sheikh H R, Bovik A C. Image information and visual quality [J]. IEEE Trans on Image Processing, 2006, 15(2): 430–444.

[37] Mittal A, Soundararajan R, Bovik Alan C. Making a "completely blind" image quality analyzer [J]. IEEE Signal Processing Letters, 2012, 20(3): 209–212.

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net