基于异步多时域特征的动态手势识别方法

崔 虎,黄仁婧,陈青梅,黄初华
贵州大学 计算机科学与技术学院,贵阳 550025

摘 要:准确及时地手势识别在增强现实技术中具有重要的意义。针对表征复杂手势序列的时空特征,提出了一种基于异步多时域时空特征的手势识别方法。该方法通过轻量级三维卷积网络提取视频序列的不同时间步态的短期时空特征,通过改进的卷积长短期记忆网络学习长期时空特征,将不同步态的时空特征融合为异步多时域特征,以此来对手势进行分类识别。通过与其他主流方法进行比较,实验结果证明了提出的方法具有较高的动态手势识别率。

关键词:增强现实;动态手势识别;时空特征;异步特征;融合预测
文献标志码:A **中图分类号:**TP391.41 doi:10.3778/j.issn.1002-8331.2103-0532

Dynamic Gesture Recognition Method Based on Asynchronous Multi-Time Domain Features

CUI Hu, HUANG Renjing, CHEN Qingmei, HUANG Chuhua
College of Computer Science &Technology, Guizhou University, Guiyang 550025, China

Abstract: Accurate and timely gesture recognition is of great significance in augmented reality technology. Aiming at the spatio-temporal features that characterize complex gesture sequences, a gesture recognition method based on asynchronous multi-time domain features is proposed. It extracts the short-term spatiotemporal features of the video sequences with different temporal resolution through a lightweight three-dimensional convolutional network, and learns long-term spatio-temporal features through an improved convolutional long short-term memory network. The temporal and spatial features of different steps are fused into asynchronous multi-time domain features to classify and recognize gestures. Compared with other state-of-the-art approaches, the experimental results show that the proposed method has a high dynamic gesture recognition accuracy.

Key words: augmented reality; dynamic gesture recognition; spatiotemporal feature; asynchronous feature; fusion prediction

手势是人类的一种重要交互手段,随着虚拟现实、增强现实、人机交互和手语翻译等领域的发展,手势识别已经成为了计算机视觉领域的热门课题之一[1],与该领域的其他任务如图像分类、语义分割、目标检测、场景识别等类似,目前动作与手势识别的研究主要是基于卷积神经网络。

动态手势识别不仅需要关注手部的形状特点,同时也需要关注手形变化以及运动过程,因此不仅需要解决与静态手势相同的环境干扰,如光线、纹理、摄像分辨率等外部问题,还需要解决手部运动与手形变化等问题,除此之外,动态手势识别还存在以下技术难点[2]:(1)手势速度差异性,即同一个含义的手势动作可以以不同速度来完成。(2)手势运行时间长度异同性,即不同的手势完成时间往往是不同的。(3)手势形状的多样性。静态手势不同形状表示不同语义,而动态手势中不同形状的手形的相近运动却往往可以表达相同的语义。动态手势的时序复杂性和空间多样性等特点为动态手势识别带来了诸多挑战。

目前主流手势与动作识别的工作都是基于RGB图像、Depth图像、光流图以及骨骼关键点信息[3]。Simonyan等[4]提出了一种双流网络模型来对动态手势和行为进行识别,核心思想是用RGB信息流来表达动态手势的空间特征,用光流信息流来表示手势动作的运动特征,然而该方法并未考虑空间信息流和运动信息流间的内在关系。Tran等[5]对双流网络模型进行了改进,应用光流来指引RGB信息流网络分支的特征提取,使RGB流特

基金项目:贵州省自然科学基金(黔科合基础[2019]1088);贵州大学引进人才科研项目(贵大人基合字(2017)31号,贵大人基合字(2015)52号)。
作者简介:崔虎(1987—),男,硕士研究生,研究方向为计算机视觉、增强现实;黄仁婧(1996—),女,硕士研究生,研究方向为计算机视觉、增强现实;陈青梅(1996—),女,硕士研究生,研究方向为强化学习、增强现实;黄初华(1978—),通信作者,男,博士,副教授,研究方向为移动增强现实、计算机视觉,E-mail:chhuang@gzu.edu.cn。
收稿日期:2021-03-29 **修回日期:**2021-05-20 **文章编号:**1002-8331(2022)21-0163-09

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

征拥有部分运动信息,但是该方法本质上还是双流模型,而光流本身无法表达完整的运动信息。Liu等[6]提出了一种分段手势识别方法,首先通过子神经网络估计手势图像深度,然后将深度信息与RGB信息结合,用来识别手势,该方法同样存在运动信息不完整的缺点。Köpüklü等[7]提出了一种将检测与分类相结合的方法来降低系统负载和提升手势识别实时性,使得手势识别更加容易部署于移动设备,但在识别算法方面改进有限。Hara等[8]提出对二维卷积网络(two-dimensional convolutional network,2DCNN)进行时间维度扩展得到三维卷积网络(three-dimensional convolutional network,3DCNN)的方法,并将其应用于动作识别。而3DCNN因为参数量过大,如果没有足够多的训练数据支持,其模型很容易过拟合。Min等[9]提出了一种基于点云和骨骼关键点的手势识别方法,该方法将动态手势的关键点云作为序列,应用长短期记忆网络(long short-term memory,LSTM)对其进行建模,捕捉手势的长期空间相关性,该方法不足之处在于需要预先提取手部关键点数据。

本文从手势的速度和长度两方面性质出发,提出了一种异步多时域网络模型,其网络结构如图1所示,首先通过轻量级3DCNN[8]网络提取出手势的短期异步时空特征,然后通过改进的卷积长短期记忆网络[10](ConvLSTM)对短期异步时空特征进行长期关系建模,使模型可以捕捉到不同速率和不同长度手势的时空特征,最终达到对复杂动态手势的有效识别。

本文的创新在于:

(1)提出一种从视频数据抽取异步特征的方法,所得的异步特征对不同速率,不同大小手势均有较强的鲁棒性,从而显著提高模型的识别能力。

(2)分段抽取动作的短期与长期时空特征,并融合两种时域的异步特征,提升对不同时间长度的手势的识别效果。

1　相关工作

动态手势识别的关键和难点在于对手势动作的时空信息处理[11],处理方法可以分为传统手工特征提取方法和深度学习方法。

传统手工特征提取方法大多采用动态时间规整算法[12](dynamic time warping,DTW)、时间金字塔[13]、隐马尔可夫模型[14](hidden Markov models,HMM)等来对手势时空信息进行建模。其中DTW方法是对捕捉到手势的关键点轨迹应用动态时间规整进行模板匹配,捕捉手势关键点坐标轨迹和形状数据则需要专门的传感器,模板匹配也需要设置特定的匹配模板;时间金字塔方法对完整的手势帧进行不同时间长度采样来处理手势的时空特征;HMM则只能关注较短时间内的手势历史信息,从而忽略了手势的连续性和完整性等特点。

在深度学习方法中,为了使模型能够捕获更加完整的手势动作信息,Varol等[15]将2DCNN网络与LSTM网络[16]相结合,对模型输入视频帧数量进行提升,使得模型输入视频帧从16帧增加到60帧,并应用双流网络模型[4]的思想,用光流进行运动信息补充。然而,输入数据的增加使得模型变得更加臃肿,难以应用于实时设备。Zhu等[17]将3DCNN与时间金字塔方法结合,使模型可以捕获手势的长时间的历史特征信息,然而模型的3DCNN结构依然面临参数量过大以及数据量不足的问题。Liu等[18]为解决多尺度目标的检测与回归问题,从网络的不同深度提取不同尺度的特征图来做预测与回归;Feichtenhofer等[19]从时间尺度将双流模型思想进行了扩展,引入快速流和慢速流的概念来进行人体行为识别;Chen等[20]对大型卷积网络进行纤维化改进,使得3DCNN更加轻量化。受以上工作的启发,本文对3DRestNet[8]进行结构调整,用来提取手势的短期时空特征,然后应用改进的ConvLSTM对短期时空特征

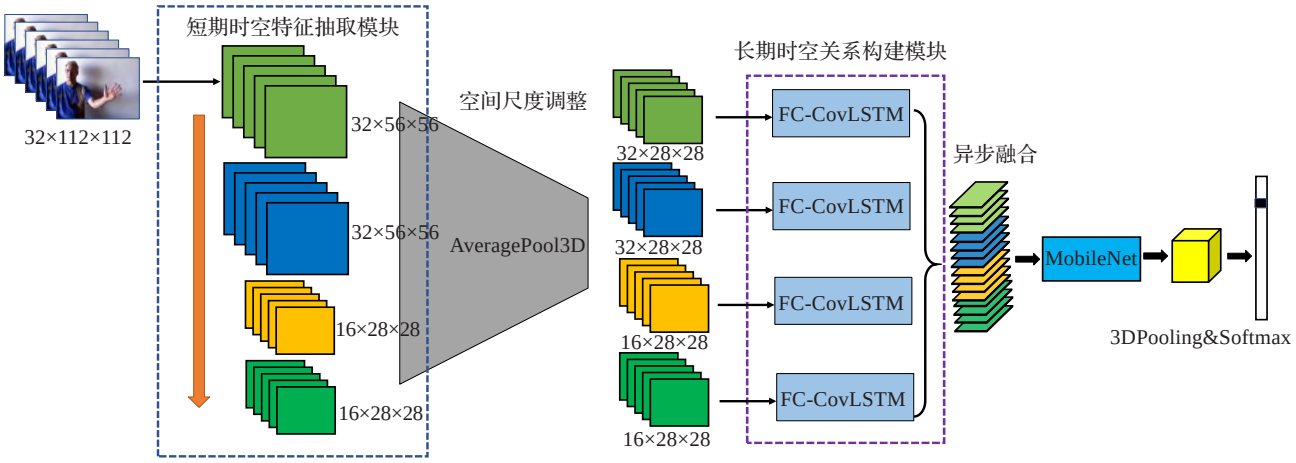

图 1 异步多时域动态手势识别网络

Fig.1　Asynchronous multi-temporal dynamic gesture recognition network

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

进行长期关系建模，从而得到多时域的时空特征。为了提高模型对不同运行状态手势的鲁棒性，网络采用了异步结构，最终模型对不同速率和不同时间长度的手势均能准确的检测与识别。

2　本文提出的异步多时域网络模型

异步多时域网络总体架构如图1所示，网络特征提取部分由短期时空特征抽取模块和长期时空关系构建模块组成，预测解码部分则由主要由微调后的MobileNetV2网络构成。其中短期时空特征抽取模块由轻量级三维卷积网络构成，负责进行短期异步时空特征的提取，长期时空关系构建模块由改进的ConvLSTM网络构成，负责对短期特征进行长期关系建模，使模型提取的手势动作特征包含丰富的运动信息，如：手势快慢、动作长度等信息。

2.1　短期异步时空特征抽取

2.1.1　三维卷积视频序列特征

二维卷积用来对单幅图像的空间特征的提取，在对视频图像序列处理的过程中，处理对象也是单个独立的帧，并未考虑帧与帧之间的相关性，如图2所示。

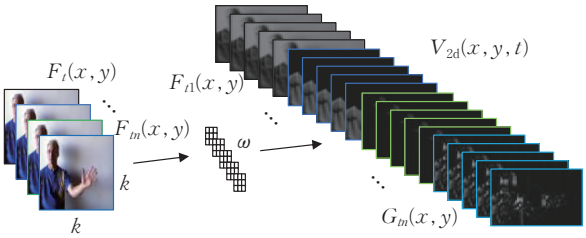

图2　二维卷积对视频序列的特征提取

Fig.2　Feature extraction of video sequence by 2D-CNN

当时间维度卷积次数越多，所得到的特征图中的历史信息则越多，其数学表达如公式（1）所示：

$$\begin{cases} G(x,y)=\omega * F_t(x,y) \\ G(x,y)=\left(\sum_{dx=0}^{k}\sum_{dy=0}^{k}\omega(dx,dy)\cdot F_t(x+dx,y+dy)\right) \\ V_{2d}(x,y,t)=\left[G_{t1}(x,y),G_{t2}(x,y),\cdots,G_{tn}(x,y)\right] \\ V_{2d}(x,y,t)=\left[\omega * F_{t1}(x,y),\omega * F_{t2}(x,y),\cdots,\omega * F_{tn}(x,y)\right] \end{cases} \tag{1}$$

其中，x,y 为图像坐标，$*$ 表示卷积运算，$F_t(x,y)$ 为单通道输入图像，ω 为二维卷积核，$G(x,y)$ 为运算后的特征图，$V_{2d}(x,y,t)$ 为整体的时空序列图，从 $V_{2d}(x,y,t)$ 的结果可以看出整个视频序列的各帧图像的特征是时间无关的，而事实上视频中的动作序列是紧密相关的，正因为这种相关性才构成了人眼所见的不同的动态行为。三维卷积是将二维卷积从空间尺度扩展到时间尺度的卷积，如图3所示。

三维卷积是将视频序列整体当做运算对象，其数学表达如公式（2）所示：

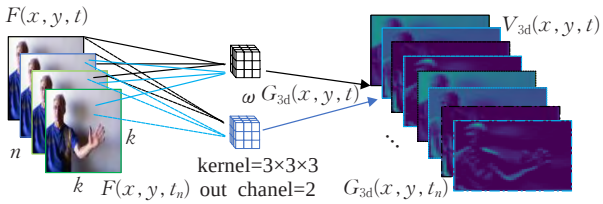

图3　三维卷积对视频序列的特征提取

Fig.3　Feature extraction of video sequence by 3D-CNN

$$\begin{cases} G_{3d}(x,y,t)=\omega * F(x,y,t) \\ G_{3d}(x,y,t)=\sum_{dt=0}^{k_t}\sum_{dx}^{k}\sum_{dy}^{k}\omega(dx,dy,dt)\cdot \\ \qquad F(x+dx,y+dy,t+dt) \\ V_{3d}(x,y,t)=\left[G_{3d}(x,y,t_1),G_{3d}(x,y,t_2),\cdots,G_{3d}(x,y,t_n)\right] \end{cases} \tag{2}$$

其中，ω 此时为三维卷积核，F 为整个视频序列输入，$V_{3d}(x,y,t)$ 为 F 的时空特征，$G_{3d}(x,y,t)$ 为 t 时刻的局部时空特征，k_t 为卷积核时间维度大小，可以看出，当 $k_t=3$ 时，G_{3d} 是与前后相邻帧有关的局部时空特征，这种具有时间维度相关性的视频序列特征与一个动作的前后连续表达的性质是相符合的。

2.1.2　短期时空特征提取

3DCNN依据不同的架构策略形成了如C3D[21]、I3D[22]、R3D[8]等大型3D-CNN模型，网络深度的增加意味着网络参数量增大和冗余噪声信息的增多，消除负面影响的一种有效方法就是为模型提供足够多的训练数据，然而视频是图像三维扩展，构建一个类似于Imagenet[23]的通用大型视频数据集无论在质量和数量上都面临巨大的困难。

本文的短期时空特征提取模块只负责提取视频序列的短期时空特征，因此该部分3D卷积网络的深度并不要求足够的深，只需要将现有的2D卷积主流网络（ResNet、DensNet、Efficient）中的卷积和池化层进行时间维度扩展即可，本文中短期时空特征提取网络是将ResNet进行时间维度扩展，并进行适当的微调，最终的网络结构如图4所示，网络由四个3D卷积块组成，其中第一个卷积块只包含一个3D卷积，后三个卷积块的结构相同，都是对前一个卷积块的输出进行多次3D卷积残差，不同的只是内部各个卷积的具体参数设置，图4中的各个卷积的具体参数如表1所示，网络中所有卷积运算后都包含了批标准化和激活函数，其中激活函数为ReLU6。

2.1.3　短期异步时空特征

在对灵长类视网膜神经节细胞的研究中[24]，研究者发现这些细胞中约80%为小细胞，15%~20%为大细胞，大细胞对高频运动信号十分敏感，但对物体细节、颜色纹理以及低速运动信号无法作出准确的反馈，而小细胞相反，对物体的空间细节、颜色纹理和低频运动敏感度较高，而对高频运动信号的刺激反馈迟钝。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

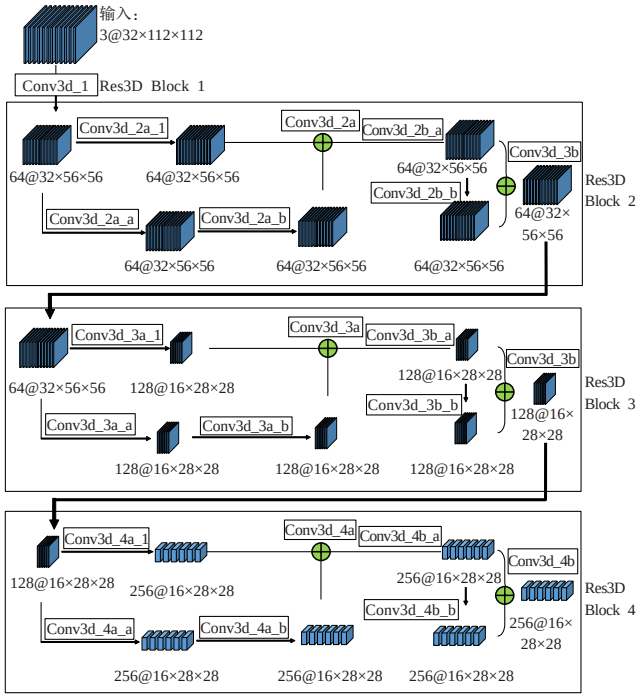

图4　短期时空特征网络结构

Fig.4　Structure of short term spatiotemporal network

表1　短期时空特征提取模块网络参数

Table 1　Parameters of short-term spatiotemporal feature extraction network

卷积名称	输出通道	卷积核	Strides	尺寸
输入	3	—	—	32×112×112
conv3d_1	64	3,7,7	1,2,2	32×56×56
conv3d_2a_1	64	1,1,1	1,1,1	32×56×56
conv3d_2a_a	64	3,3,3	1,1,1	32×56×56
conv3d_2a_b	64	3,3,3	1,1,1	32×56×56
conv3d_2a(add)	—	—	—	32×56×56
conv3d_2b_a	64	3,3,3	1,1,1	32×56×56
conv3d_2b_b	64	3,3,3	1,1,1	32×56×56
conv3d_2b(add)	—	—	—	32×56×56
conv3d_3a_1	128	1,1,1	2,2,2	16×28×28
conv3d_3a_a	128	3,3,3	2,2,2	16×28×28
conv3d_3a_b	128	3,3,3	1,1,1	16×28×28
conv3d_3a(add)	—	—	—	16×28×28
conv3d_3b_a	128	3,3,3	1,1,1	16×28×28
conv3d_3b_b	128	3,3,3	1,1,1	16×28×28
conv3d_3b(add)	—	—	—	16×28×28
conv3d_4a_1	256	1,1,1	1,1,1	16×28×28
conv3d_4a_a	256	3,3,3	1,1,1	16×28×28
conv3d_4a_b	256	3,3,3	1,1,1	16×28×28
conv3d_4a(add)	—	—	—	16×28×28
conv3d_4b_a	256	3,3,3	1,1,1	16×28×28
conv3d_4b_b	256	3,3,3	1,1,1	16×28×28
conv3d_4b(add)	—	—	—	16×28×28

基于以上生物学研究的启发，将短期特征提取模块得到四种不同时间跨度与不同分辨率的输出特征序列进行调整与融合，组合成异步特征。从图4与表1中可以看到短期时空特征提取模块的四个输出分别是64@32×56×56、64@32×56×56、128@16×28×28、256@16×28×28，第一个卷积块和第二卷积块输出的特征图是相同的，它们在时间维度的采样频率也是相同的，但是在时间维度的感受野却不同，四个输出的感受野分别是3^1、3^5、3^9、3^{13}，还可以看出第一、第二、第三和第四个卷积块的时间步态是不同的，后两个的时空特征感受野更大，但更偏于低频，而前二的时空特征感受野偏小，但对高频运动更加敏感。将不同步态和感受野的时空特征进行融合，得到异步时空特征，对变化快慢不同的手势都可以进行全面特征描述，同时这种策略也符合生物的视觉感官直觉。

2.2　长期时空关系构建

对于一般用途的序列建模，LSTM作为一种特殊的RNN结构，在以往的研究中已经被证明是稳定且有效的，它用来对序列进行长期依赖关系建模，在其基础上的FC-LSTM[25]、ConvLSTM[10]等模型则专门用来对视频序列的长期依赖关系进行建模。FC-LSTM、ConvLSTM等模型是直接应用于原始视频序列数据，而本文的时间序列网络的对象则是短期异步时空特征网络的输出，因此对ConvLSTM的内部结构进行了调整和改进，以使序列预测模型部分更加高效和便捷。

2.2.1　ConvLSTM

FC-LSTM和ConvLSTM模型均是LSTM与CNN的结合，所不同的是前者为串联结合，后者则为内部结构融合，图5为LSTM内部结构。

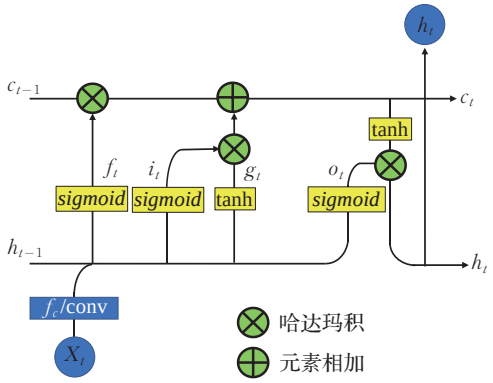

图5　LSTM内部结构示意图

Fig.5　LSTM internal structure

ConvLSTM中的各个门控运算均为卷积运算，其内部结构如公式(3)所示：

$$\begin{cases} i_t=\sigma(\boldsymbol{W}_{xi}*x_t+\boldsymbol{W}_{hi}*\boldsymbol{h}_{t-1}+b_i) \\ f_t=\sigma(\boldsymbol{W}_{xf}*x_t+\boldsymbol{W}_{hf}*\boldsymbol{h}_{t-1}+b_f) \\ o_t=\sigma(\boldsymbol{W}_{xo}*x_t+\boldsymbol{W}_{ho}*\boldsymbol{h}_{t-1}+b_o) \\ g_t=\tanh(\boldsymbol{W}_{xc}*\boldsymbol{x}_t+\boldsymbol{W}_{hc}*\boldsymbol{h}_{t-1}+b_c) \\ c_t=f_t\circ c_{t-1}+i_t\circ g_t \\ h_t=o_t\circ\tanh(c_t) \end{cases} \tag{3}$$

其中，$\circ$表示哈达玛乘积，$*$表示卷积运算，σ表示

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

sigmoid 激活函数，tanh 表示 tanh 激活函数，i_t 表示输入门，f_t 表示过滤门，o_t 为输出门，$W_{x\sim}$ 和 $W_{c\sim}$ 表示各个门与输入向量权重，h_{t-1} 和 h_t 表示历史隐藏状态和当前隐藏状态，x_t 表示输入序列，ConvLSTM结构中 x_t 与 X_t 相同，表示视频序列或者特征图序列的第 t 个帧，因为ConvLSTM内部的运算均为卷积运算，所以可以自动对图像进行特征提取。而FC-LSTM的结构则如公式（4）所示：

$$\begin{cases} i_t = \sigma\left(W_{xi}\odot x_t + W_{hi}\odot h_{t-1} + b_i\right) \\ f_t = \sigma\left(W_{xf}\odot x_t + W_{hf}\odot h_{t-1} + b_f\right) \\ o_t = \sigma\left(W_{xo}\odot x_t + W_{ho}\odot h_{t-1} + b_o\right) \\ g_t = \tanh\left(W_{xc}\odot x_t + W_{hc}\odot h_{t-1} + b_c\right) \\ c_t = f_t \circ c_{t-1} + i_t \circ g_t \\ h_t = o_t \circ \tanh\left(c_t\right) \end{cases} \tag{4}$$

其中，$\odot$ 表示全连接运算，并且 x_t 与 X_t 不同，X_t 为视频序列或者特征图序列的第 t 帧，x_t 为 X_t 卷积后的一维向量，如公式（5）所示：

$$x_t = reshape[conv2d(X_t)] \tag{5}$$

2.2.2　局部卷积的FC-ConvLSTM

考虑到从轻量级3D-CNN网络提取的是具有短期异步信息的时空特征序列，这种特征与2D-CNN所提取的序列特征具有极大的不同，这些特征序列是具有时空相关性的特征序列，其拥有宝贵的时间信息，这与ConvLSTM中的卷积的作用在某种程度是重复的，在这种情况下，只要专注于长序列关系建模即可，因此将FC-LSTM和ConvLSTM特点相结合，构建适合短期异步时空特征的序列模型FC-ConvLSTM，其内部运算如公式（6）所示：

$$\begin{cases} \bar{x}_t = \text{Global AveragePoo1}\left(X_t\right) \\ \bar{h}_{t-1} = \text{Global AveragePool}\left(h_{t-1}\right) \\ i_t = \sigma\left(W_{xi}\odot \bar{x}_t + W_{hi}\odot \bar{h}_{t-1} + b_i\right) \\ f_t = \sigma\left(W_{xf}\odot \bar{x}_t + W_{hf}\odot \bar{h}_{t-1} + b_f\right) \\ o_t = \sigma\left(W_{xo}\odot \bar{x}_t + W_{ho}\odot \bar{h}_{t-1} + b_o\right) \\ g_t = \tanh\left(W_{xc} * X_t + W_{hc} * \bar{h}_{t-1} + b_c\right) \\ c_t = f_t \circ c_{t-1} + i_t \circ g_t \\ g_t = o_t \circ \tanh\left(c_t\right) \end{cases} \tag{6}$$

其中的 X_t 短期异步时空特征序列的当前特征帧，$\bar{x}_t$ 为对其进行通道全局平均得到的特征图，$\bar{h}_t$ 为隐藏状态通道全局平均值，输入门 i_t、过滤门 f_t，以及 o_t 输出门的运算因此都变成了单通道卷积或者全连接运算，但是候选记忆门 g_t 的运算因为需要将原始序列特征的信息保存的历史状态信息 c_t 中，所以依然保留对 X_t 进行卷积运算。

相比于Conv-LSTM，FC-ConvLST中的各个门控节点的计算量大大的减少，除此之外，本文以深度可分离卷积来代替FC-ConvLSTM中的卷积操作，从而使模型的参数进一步降低。

2.3　异步特征融合与预测

在从FC-ConvLSTM得到异步时空特征因为进行过空间尺度调整所以除了时间步不同，尺度统一为28×28×512，而本文所采用的融合策略则是将不同时间步的特征在各个通道进行concate，最终得到1/2×temstep×28×28×512×4大小的异步融合时空特征，将该特征送入MobileNetv2预训练网络当中，得到时空特征序列尺度为1/2×temstep×4×4×1 024，之后经过3Dpool、FC、softmax分别进行下采样，全连接以及最终的概率估计得到预测结果。

3　实验结果与分析

硬件环境：NVidia Tesla P40 24 GB显卡 Intel Xeon E5-2650v4-2.20 GHz 12核64 GB CPU。

软件环境：Ubuntu18.04操作系统 Python2.7.1版 Tensorflow1.2.1版CUDA8.0 cuDNN5.0。

3.1　数据集及参数设置

为测试本文所提出算法的有效性，在两个典型公开数据集The 20BN-jester Dataset V1（Jester）和Sheffield Kinect Gesture（SKIG）上进行了实验。

Jester数据集[26]是一个最新的用于手势识别的大型视频数据集，它包含了27种在摄像机前执行的预定义手势。它从原始视频中以每秒12帧的速度提取了148 092个手势样本。样本分为三组，118 562个样本用于训练、14 787个样本用于验证、14 743个样本用于测试，视频的平均长度是35帧。

SKIG数据集[27]是利用微软Kinect设备的RGB摄像头和深度摄像头同步采集人体手势而得到，分别采集了6人的手势，每个手势都拥有RGB和Depth两种形式，共包含10种手势，总视频数2 160，RGB视频和Depth视频各占一半（6×10×3×3×2=1 080个），视频的长度从80帧到320帧不等。本文将该数据集随机分为三组，70%作为训练集，20%作为验证集，剩下的数据作为最终的测试集。

网络总体架构如图1所示，短期时空特征提取模块是将ResNet内部卷积扩展为3D卷积，具体参数如图4和表1所示，该部分理论上可以用其他轻量级网络来进行代替，在将短期异步特征序列送入FC-ConvLSTM之前，需要对异步特征进行尺度调整，对1和2卷积块的输出进行平均池化操作，池化大小为（1，3，3），池化步为（1，2，2），边缘扩展模式为“same”，而对3和4卷积块的输出则不需要进行调整，最终所有异步特征的空间尺度均为28×28；FC-ConvLSTM部分结构如图5与公式（6）所示，内部卷积采用可分离卷积结构，需要注意的是

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

FC-ConvLSTM只适合于短期时空特征提取模块的输出特征,应用于其他2DCNN处理的视频序列的效果并不出色,该部分由两层结构相同的FC-ConvLSTM组成,输出通道为256,卷积核为3×3,stride=(1,1),参数初始化采用he_normal方法,正则项均采用L2正则化;最后将融合了短期和长期的异步时空特征进行concat操作后再进行预测。

3.2　结果与分析

3.2.1　对比实验

模型总共在Jester数据上训练40个周期,学习率从0.001到0.000 001呈多项式衰减,输入为16个视频段,每个视频段均是通过随机策略从原始视频段中抽取的连续16个视频帧,并进行统一的随机图像增强,视频帧大小为112×112,训练后对模型在测试集上进行测试,得到其混淆矩阵如图6所示。

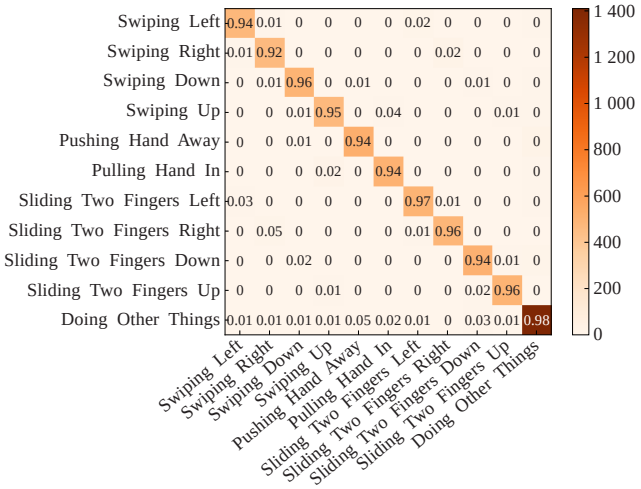

Accuray=0.951 6,misclass=0.048 7

图6　Jester数据上进行测试的前10个类别混淆矩阵

Fig.6　Confusion matrix for testing on first ten classes of Jester data

将结果与传统的C3D[21]、3DrestNet101[8]及最新模型RT-C3D[28]、3D-GestNet[29]进行了对比,结果如表2所示。

表2　Jester数据集上手势识别实验结果

Table 2　Gesture recognition results on Jester dataset

方法	输入帧数	分辨率	准确率/%
M-C3D[21]	32	112×112	89.26
3DRestNet101[8]	16	224×224	85.99
2DCNN+LSTM[15]	16	112×112	86.31
3DCNN+Rest18	16	112×112	81.55
RT-C3D[28]	16	140×100	92.65
3D-GesNet[29]	16	112×112	93.99
Ours	16	112×112	**95.16**

从表2中可以看出:(1)在Jester这种大型的动态手势数据集中,3DCNN网络的参数可以充分地被训练,相比2DCNN+LSTM网络,各种3DCNN网络的结果表现的更好。(2)与3D系列网络相比较,本文将3D与FC-ConvLSTM相结合后效果提升1.7%,一部分原因在于本文3DCNN网络部分提取的特征是异步时空特征,另一方面则在于使用FC-ConvLSTM对时空特征进行更广泛时间域建模。

在SKIG数据集上,输入为4个视频段,每个视频段为32或16个视频帧,训练过程中对视频进行亮度色度等图像增强预处理,视频帧大小为112×112,实验结果如表3所示。

表3　SKIG数据集上实验结果

Table 3　Gesture recognition results on SKIG dataset

方法	输入帧数	分辨率	准确率/%
3DRestNet101[8]	32	112×112	75.46
2DCNN+LSTM[15]	32	112×112	87.98
RGGP+RGB-D[27]	32	112×112	88.71
MRNN[30]	32	112×112	97.80
Dens3D+RGB-D[31]	32	112×112	**99.07**
Dens3D-RGB[31]	32	112×112	96.11
Ours	16	112×112	96.13
Ours	32	112×112	**99.17**

从表3中可以看出:(1)2DCNN+LSTM网络在较小的数据集上相比于3DResNet101网络的效果要好12个百分点左右,值得说明的是其中的3DResNet101是在Jester数据集上预训练集后经过微调再训练的结果,这表明在较小的数据集上,即便是使用了迁移学习的预训练3DCNN网络也依然存在过拟合问题。(2)相比于同样经过轻量化处理Dens3D+金字塔模型[31],本文的算法也显示出一定优势,当输入帧数为16帧时,本文的结果可以达到Dens3D输入为32帧的结果,从而验证了异步结构的有效性。而当输入同为32帧时,本文的结果优于Dens3D双模态融合的结果,而本文所用的仅仅只有RGB模态,这从某种角度说明异步时空特征中不仅融合了异步时间尺度信息,同时融合类似深度信息的异步的空间尺度信息。

3.2.2　消融实验

本文算法的核心在于通过短期时空特征提取模块提取异步特征,之后通过微调FC-ConvLSTM来使短期异步特征具有关注长期历史信息的能力。为了更深入地对模型各个部分的贡献进行研究,在SKIG数据集上进行消融实验,其结果如表4所示。

表4　不同网络结构消融实验结果

Table 4　Ablation results on different structions of network

方法	准确率/%	计算量(Mult-Adds)/10^6
3DCNN	98.61	826
3DCNN+ConvLSTM	98.33	2 182
3DCNN+FC-LSTM	98.95	993
3DCNN+FC-ConvLSTM	99.17	1 240

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

从表4中可以看出：（1）当只使用短期异步时空特征进行手势预测的结果达到了98.61%，在其基础上应用ConvLSTM进行长期时序建模后的预测结果反而下降到了98.33%，这表明对于3DCNN提取的异步时空特征，ConvLSTM内部的卷积运算是冗余的，这从3DCNN+FC-LSTM的结果也可以看出。（2）在将ConvLSTM的各个门控卷积替换成为3Dpool和全连接的结构后，模型的整体运算相比ConvLSTM的运算降低了接近一倍，同时准确率得到了提升。

将网络每个阶段的中间输出前八帧的第一个通道特征进行可视化，效果如图7所示。

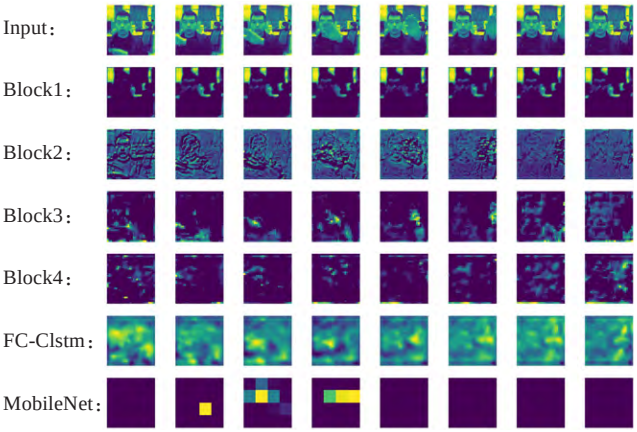

图7　网络中间结果抽取可视化

Fig.7　Visualization of network intermediate results

从图7中可以看出：短期时空特征抽取模块中的四个卷积块的时空特征表现有很大的不同，分别关注背景变化特征、前景纹理变化特征、手部位置变化信息、关键点移动信息，那么如果对该部分卷积块数量进行扩充，能否得到更多有用的时空特征，为此本文对不同深度3DCNN构成的短期时空特征抽取模块进行了测试，结果如表5所示。

表5　不同深度的异步结构的效果

Table 5　Effects of asynchronous structures of different

Block数量	准确率/%	计算量（Mult-Adds）/10^6
1	90.28	—
2	96.11	—
3	96.94	1 105
4	99.17	1 240
5	99.15	1 955
6	99.17	2 669

从表5中可以看出，当短期时空特征抽取模块的卷积块数量从1增加到2时，手势识别结果的准确度提高了近6个百分点，而当增加至4个的时候，识别准确度达到最大，之后继续增加block数量结果并未再提高。这表明：（1）本算法的异步多尺度时空特征相比于单独3DCNN提取非异步特征对原始视频时空语义的表达更加充分。（2）本算法的短期异步时空特征提取模块确实只需要根据应用场景构建合适的轻量级3DCNN网络即可，这与“奥卡姆剃刀定律”不谋而合。

六种block组成的模型训练曲线画如图8所示。

从图8中可以看出，在训练SKIG数据的过程中，短期异步时空网络的卷积块达到4个的时候，在保证测试准确率达到最高的前提下，其训练效率是最好的，减少卷积块数目会使验证准确率降低，提高卷积块数目则会使模型变大，训练变慢，而准确率无明显提升。

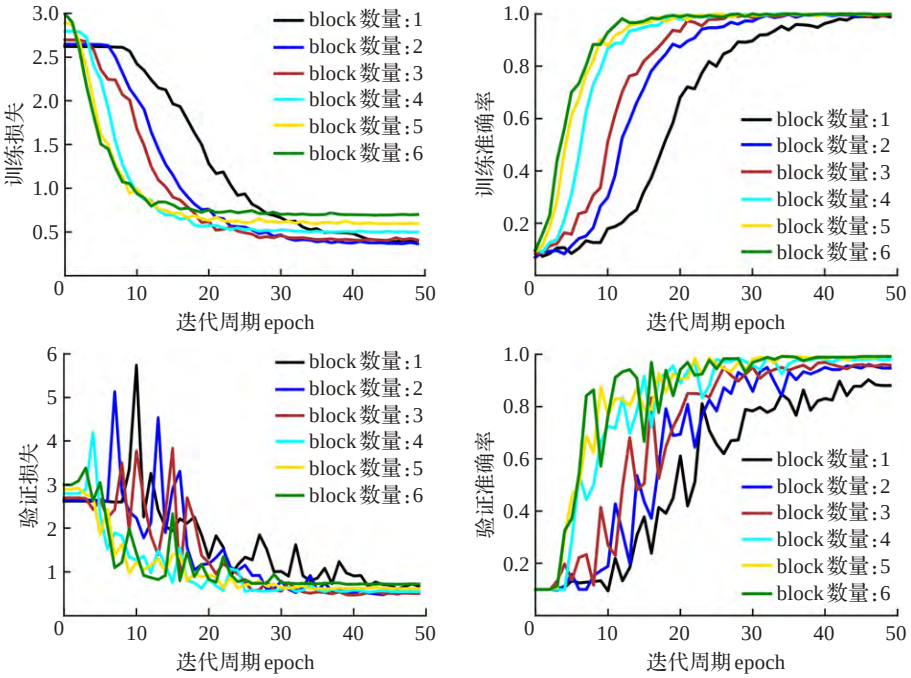

图8　不同深度卷积块的训练曲线

Fig.8　Training curves of different depth convolution blocks

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

4 结束语

本文提出了异步多时域手势识别方法,应用轻量级3DCNN网络提取动态手势的短期异步时空特征,FC-ConvLSTM建立长短期异步时空特征。实验结果表明,本文所提网络在不同规模与平均长度的数据集上均取得了更好的结果,证明了模型的有效性和合理性。同时也发现对于训练数据不均衡的相似动作未能得到较好的识别率。在未来工作中,将计划在更多的模态上进行类似实验,并尝试结合提升方法来处理样本不均衡问题。

参考文献:

[1] ASADI-AGHBOLAGHI M,CLAPÉS A,BELLANTONIO M,et al.A survey on deep learning based approaches for action and gesture recognition in image sequences[C]//2017 IEEE International Conference on Automatic Face & Gesture Recognition(FG 2017),Washington,DC,USA,2017:476-483.

[2] 孙玉,袁贞明,孙晓燕.基于Leap Motion的动态手势识别[J].计算机工程与应用,2019,55(13):151-157.
SUN Y,YUAN Z M,SUN X Y.Dynamic gesture recognition based on leap motion[J].Computer Engineering and Applications,2019,55(13):151-157.

[3] 谭立行,鲁嘉淇,张笑楠,等.基于轻量级OpenPose改进的幻影机手势交互系统[J].计算机工程与应用,2021,57(16):159-166.
TAN L X,LU J Q,ZHANG X N,et al.Improved ghost-machine gesture interaction system based on lightweight OpenPose[J].Computer Engineering and Applications,2021,57(16):159-166.

[4] SIMONYAN K,ZISSERMAN A.Two-stream convolutional networks for action recognition in videos[C]//Proceedings of the 27th International Conference on Neural Information Processing Systems(NLPS),Cambridge,USA,2014:568-576.

[5] TRAN A,CHEONG L F.Two-stream flow-guided convolutional attention networks for action recognition[C]//2017 IEEE International Conference on Computer Vision Workshop(ICCVW),Venice,Italy,2017:3110-3119.

[6] LIU J,FURUSAWA K,TATEYAMA T,et al.An improved hand gesture recognition with two-stage convolution neural networks using a hand color image and its pseudo-depth image[C]//2019 IEEE International Conference on Image Processing(ICIP),2019:375-379.

[7] KÖPÜKLÜ O,GUNDUZ A,KOSE N,et al.Real-time hand gesture detection and classification using convolutional neural networks[C]//2019 14th IEEE International Conference on Automatic Face & Gesture Recognition(FG 2019),Lille,France,2019:1-8.

[8] HARA K,KATAOKA H,SATOH Y.Can spatiotemporal 3D CNNs retrace the history of 2D CNNs and ImageNet?[C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition(CVPR),Salt Lake City,UT,USA,2018:6546-6555.

[9] MIN Y,ZHANG Y,CHAI X,et al.An efficient PointLSTM for point clouds based gesture recognition[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition(CVPR),Seattle,WA,USA,2020:5760-5769.

[10] SHI X,CHEN Z,WANG H,et al.Convolutional LSTM network:a machine learning approach for precipitation nowcasting[C]//Proceedings of the 28th International Conference on Neural Information Processing Systems(NIPS),Cambridge,MA,USA,2015:802-810.

[11] LIU Z,HU H,ZHANG J.Spatiotemporal fusion networks for video action recognition[J].Neural Processing Letters,2019,50(1):1877-1890.

[12] 余思泉,曹江涛,李平,等.基于空间金字塔特征包的手势识别算法[J].智能系统学报,2015,10(3):429-435.
YU S Q,CAO J T,LI P,et al.Hand gesture recognition based on the spatial pyramid bag of features[J].CAAI Transactions on Intelligent Systems,2015,10(3):429-435.

[13] 胡敦利,柯浩然,张维.基于Kinect和ROS的骨骼轨迹人体姿态识别研究[J].高技术通讯,2020,30(2):177-184.
HU D L,KE H R,ZHANG W.Research on human body attitude recognition based on Kinect and ROS[J].High Technology Letters,2020,30(2):177-184.

[14] 杨世强,罗晓宇,李小莉,等.基于DBN-HMM的人体动作识别[J].计算机工程与应用,2019,55(15):169-176.
YANG S Q,LUO X Y,LI X L,et al.Human action recognition based on DBN-HMM[J].Computer Engineering and Applications,2019,55(15):169-176.

[15] VAROL G,LAPTEV I,SCHMID C.Long-term temporal convolutions for action recognition[J].IEEE Transactions on Pattern Analysis & Machine Intelligence,2018,40(6):1510-1517.

[16] SARKAR A,GEPPERTH A,HANDMANN U,et al.Dynamic hand gesture recognition for mobile systems using deep LSTM[C]//International Conference on Intelligent Human Computer Interaction,Evry,France,2017:19-31.

[17] ZHU G,ZHANG L,MEI L,et al.Large-scale isolated gesture recognition using pyramidal 3D convolutional networks[C]//2016 23rd International Conference on Pattern Recognition(ICPR),Cancun,Mexico,2016:19-24.

[18] LIU W,ANGUELOV D,ERHAN D,et al.SSD:single shot MultiBox detector[C]//European Conference on Computer Vision(ECCV),Amsterdam,The Netherlands,2016:21-37.

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

[19] FEICHTENHOFER C,FAN H,MALIK J,et al.SlowFast networks for video recognition[C]//2019 IEEE/CVF International Conference on Computer Vision(ICCV),Seoul,Korea(South),2019:6201-6210.

[20] CHEN Y,KALANTIDIS Y,LI J,et al.Multi-fiber networksfor video recognition[C]//15th European Conference on Computer Vision(ECCV),Munich,Germany,2018:364-380.

[21] TRAN D,BOURDEV L,FERGUS R,et al.Learning spatiotemporal features with 3D convolutional networks[C]//2015 IEEE International Conference on Computer Vision(ICCV),Santiago,Chile,2015:4489-4497.

[22] TRAN D,WANG H,TORRESANI L,et al.A closer look at spatiotemporal convolutions for action recognition[C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition(CVPR),Salt Lake City,UT,USA,2018:6450-6459.

[23] RUSSAKOVSKY O,DENG J,SU H,et al.ImageNet large scale visual recognition challenge[J].International Journal of Computer Vision,2015,115(3):211-252.

[24] HE K,ZHANG X,REN S,et al.Delving deep into rectifiers:surpassing human-level performance on ImageNet classification[C]//2015 IEEE International Conference on Computer Vision(ICCV),Santiago,Chile,2015:1026-1034.

[25] 程子均,马六章,张翼翔.基于LSTM-FC的瓦斯浓度时空分布预测[J].计算机工程与应用,2020,56(16):258-264.
CHEN Z J,MA L Z,ZHANG Y X.Prediction of spatiotemporal distribution of gas concentration based on LSTM-FC model[J].Computer Engineering and Applications,2020,56(16):258-264.

[26] MATERZYNSKA J,BERGER G,BAX I,et al.The Jester dataset:a large-scale video dataset of human gestures[C]//2019 IEEE/CVF International Conference on Computer Vision Workshop(ICCVW),Seoul,Korea(South),2019:2874-2882.

[27] LIU L,SHAO L.Learning discriminative representations from RGB-D video data[C]//International Joint Conference on Artificial Intelligence(IJCAI),Beijing,China,2013:1493-1500.

[28] BALDISSERA F B,VARGAS F L.A light implementation of a 3D convolutional network for online gesture recognition[J].IEEE Latin America Transactions,2020,18(2):319-326.

[29] LI Y,XU L,SHU W,et al.AutoGesNet:auto gesture recognition network based on neural architecture search[C]//2020 12th International Conference on Advanced Computational Intelligence(ICACI),Dali,China,2020:57-262.

[30] NISHIDA N,NAKAYAMA H.Multimodal gesture recognition using multi-stream recurrent neural network[C]//Pacific-Rim Symposium on Image and Video Technology(PSIVT),Auckland,New Zealand,2015:682-694.

[31] 马正文,蔡坚勇,刘磊,等.基于RGB-D视频的多模态手势识别[J].计算机系统应用,2018,27(12):234-239.
MA Z W,CAI J Y,LIU L,et al.Multimodal gesture recognition based on RGB-D video[J].Computer Systems & Applications,2018,27(12):234-239.

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net