基于 DRQN 的视觉 SLAM 参数自适应调整

陈青梅，秦 进，黄仁婧，崔 虎，黄初华+

（贵州大学 计算机科学与技术学院，贵州 贵阳 550025）

摘 要：为解决传统视觉 SLAM 算法中的参数调整问题，提出一种基于深度循环 Q 网络的视觉 SLAM 参数自适应调整方法。筛选视觉 SLAM 参数构建动作空间；采用地标点的协方差矩阵描述视觉定位的不确定性，用地标点的不确定性构建奖励函数；参数智能体通过 ε-greedy 策略选择 Q 值最大的动作作用于视觉 SLAM 环境，根据环境的反馈更新网络参数。EuRoC 和 TUM-VI 数据集上的实验结果表明，该方法提高了室内场景下的位姿轨迹精度，避免了复杂的参数调整过程。

关键词：视觉 SLAM；深度循环 Q 网络；ε-greedy 策略；不确定度；参数自适应调整

中图法分类号：TP242 **文献标识号**：A **文章编号**：1000-7024（2022）11-3235-08

doi：10.16208/j.issn1000-7024.2022.11.031

Visual SLAM parameter adaptive adjusting method based on DRQN

CHEN Qing-mei，QIN Jin，HUANG Ren-jing，CUI Hu，HUANG Chu-hua+

(College of Computer Science and Technology，Guizhou University，Guiyang 550025，China)

Abstract：To solve the problem of parameter adjustment in traditional visual SLAM algorithms，an adaptive adjustment method of visual SLAM parameters based on deep recurrent Q-network was proposed. Visual SLAM parameters were filtered to form the action space. The covariance matrix of landmark was regarded to represent the visual localization uncertainty，and the uncertainty of landmark was used to construct the reward function. The ε-greedy strategy was adopted to select the action with the largest Q value and transmits it to the visual SLAM environment，and the network parameters were updated based on environment feedback. Experimental results on EuRoC and TUM-VI datasets show that the proposed method improves the pose trajectory accuracy in indoor scenes and avoids the complicated parameter adjusting process.

Key words：visual SLAM；deep recurrent Q-network；ε-greedy strategy；uncertainty；parameter adaptive adjusting

0 引 言

视觉 SLAM 以摄影机作为传感器，以图像作为主要环境感知信息源的 SLAM 系统，作为当今前沿技术之一，在 AR/VR、移动机器人等新兴领域都具有广泛的应用。但目前大多数视觉 SLAM 参数都是通过多次实验得到的经验值，在实际应用中采用固定的参数配置，当改变传感器或场景时需重新调整参数，这对于非专业的用户来说是一件相对耗时的工作。针对该问题，研究者们提出了多种自适应调整参数的方法来提高视觉 SLAM 的定位精度和鲁棒性。如 Khalufa 等[1]提出一种视觉 SLAM 轻量级动态控制策略，该策略依赖摄影机运动来自适应调整算法和计算设备的控制参数，可以实现动态控制参数的效果，但算法没有考虑场景信息，在算法运行时位姿跟踪精度和鲁棒性有所降低。Kuo 等[2]提出一个自适应 SLAM 算法，该算法可适用于多个摄影机位的设置并根据摄影机之间的几何关系来在线选择最合适的初始化方法，在鲁棒性方面有所提高，但跟踪精度提升不明显且增加视觉前端的设计复杂度。以上方法是从传感器的角度来考虑问题，对算法自身参数的自适应调整没有过多研究，此外，这些算法在精度、鲁棒性方面还有一定的提升空间。

为解决上述问题，需研究一种既考虑环境信息又不丢失精度和鲁棒性的视觉 SLAM 参数自适应调整方法，保证视觉 SLAM 算法在变化环境下的位姿轨迹精度和泛

收稿日期：2021-05-31；**修订日期**：2021-09-07

基金项目：国家自然科学基金项目（61562009）；贵州省自然科学基金项目（黔科合基础［2019］1088）

作者简介：陈青梅（1996-），女，贵州仁怀人，硕士研究生，研究方向为计算机视觉、强化学习；秦进（1980-），男，贵州毕节人，博士，副教授，研究方向为强化学习、机器学习；黄仁婧（1996-），女，贵州毕节人，硕士研究生，研究方向为计算机视觉、增强现实；崔虎（1987-），男，陕西西安人，硕士研究生，研究方向为计算机视觉、增强现实；+通讯作者：黄初华（1978-），男，贵州六盘水人，博士，副教授，CCF 会员，研究方向为混合现实、机器学习。E-mail：chhuang@gzu.edu.cn

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

化能力。

1 相关工作

主流的视觉 SLAM 通常分为 3 类：基于特征点、基于光流法和基于直接跟踪的 SLAM。基于直接法[3]和光流法[4]的 SLAM 通过比较像素的亮度信息来估计相机运动，不用计算关键点和描述子，节省了特征提取和匹配的大量时间，在特征点缺失或光照变化不明显的场景下能取得不错的估计效果。基于特征点的 SLAM 算法主要通过对图像进行特征点检测，并借助 2D 或 3D 的特征点匹配，利用多视图几何原理来计算摄影机位姿以及构建环境地图。其中，具有代表性工作的是 Raul Mur-Artal 等提出的 ORB_SLAM[5]，它是一种基于 ORB（oriented FAST and rotated，BRIEF）特征的三维定位与地图构建算法，也是目前性能最好的单目视觉 SLAM 系统之一，其改进版本 ORB_SLAM2[6]加入了双目和 RGB-D 模式，进一步提高系统对不同传感器配置的适应能力。当前，最佳的是 2020 年 Campos 等[7]提出的 ORB_SLAM3，该系统除了包含 ORB_SLAM 和 ORB_SLAM2 的共有模块位姿跟踪、建图、重定位、闭环检测以外，新增了基于最大后验估计的 IMU 融合算法、鱼眼相机模型和多地图模式。此外，ORB_SLAM3 是一个多地图系统，跟踪丢失时，它会启动一个新的地图，当重新访问地图区域时，它将与以前的地图无缝地合并，与只使用最后几秒信息的视觉里程计系统相比，ORB_SLAM3 是一个在所有算法阶段能重用先前所有信息的系统。

上述视觉 SLAM 大多是以配置文件的形式来加载参数，参数阈值是固定的，当切换到新的场景时，位姿估计精度和鲁棒性等易受固定参数阈值的影响。基于此，近几年来部分研究者将深度强化学习方法应用在参数自适应上，试图通过端到端的方式来解决复杂的参数控制问题。如 Huang 等[8]提出一种特征跟踪自适应的方法，用强化学习的思想选择可以判断跟踪结果的特征层。Bhowmik 等[9]提出一种新的训练方法，该方法将特征检测器嵌入完整的视觉管道中，并以端到端的方式训练可学习的参数，使用强化学习的方法克服了关键点选择和描述符匹配的离散性。Wang 等[10]提出一种基于深度强化学习的移动机器人路径规划方法，该方法采用双深度 Q 网络[11]（double deep Q-network，DDQN）算法对机器人的状态和相应动作进行回归预测以求得最优策略和最优路径。

本文受深度强化学习自适应特征提取和决策能力的启发，针对 ORB_SLAM3 算法中参数调整问题，引入深度强化学习中的深度循环 Q 网络[12]（deep recurrent Q-network，DRQN），提出了一种基于 DRQN 的视觉 SLAM 参数自适应调整方法。该方法有望解决视觉 SLAM 中复杂的参数调整问题。

2 计算地标点的不确定性

在计算机视觉领域，常见的 SLAM 不确定度描述方法有两种：第一种是基于熵的方法[13]，在 SLAM 问题中，常常把位姿和路标看成服从某种概率分布的随机变量，通常用熵来表示随机变量的不确定性。第二种是基于协方差矩阵的方法[14]，SLAM 中通过建立地标点的空间不确定性模型来提高传感器轨迹估计的精确度，并证明了以协方差矩阵的形式传播不确定性可以减少位姿估计的不确定性。

受第二种方法的启发，本文将双目立体视觉三维重建原理应用在单目上，采用协方差矩阵的方式来表征地标点的不确定性，并参考文献［14］求出协方差矩阵 Λ_W 如式（1）所示

$$\Lambda_W = J\Lambda_p J^T = \frac{\partial f(p)}{\partial p}\Lambda_p\left[\frac{\partial f(p)}{\partial p}\right]^T \tag{1}$$

其中，p，W 分别为像点坐标的和地标点三维坐标，用 Λ_p 和 Λ_W 来分别代表其协方差矩阵。W 与 p，透视投影矩阵[15]构成函数 $f(p)$，J 和 J^T 为雅克比矩阵 $\frac{\partial f(p)}{\partial p}$ 及其转置 $\left[\frac{\partial f(p)}{\partial p}\right]^T$。

3 基于 DRQN 的视觉 SLAM 参数自适应调整

DRQN 结合了长短期记忆网络（long short-term memory，LSTM）来循环记忆信息，在不完整且带噪的观测信息情况下能获得较好的实验效果。

受深度强化学习感知决策能力及 LSTM 记忆信息能力的启发，针对传统视觉 SLAM 手动调参及视频帧序列带噪问题，采用改进的 DRQN 作为本文算法迭代学习的主要网络架构，以便更好处理由飞行器采集速度过快或光照变化过强导致的模糊视频帧序列。此外，为验证本文方法的有效性，采用了 ORB_SLAM3 算法作为深度强化学习下的环境。下面将从构建动作空间、奖励函数、算法整体结构及网络模型来讲解本文方法的具体实现过程。

3.1 动作空间

构建动作空间的设计思路为筛选出 ORB_SLAM3 算法中的参数，并赋予参数合适的取值范围，整个动作空间中的动作由各参数值间的组合构成。在本文中，选取的参数有：金字塔尺度因子 P_1、金字塔层数 P_2 和最近邻阈值 P_3，通过对算法及前期参数实验分析，给 3 个参数赋予取值范围 $P_1 \in \{1.10,\cdots,1.40\}$、$P_2 \in \{2,\cdots,8\}$、$P_3 \in \{0.60,\cdots,0.90\}$，且动作空间的总容量 m 为 3 个参数各取值空间大小的乘积，动作空间可表示为 A

$$A = (a_1, a_2, \cdots, a_m)$$

其中，一个 a_i 为一个动作，每个动作包含 P_1、P_2、P_3 这 3 个参数，记为 $a_i = (P_1, P_2, P_3)$，$i = 1,2,\cdots,m$。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

3.2　奖励函数

在基于扩展卡尔曼滤波的视觉 SLAM 中，引入系统协方差 $P(x \mid x)$ 作为当前状态下系统的不确定性[16]，不确定度可量化为系统协方差矩阵主对角线上前 3 个值的和，如式（2）所示

$$P(x \mid x) = P(x \mid x)_{11} + P(x \mid x)_{22} + P(x \mid x)_{33} \quad (2)$$

同理，在 ORB_SLAM3 算法中，根据第 2 章节计算地标点协方差矩阵的方式来求得 ORB_SLAM3 算法中每个地标点的 $\wedge_W$，令 $P(k \mid k) = \wedge_W$，n 为地标点数，$k = 1, 2, \cdots, n$，采用式（2）来量化地标点在当前状态下的不确定度，最后采用每帧图像地标点的平均不确定度值表示该帧的不确定度，并将平均不确定度值归一化到（0，1）取值空间。

本文将每帧图像地标点的平均不确定度值作为每次算法运行下环境返回给智能体的信号（记为 g），设环境的奖励值为 r，由于算法的目的是使不确定值越来越小，故奖励函数设为 $r = 1 - g$。

3.3　本文算法结构

本文算法结构主要由 DRQN 和 ORB_SLAM3 算法构成，如图 1 所示，ORB_SLAM3 初始化成功后，通过计算初始化后第一帧图像的不确定度 g_t 得到奖励值 r，并将其传入 DRQN，DRQN 读取该奖励值对应的视频帧，将该帧图像处理后构成状态向量 s_t 作为 DRQN 算法评估网络的输入，评估网络得到该状态下每组参数（即每个动作）的 $Q(s_t, a)$ 值，算法根据 ε-greedy 策略来输出动作作为下一次运行的调整参数。

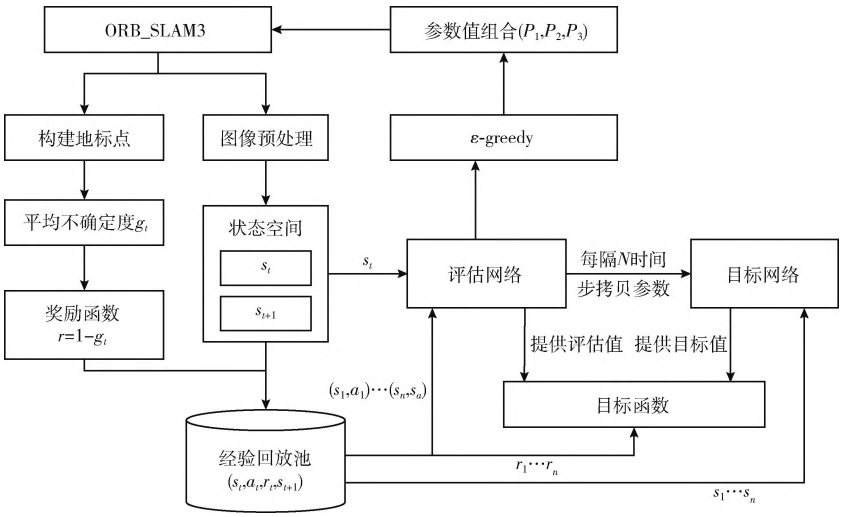

图 1　DRQN 参数自适应调整算法框架

强化学习的目标是尽可能获得更大的奖励，而在 DRQN 参数自适应调整算法中即为找到每帧图像的最佳参数组合使其位姿跟踪不确定度越来越小。在 t 时刻，ORB_SLAM3 执行动作 a_t 之后产生的经验为 (s_t, a_t, r_t, s_{t+1})，s_t 代表当前 t 时刻的状态，a_t 代表 t 时刻执行的动作，r_t 代表执行动作 a_t 获得的即时奖励，s_{t+1} 表示在 t 时刻执行动作 a_t 之后的状态，每循环一次将经验保存到经验回放池，当算法需要进行学习训练时，从经验回放池中随机选择一个序列并从序列中的随机点开始反向选取 n 个时间步长进行学习（n 可以为 1），本文 n 取值为 9，在每一次更新前需要将 LSTM 隐含层的状态置为 0。随机选取序列和时间步破坏了样本间的连续性，使得训练更加有效，同时经验池的经验序列达到容量上限以后，新的经验序列将覆盖已有的经验序列。

DRQN 采用了两个结构相同，参数不同的神经网络达到更新网络参数的目的，即评估网络和目标网络。评估网络为训练网络，每隔 N 时间步训练之后，将评估网络的参数拷贝给目标网络。整个网络的目标函数（即损失函数）如式（3）所示，y 为目标网络计算出来的 $Q_{target}(s_{t+1}, a_{t+1})$ 目标值，如式（4）所示，$Q_{eval}(s_t, a_t; \theta)$ 为评估网络得到的预测值，即为需优化的值，θ 为网络模型参数。损失函数定义为预测值和目标值的均方差，同时采用均方根反向传播（root mean square prop，RMSProp）算法对损失进行优化

$$loss(\theta) = E[(y - Q_{eval}(s_t, a_t; \theta))^2] \quad (3)$$

$$y = r + \gamma \max_{a_{t+1}} Q(s_{t+1}, a_{t+1}; \theta^-) \quad (4)$$

其中，r 为奖励值，γ 为折扣因子，$\gamma \in [0, 1]$。接下来对 θ 求偏导

$$\nabla l_\theta = [(r + \gamma \max_{a_{t+1}} Q(s_{t+1}, a_{t+1}; \theta^-)) - Q(s_t, a_t; \theta) \cdot \nabla_\theta Q(s_t, a_t; \theta)] \quad (5)$$

3.4　DRQN 模型结构

DRQN 模型除了继承深度强化学习从感知到决策的优点以外，它在缺失状态信息的情况下，具有很强的适应性和鲁棒性。尽管在每个时间步中仅看到单个帧，但该模型仍能跨帧集成信息以检测完整的状态，故选择该 DRQN 模

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

型作为本文算法的模型结构。

DRQN 网络结构主要由 3 个卷积层，1 个 LSTM 层及 1 个全连接层组成，且评估网络和目标网络结构相同如图 2 所示，首先将图像等比例采样到大小为 84×84 的图像且进行灰度化处理，然后将预处理后的图像输入到 DRQN 中卷积 3 次；接着将卷积层的输出送到 LSTM 层中进行处理；最后，全连接层为每个可能的动作输出 Q 值。

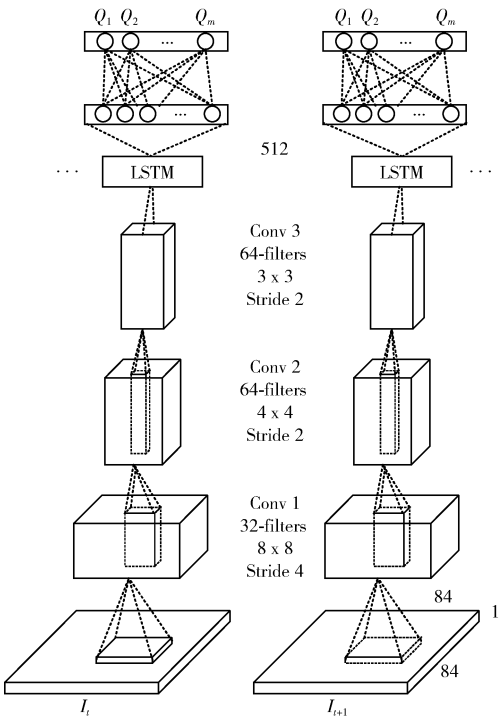

图 2 DRQN 模型结构

（1）卷积层

将处理后的单张 84×84 大小的图片 I 送入 3 个卷积层中，3 个卷积层均并采用 Relu 激活函数进行激活，从表 1 和图 2 可知，第一个卷积层在输入图像上用 32 个 8×8 滤波器进行卷积（步幅为 4）；第二个卷积层使用 64 个 4×4 滤波器进行卷积（步幅为 2）；第三个卷积层使用 64 个 3×3 滤波器进行卷积（步幅为 1）；卷积输出被传送到全连接的 LSTM 层。

表 1 网络模型参数细节

网络层	输入	卷积核大小	Stride	卷积核数量	输出
Conv 1	84×84×1	8×8	4	32	20×20×32
Conv 2	20×20×32	4×4	2	64	9×9×64
Conv 3	9×9×64	3×3	1	64	7×7×64
LSTM	7×7×64	—	—	512	512
Fc	512	—	—	10 500	10 500

（2）LSTM 层

LSTM 是一种改进的 RNN，相比一般网络，它能够更好处理序列数据及解决训练过程中的梯度爆炸和梯度消失问题。于 DRQN 而言，将 LSTM 和卷积层结合能将视频帧序列在时间和空间特征上进行更完整的学习，其内部结构如图 3 所示。

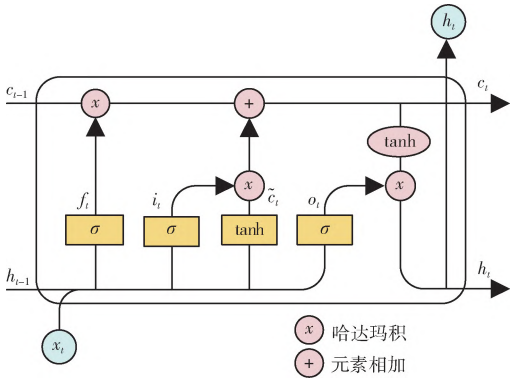

图 3 LSTM 内部结构

在输入 LSTM 前需将 7×7×64 的特征图进行降维处理再输入到该层。其内部结构如式（6）所示

$$
\begin{aligned}
i_t &= \sigma(W_i x_t + U_i h_{t-1} + b_i) \\
f_t &= \sigma(W_f x_t + U_f h_{t-1} + b_f) \\
o_t &= \sigma(W_o x_t + U_o h_{t-1} + b_o) \\
\tilde{c}_t &= \tanh(W_c x_t + U_c h_{t-1} + b_c) \\
c_t &= f_t * c_{t-1} + i_t * \tilde{c}_t \\
h_t &= o_t * \tanh(c_t)
\end{aligned} \tag{6}
$$

其中，σ 为 sigmoid 激活函数，W、U 和 b 分别为权重值和偏置值向量，$*$ 代表操作矩阵中对应的元素相乘，x_t 为输入向量，h_t 为输出向量，h_{t-1} 表示历史隐藏状态，$\tilde{c}_t$ 和 c_t 为候选值及新的记忆单元，f_t 遗忘门，i_t 表示输入门，o_t 为输出门。

（3）全连接层

全连接层主要用来线性输出每个动作的 Q 值，在本算法中，所有动作为 3.1 节中的动作空间 A，动作总数为 $m=10\ 500$，一个动作即为选取的 3 个参数的组合。

4 实验结果与分析

实验所用的环境配置为英特尔酷睿 i5-6400，最高睿频 3.3 GHz，4 核 4 线程处理器，16 G 内存，操作系统为 ubuntu16.04，Tensorflow1.12 版，Python3.6 版。

4.1 ORB_SLAM3 算法参数分析实验

视觉 SLAM 参数自适应调整方法有 3 个关键参数：金字塔尺度因子 P_1、金字塔层数 P_2 和最近邻阈值 P_3，在 ORB_SLAM3 算法中设置为固定的经验值，分别为 1.2/8/0.9。金字塔层数主要用于解决 SLAM 中尺度不变形问题，决定了提取关键点的数量，尺度因子决定了金字塔层间的缩放比

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

例，最近邻阈值指最佳匹配和次佳匹配的特征点评分比值阈值，用于筛选匹配点，通常值越小匹配就越苛刻。

为对比不同参数对全局位姿轨迹精度的影响，表 2 为 6 组不同参数组合下 ORB_SLAM3 算法在 EuRoC 部分序列集下的绝对轨迹误差中均方根误差（root mean square error，RMSE）结果。由表 2 前三行数据可知，在同一序列集下，固定参数 P_2，P_3，参数 P_1 对算法精度的影响是不稳定的，后三行数据为固定参数 P_1，P_3 观察 P_2 对算法精度的影响，从实验数据也可以得出类似的结论，因此，对于不同序列集而言，算法中采用同一组固定参数不一定是最优的。

表 2　EuRoC 序列集在不同参数组合下的绝对位姿误差，RMSE/m

参数($P_1-P_2-P_3$)	MH01	MH02	MH03	MH04
1.1-8-0.9	**0.010**	0.024	**0.026**	0.143
1.3-8-0.9	0.031	0.087	0.059	0.058
1.4-8-0.9	0.027	0.024	0.042	0.072
1.2-4-0.9	0.018	0.063	0.086	0.146
1.2-6-0.9	**0.010**	0.069	0.057	**0.055**
1.2-8-0.9	0.015	**0.019**	0.043	0.084

为观察 P_1 和 P_3 两个参数对每帧图像位姿跟踪精度的影响，算法训练过程中随机提取连续的 200 帧图像来观测地标点平均不确定度 g 变化情况，如图 4 所示，从散点的分布情况可知，当每帧图像根据自身状态选取合适的参数组合时可以减小该帧的位姿跟踪不确定度。

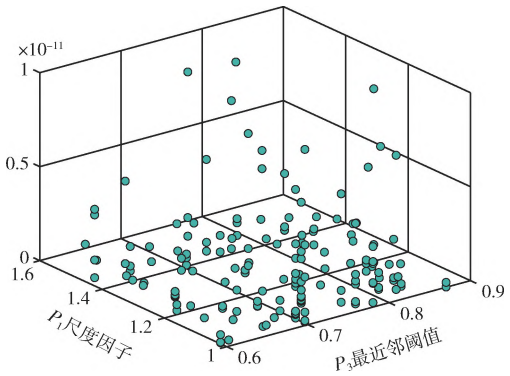

图 4　地标点平均不确定度 g 的散点

4.2　定位结果与分析

4.2.1　EuRoC 数据集

EuRoC 数据集[17]包含 Machine Hall（MH）、Vicon Room1（VR1）和 Vicon Room2（VR2）等 11 个序列集。训练数据采用等级为 difficult VR103。测试数据选用 EuRoC 数据集中除了训练序列集以外的其它序列集。

为测试本文算法的有效性，将实验结果与 DSM[18]、ORB_SLAM3 和 DSO[19]算法作定位精度对比。DSM 是一种基于光度束调整（photometric bundle adjustment，PBA）的单目视觉 SLAM，ORB_LAM3 算法为西班牙萨拉戈萨大学提出的基于特征点法的视觉 SLAM，DSO 为典型的基于直接法的 SLAM。表 3 为采用 EuRoC 除训练序列集之外的其它序列集测试得到的绝对轨迹误差的 RMSE 结果，为保持与文献［7］一致的评估准则，该数据集的实验结果取为反复测试 10 次后的中位数。

表 3　EuRoC 数据集的绝对轨迹误差，RMSE/m

序列	Ours	DSM	ORB_SLAM3	DSO
MH01	**0.012**	0.039	0.017	0.046
MH02	**0.011**	0.036	0.017	0.046
MH03	**0.023**	0.055	0.031	0.172
MH04	0.069	0.057	**0.066**	3.810
MH05	**0.044**	0.067	**0.044**	0.110
VR101	**0.025**	0.095	0.033	0.089
VR102	**0.012**	0.059	0.016	0.107
VR201	**0.021**	0.056	**0.021**	0.044
VR202	**0.020**	0.057	0.022	0.132
VR203	—	**0.0784**	—	1.152

从实验结果来看，本文算法相比于其它 3 种算法在大部分序列集上位姿跟踪精度有了一定的提升，而在个别序列集上效果却一般（如 MH04），此外，我们可以发现次佳结果由 DSM 获得，可能原因是该算法也采用 ORB_SLAM3 的中期匹配方法。DSO 是一种基于直接法的 SLAM，与其它方法相比，该算法是基于灰度不变假设下成立的，容易受光照影响，故位姿跟踪效果不明显。图 5（a）、图 5（c）为在 EuRoC 的序列集 MH01 和 MH03 下，本文算法、ORB_SLAM3 和真实轨迹（ground_truth）在 xy 轴上的位姿轨迹对比图，图 5（b）、图 5（d）分别为图 5（a）、图 5（c）对应的轨迹平移细节，从轨迹对比图和表 3 的数据来看，本文算法估计的轨迹相对于 ORB_SLAM3 算法而言离真实轨迹更近，偏差更小。

4.2.2　TUM-VI 数据集

TUM-VI 数据集[20]包含 6 种不同场景的 28 序列组成，本文使用该数据集中的 Room 和 Corridor 序列集进行实验。该部分实验的训练数据采用 Room6，测试数据选用除训练序列集之外的其它序列集。

表 4 为在 TUM-VI 数据集的部分序列集下本文方法与 ORB_SLAM3、VINS-Mono[21]和 ROVIO[22]算法的绝对位姿误差的 RMSE 对比结果，实验结果为反复测试 10 次后的中位数，其中 VINS-Mono 为基于紧耦合的单目视觉惯性定位算法，ROVIO 是基于迭代卡尔曼滤波的鲁棒视觉惯性里程计，这两种算法的实验数据由文献［20］给出。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

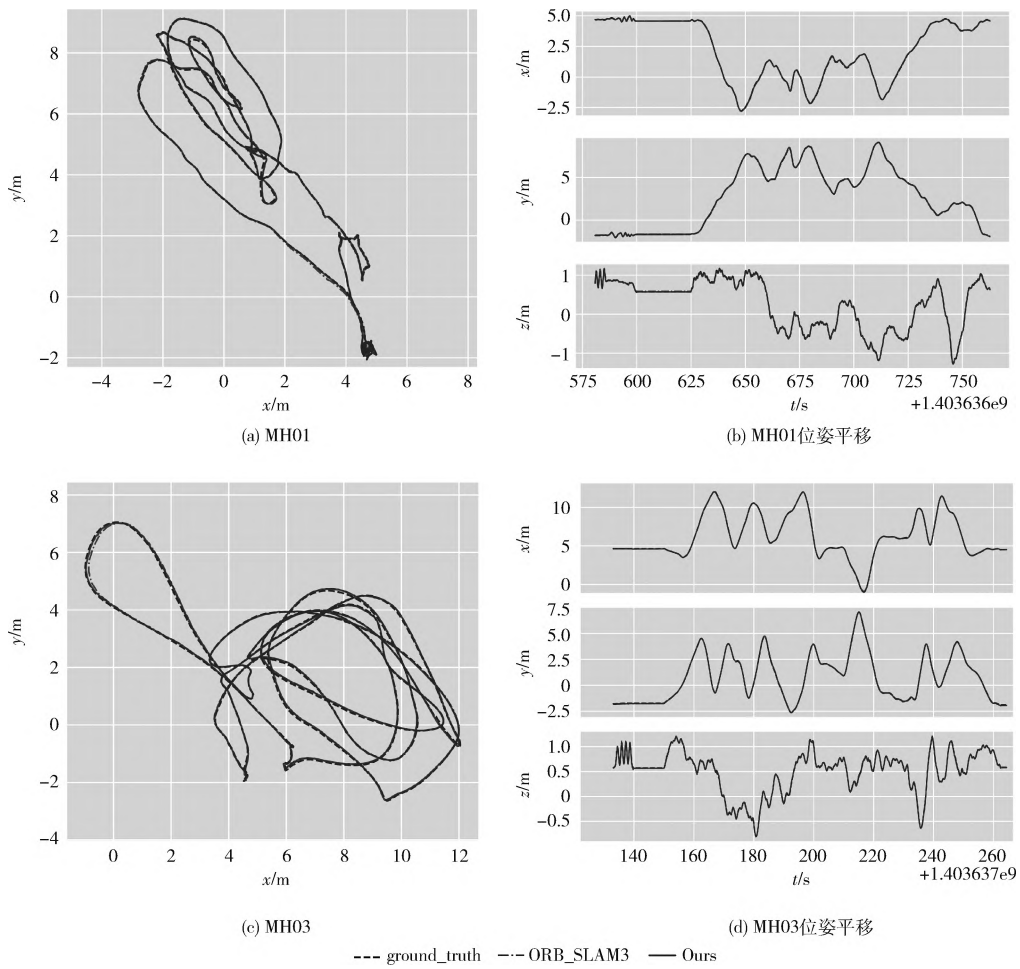

图 5 EuRoC 部分序列集的位姿轨迹对比

表 4 TUM-VI 数据集的绝对轨迹误差，RMSE/m

序列	Ours	ROVIO	ORB_SLAM3	VINS-Mono	长度/m
Corridor1	**0.01**	0.47	0.04	0.63	305
Corridor2	**0.02**	0.75	**0.02**	0.95	322
Corridor3	**0.23**	0.85	0.31	1.56	300
Corridor4	0.14	**0.13**	0.17	0.25	114
Corridor5	**0.02**	2.09	**0.03**	0.17	270
Room1	**0.01**	0.16	**0.01**	0.07	146
Room2	**0.01**	0.33	0.02	0.07	142
Room3	**0.02**	0.15	0.04	0.11	135
Room4	**0.01**	0.09	**0.01**	0.04	68
Room5	**0.01**	0.12	0.02	0.20	131

从实验结果可知，本文算法在 Room 和 Corridor 两个序列集上都略优于其它算法，ROVIO 算法计算量小且具有鲁棒的定位，但该算法没有闭环检测模块，在定位时存在误差累积，故在大部分序列集上表现不佳。图 6（a）、图 6（c）为在 TUM-VI 的序列集 Corridor1 和 Room1 下，本文算法、ORB_SLAM3 和真实轨迹（ground_truth）在 xy 轴上的位姿轨迹对比图，图 6（b）、图 6（d）分别为图 6（a）、图 6（c）对应的绝对位姿误差，从位姿轨迹和绝对位姿误差的

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

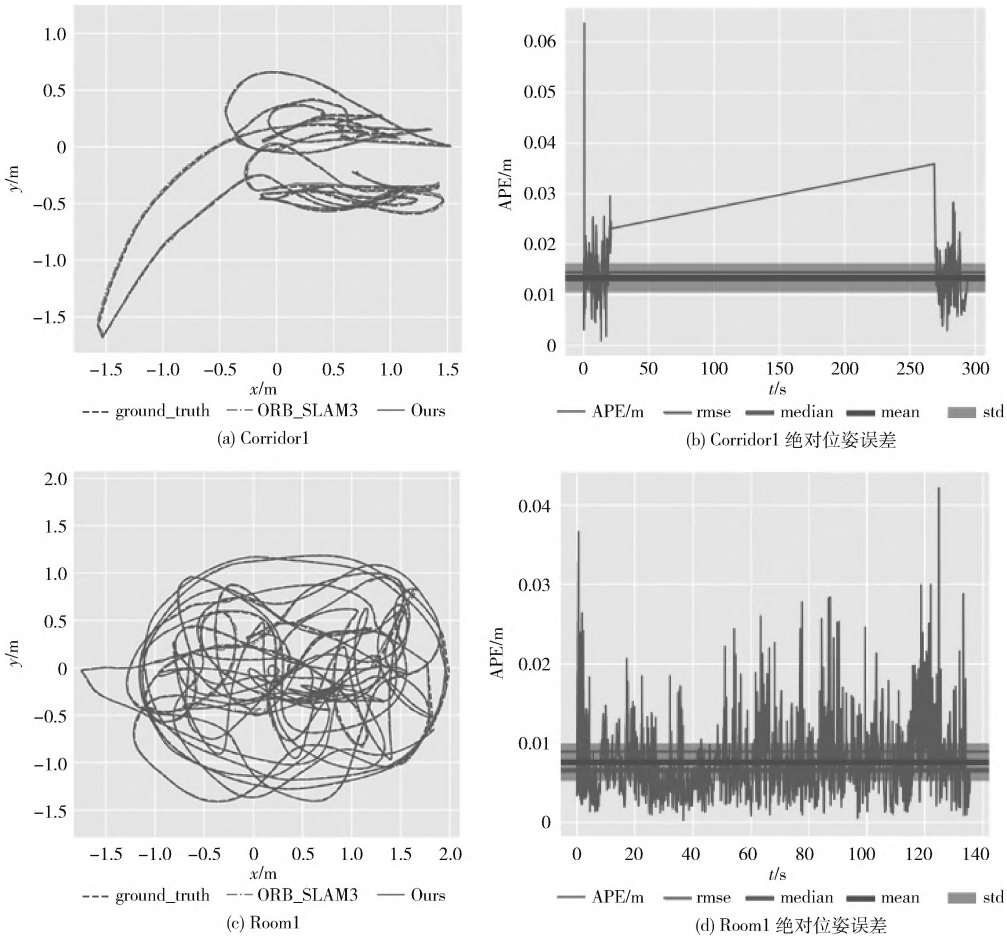

图 6　TUM-VI 部分序列集的位姿轨迹及绝对位姿误差对比

RMSE 值来看，由本文算法得到的位姿轨迹精度相比 ORB_SLAM3 也是有一定提升的。

4.3　运行时间对比

在同等运行环境配置下，通过记录算法在 EuRoC 和 TUM-VI 部分序列集上的运行时间来比较 ORB_SLAM3 和本文算法的运行速度，取值为连续 3 次运行时间的平均值。如表 5 所示，由于本文算法在运行过程中需动态加载参数和计算地标点的平均不确定度值，故相对于 ORB_SLAM3 算法而言总体耗时稍微有所增加，但对于部分序列集来说平均运行时间几乎是一致的。

5　结束语

针对视觉 SLAM 算法复杂的参数调整问题，本文提出了一种基于 DRQN 的视觉 SLAM 参数自适应调整方法。该方法将 ORB_SLAM3 作为环境，并以地标点的不确定性构建奖励函数，以求在不断迭代学习过程中获得最大回报奖励，从而提高 ORBLAM3 的位姿跟踪精度和泛化能力。实验结果表明，该方法相比传统人工设定经验值的方法有明显优势，虽然测试时间相比原来算法略有增加，但从跟踪精度和泛化性上来看有一定的提升，且避免了传统视觉 SLAM 算法的复杂参数调整过程，故可以作为视觉 SLAM 领域参数自适应调整的一种有效方法。

表 5　EuRoC 和 TUM-VI 部分序列集的运行时间对比/s

序列	Ours	ORB_SLAM3
MH01	214	206
MH03	159	157
MH05	129	125
VR101	166	164
VR103	115	116
VR201	126	124
Room1	168	165
Room4	137	131
Corridor1	359	342
Corridor4	123	110

目前本文的方法主要应用在单目上，且采用机房、办

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

公室等室内数据集，后期将针对不确定模型及奖励函数的设计进行优化，并将传感器扩展到双目、RGB-D，且针对室外环境对 ORB_SLAM3 和 DRQN 算法进行改进。

参考文献：

[1] Khalufa A，Riley G，Luján M. A dynamic adaptation strategy for energy-efficient keyframe-based visual SLAM [C] //Proc of the International Conference on Parallel and Distributed Processing Techniques and Applications. Greece：PDPTA Press，2019：3-10.

[2] Kuo J，Muglikar M，Zhang Z. Redesigning SLAM for arbitrary multi-camera systems [C] //IEEE International Conference on Robotics and Automation. Paris：IEEE Press，2020：2116-2122.

[3] Chao M，Guo B，Xin L. Simultaneous localization and mapping using monocular direct method [C] //International Conference on Control. Phuket：IEEE Press，2017：1-5.

[4] TANG Dingxin，YUAN Liang，RAN Teng. Semantic SLAM of indoor dynamic scene [J]. Computer Engineering and Design，2020，41 (12)：3538-3543 (in Chinese). [唐鼎新，袁亮，冉腾. 室内动态场景下的语义 SLAM [J]. 计算机工程与设计，2020，41 (12)：3538-3543.]

[5] Mur-Artal R，Montiel J，Tardos JD. ORB-SLAM：A versatile and accurate monocular SLAM system [J]. IEEE Transactions on Robotics，2015，31 (5)：1147-1163.

[6] Mur-Artal R，Tardos JD. ORB-SLAM2：An open-source SLAM system for monocular，stereo and RGB-D cameras [J]. IEEE Transactions on Robotics，2017，33 (5)：1255-1262.

[7] Campos C，Elvira R，Rodríguez J，et al. ORB-SLAM3：An accurate open-source library for visual，visual-inertial and multi-map SLAM [J]. arXiv preprint arXiv：2007.11898，2020.

[8] Huang C，Lucey S，Ramanan D. Learning policies for adaptive tracking with deep feature cascades [C] //Proc of the IEEE International Conference on Computer Vision. Venice：IEEE Press，2017：105-114.

[9] Bhowmik A，Gumhold S，Rother C，et al. Reinforced feature points：Optimizing feature detection and description for a high-level task [C] //IEEE/CVF Conference on Computer Vision and Pattern Recognition. Seattle：IEEE Press，2020：4948-4957.

[10] Wang Yang，Fang Yilin，Lou Ping，et al. Deep reinforcement learning based path planning for mobile robot in unknown environment [C] //Journal of Physics：Conference Series. IOP Press，2020：12009.

[11] Van HH，Guez A，Silver D. Deep reinforcement learning with double q-learning [C] //Proc of the AAAI Conference on Artificial Intelligence. Phoenix：AAAI Press，2016：2094-2100.

[12] Oh Hyunwoo，Kaneko T. Deep recurrent Q-network with truncated history [C] //Conference on Technologies and Applications of Artificial Intelligence. Taichung：IEEE Press，2018：34-39.

[13] Rodríguez-Arévalo ML，Neira J，Castellanos JA. On the importance of uncertainty representation in active SLAM [J]. IEEE Transactions on Robotics，2018，34 (3)：829-834.

[14] Belter D，Nowicki M，Skrzypczyński P. Modeling spatial uncertainty of point features in feature-based RGB-D SLAM [J]. Machine Vision and Applications，2018，29 (5)：827-844.

[15] GAO Xiang，ZHANG Tao. Fourteen lectures on visual SLAM：From theory to practice [M]. Beijing：Publishing House of Electronics Industry，2017：84-90 (in Chinese). [高翔，张涛. 视觉 SLAM 十四讲：从理论到实践 [M]. 北京：电子工业出版社，2017：84-90.]

[16] Mazlan MM，Othman NA，Ahmad H. Diagonalization of covariance matrix in simultaneous localization and mapping of mobile robot [C] //Proc of the 10th National Technical Seminar on Underwater System Technology. Singapore：Springer Press，2019：285-297.

[17] Burri M，Nikolic J，Gohl P，et al. The EuRoC micro aerial vehicle datasets [J]. International Journal of Robotics Research，2016，35 (10)：1157-1163.

[18] Zubizarreta J，Aguinaga I，Montiel JMM. Direct sparse mapping [J]. IEEE Transactions on Robotics，2020，36 (4)：1363-1370.

[19] Engel J，Koltun V，Cremers D. Direct sparse odometry [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence，2017，40 (3)：611-625.

[20] Schubert D，Goll T，Demmel N，et al. The TUM VI benchmark for evaluating visual-inertial odometry [C] //IEEE/RSJ International Conference on Intelligent Robots and Systems. Madrid：IEEE Press，2018：1680-1687.

[21] Qin Tong，Li Peiliang，Shen Shaojie. Vins-mono：A robust and versatile monocular visual-inertial state estimator [J]. IEEE Transactions on Robotics，2018，34 (4)：1004-1020.

[22] Bloesch M，Burri M，Omari S，et al. Iterated extended Kalman filter based visual-inertial odometry using direct photometric feedback [J]. The International Journal of Robotics Research，2017，36 (10)：1053-1072.

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net