分 类 号：TP391.41;TP183　　密级：公开
论文编号：

贵　州　大　学
2022 届硕士研究生学位论文

基于图像的深度逆向光照估计研究

学科专业：计算机科学与技术
研究方向：计算机应用技术
导　　师：黄初华 副教授
研 究 生 ：黄仁婧

中国 ▪ 贵州 ▪ 贵阳

2022 年 6 月

中国知网 https://www.cnki.net

硕士学位论文答辩委员会名单

基于图像的深度逆向光照估计研究

答辩人：黄仁婧

答辩委员会委员：

贵州大学教授:_____李辉_____（主席）

贵州大学教授:_____黄瑞章_____

贵州大学教授:_____王琦_____

贵州大学副教授:_____苟刚_____

中南大学教授:_____吴嘉_____

答辩秘书：薛现斌讲师

答辩时间：2021 年 5 月 30 日

答辩地点：博学楼 525

中国知网 https://www.cnki.net

摘 要

增强现实技术将计算机生成的虚拟信息加入到真实环境中，这需要满足光照一致性、几何一致性和时间一致性，以提高虚拟信息和真实世界融合的视觉一致性。增强现实技术的光照一致性需要估计整个真实场景的光照分布，从而准确渲染虚拟物体插入到真实场景中。本文针对增强现实中的光照一致性问题，做了如下工作：

1. 首先针对在各种条件拍摄的彩色图像难以满足光照估计任务需求，提出了融合多分支残差与仿射变换的低照度图像增强方法。该方法借鉴最新深度学习多分支残差网络的成功，设计了光照估计模块、光照仿射变换模块、细节重建模块来分别处理低照度图像存在的低光、噪声和细节问题。为下一步实现增强现实中的光照一致性提供前提条件。

2. 其次设计了材质和形状估计网络与球形高斯光照建模网络。图像的形成是物体形状、材质、光照和相机等信息复杂交互的结果，则获取光照信息就需要逆转图像形成的过程。先利用材质和形状估计网络从单图像中获得场景的反照率、法线和粗糙度图。再将原图像、增强后图像与材质和形状估计网络的输出结合，通过球形高斯光照建模网络估计出空间变化的照明信息，解决虚拟物体重光照问题的同时也为虚拟物体向真实场景提供绘制阴影的条件。

本文将深度学习技术应用到增强现实系统中来解决光照一致性问题，提出了基于图像的逆向光照估计方法。该方法不需要场景的任何三维形状信息先验知识，也不需要限定场景中物体的材质和纹理，适用于任何漫反射或者镜面反射的场景，除了场景单图像外不需要任何额外的输入。而且将获得的光照信息应用到增强现实系统中，可以较好地提高虚拟信息与真实世界融合的视觉一致性。因此本文提出的基于图像的深度逆向光照估计方法有一定的理论意义和实用价值。

关键词：深度学习；光照估计；低照度图像增强；微表面模型；球形高斯光照

中国知网 https://www.cnki.net

ABSTRACT

Augmented Reality technology adds computer-generated virtual information to the real environment, it needs to satisfy illumination consistency, geometric consistency and temporal consistency, thereby improving the vision consistency of virtual information and real scene fusion. The illumination consistency requires estimating the illumination distribution of the entire real scene, aiming to accurately render virtual objects inserted into the real scene. In order to solve the illumination consistency problem in Augmented Reality, the following work has been done:

1. addressing the problem that images do not meet the need of illumination estimation task firstly, thence proposing a low-light image enhancement method that combines multi-branch residuals and affine transformation. The method draws on the success of the latest deep learning multi-branch residual network, and designs an illumination estimation module, an illumination affine transformation module, and a detail reconstruction module to deal with low-light, noise and detail problems in low-light images respectively. It provides prerequisites for the next step to achieve illumination consistency in Augmented Reality.

2. Hereafter, designing material and shape estimation network (MSNet) and spherical Gaussian illumination modeling network (SGNet). The formation of image is the result of complex interaction of information such as object shape, material, illumination and camera, obtaining illumination information requires reversing the process of image formation. Firstly, the albedo, normal and roughness maps are obtained from a single image using the MSNet. Then the SGNet accepts the output of the MSNet as input, along with the original image and the enhanced image, it outputs the spatially varying illumination information, which solves the problem of relight of virtual objects and provides conditions for virtual objects to draw shadows to the real scene.

By applying deep learning to solve the illumination consistency problem in Augmented Reality, proposing image-based inverse illumination estimation method. It neither requires any a priori knowledge of the 3D shape information, nor defines the materials and textures of the objects in the scene, it is applicable to any diffuse or specular reflective scene, without any additional input other than the single image of the scene. What's more, applying the obtained illumination information to the augmented reality system, it can well improve the visual consistency of virtual and real fusion. Therefore, the image-based inverse illumination estimation method has theoretical and practical.

Key words: Deep learning, illumination estimation, low-light image enhancement, microfacet BRDF Model, spherical Gaussians illumination

中国知网 https://www.cnki.net

目录

摘 要 I
ABSTRACT II
第一章 绪论 1
1.1 研究的背景及意义 1
1.1.1 研究背景 1
1.1.2 研究意义 2
1.2 国内外研究现状与发展趋势 3
1.2.1 光照估计的研究现状与发展趋势 3
1.2.2 目前存在的问题 8
1.3 研究内容及章节安排 9
1.3.1 研究内容 9
1.3.2 章节安排 9
第二章 相关理论技术基础 11
2.1 低照度图像增强算法 11
2.1.1 直接调整对比度的低照度图像增强 11
2.1.2 基于 Retinex 理论的低照度增强方法 13
2.2 光照基本理论 13
2.2.1 光照概念 13
2.2.2 绘制方程 15
2.3 光照模型 15
2.3.1 环境光照模型 15
2.3.2 漫反射模型 16
2.3.3 高光反射光照模型 16
2.3.4 微表面模型 17
2.4 基于图像的光照表示方法 20
2.4.1 HDR 光照贴图 20
2.4.2 球形谐波函数 21
2.5 光照估计中用到的神经网络 21
2.5.1 U-net 22

中国知网 https://www.cnki.net

2.5.2 ResNet 23
2.5.3 RepVGG 23
2.6 本章小结 25
第三章 融合多分支残差与仿射变换的低照度图像增强方法 26
3.1 引言 26
3.2 网络模块与结构 26
3.2.1 光照估计模块 27
3.2.2 光照仿射变换模块 28
3.2.3 细节重建模块 29
3.3 损失函数 29
3.3.1 L1 损失 30
3.3.2 结构损失 30
3.3.3 人眼感知损失 31
3.3.4 区域损失 31
3.4 实验结果及分析 32
3.4.1 实验前提 32
3.4.2 主观评定 35
3.4.3 客观评定 37
3.4.4 消融实验 39
3.5 本章小结 39
第四章 基于图像的球形高斯光照估计 41
4.1 引言 41
4.2 图像材质和形状估计 44
4.2.1 网络模型 44
4.2.2 损失函数 46
4.3 球形高斯光照建模 46
4.3.1 网络模型 47
4.3.2 损失函数 49
4.4 实验与结果分析 50
4.4.1 实验前提 50

中国知网 https://www.cnki.net

4.4.2 主观评定 54
4.4.3 客观评定 56
4.4.4 增强现实应用 58
4.4.5 消融实验 61
4.5 本章小结 62
第五章 总结与展望 63
5.1 总结 63
5.2 展望 64
致谢 65
参考文献 66
附录 70
图版 71
表版 73

中国知网 https://www.cnki.net

第一章 绪论

1.1 研究的背景及意义

1.1.1 研究背景

虚拟现实（Virtual Reality，VR）是通过计算机技术创建的一种虚拟世界，这种虚拟世界可以是对真实环境的模拟，也可以是梦想的投射。走进创建的虚拟世界，不仅仅可以用眼睛去看，还可以与环境交互，让体验者拥有沉浸感、交互感与想象感。增强现实技术（Augmented Reality，AR）是随着 VR 技术的发展而出现的，因此，AR 与 VR 之间既存在联系又有区别，其中最显著的区别是 AR 没有让用户脱离真实环境，而是与周围的真实环境建立紧密的联系。VR 与 AR 的关系如图 1.1 所示。

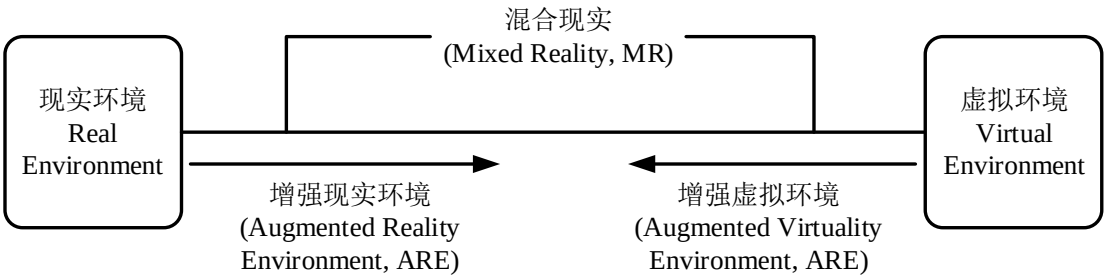

图 1.1 真实环境与虚拟环境的连续体图

AR 技术可以将虚拟信息添加到现实场景，让用户难以分辨是渲染插入的虚拟信息还是现实中本来存在的真实信息。AR 与 VR 技术一样，也可以实现用户与虚拟场景交互，使用户的体验感更好，增强用户对现实的认识与感受。最近，因为深度学习在各类计算机视觉任务中表现优异，研究者们也开始将深度学习被用到 AR 中，AR 借助物体识别技术、全流程化工作指导、智能信息交互与智能化计算机视觉考核等技术，通过对真实设备的指引化流程可构造以实战为目的的新型培训模式，此种新型培训技术最大的优点在于大幅提高了操作的规范水平，不仅安全方面得到很好的保证，而且能够重复使用，极大地节约了培训费用成本，同时对于培训效率的提升也有了很大改善。AR 的本质是计算机接口技术，除了可以用到培训方面，还有很广泛的应用领域，尤其是在疫情期间得到迅猛发展，目前已经将 AR 技术应用到商业、工业、医学、娱乐、教育培训、军事与航空航天以及文物展览等诸多领域，如图 1.2 所示。

中国知网 https://www.cnki.net

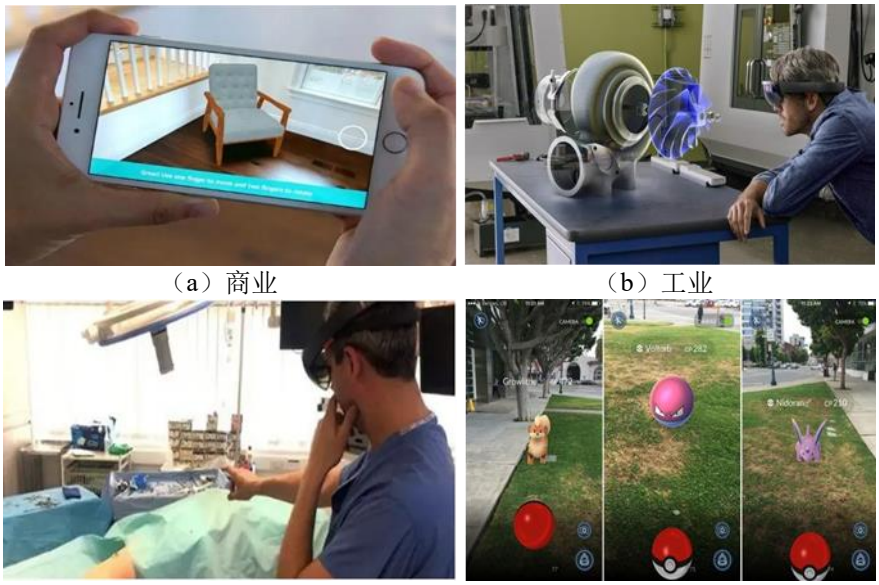

（a）商业　（b）工业

（c）医学　（d）娱乐

图 1.2 增强现实应用示意图

增强现实系统需要将虚拟信息和真实场景信息极其逼真地融合，并把融合后的结果有效地传送给用户的整个视觉系统。然而需要解决几何一致性、时间一致性和光照一致性三个关键问题，才能呈现逼真的增强现实效果。其中几何一致性是指虚拟物体被嵌入到真实环境之后，与真实环境中的其他物体间有合理的透视和遮挡关系[1]；时间一致性是指虚拟物体与真实环境中的其他物体运动相统一；光照一致性是指虚拟物体和场景中存在的真实物体一样具有合理的光照对应关系。增强现实技术在跟踪、注册以及交互方面的研究相对较多，而对于光照一致性的研究特别是同时满足室内外场景的光照一致性研究少之又少，导致增强现实系统中虚拟信息的真实感需要进一步提高，比如明暗、色彩与阴影等光照效果。如何提升虚拟信息与真实场景融合效果的真实感，将是直接影响用户的体验感和制约增强现实技术发展的必要技术。

1.1.2 研究意义

如何使虚拟信息的渲染更加接近真实信息，一直受光照复杂度的影响。在室外场景中，起主要作用的是太阳光，其他人造光的强度远远弱于太阳光的强度。在室内场景中，不仅受到太阳光的影响，还有室内场景中存在各种人造光以及人造物体的影响也比较大。室内与室外相比，空间非常狭小，各种各样的人造物体会对光产生反射和折射，不仅如此，室内环境中的各种灯光明亮程度可能不一致，使得光照情况变得更加复杂。先前的研究都是针对特定场景，很

中国知网 https://www.cnki.net

少有满足室内外场景的光照估计研究，因此从有限视野的室内外场景中准确估计出空间变化的光照信息对提升虚拟信息与真实场景融合的真实感意义重大。

1.2 国内外研究现状与发展趋势

1.2.1 光照估计的研究现状与发展趋势

光照估计是增强现实技术中光照一致性的关键技术，其主要用于在三维世界中获取该场景的照明分布，空间变化的光照估计技术有助于虚拟物体与现实世界的实时互动，增强用户视觉体验感。

在实时场景中获得照明分布最直接的方式是借助辅助标志物和辅助拍摄设备，然而这些方法需要复杂的拍摄过程或者附加设备。另外一种从场景中估计照明的方式是通过图像分析，该方法相对于前两种方法，不需要额外的辅助设备，大多数工作都是输入图像与附加信息相结合，缺陷就是需要提前获取这些附加信息。后来，随着深度学习的发展，通过大量的数据来训练模型，使该模型具有学习光照信息的能力，相比于前面的方法，基于深度学习的方法具有较高的实用性。接下来展开介绍这些光照估计技术的研究现状。

1. 基于辅助标志物的光照估计方法

常见的光照探测物包括：镜面球体、漫反射球体、镜面反射/漫反射混合球体、人眼、人脸和人手等等。1998 年，Debevec[2] 在要拍摄的场景中放置镜面小球，并拍摄多幅镜面小球图像捕获场景照明。该工作首次提出高动态范围全景图可以通过拍摄不同曝光下的镜面球体来获取，这一方法也为后期的高动态全景图合成提供了思路。2012 年，Debevec 等人[3]对先前的工作[2]做出了改进，他们指出，使用一个漫反射球体，或者漫反射与镜面反射表面混合的球体，也可以达到同样的效果。

除了上述已知物体的几何和表面材质、且预先放置在场景中的规则物体的光探测物外。还有一些特殊的“物体”也可以用作光探测物，例如人的眼球、人脸和人手等一些经常出现照片中的元素。因为人眼是对光起反应的多用途器官，而人脸、人手图像的外观会随着光照情况的变化发生巨大的变化，相当于人脸、人手能将光照变化情况放大。2003 年，Tsumra 等人[4]假设人眼是规则球体，并以此为前提，利用眼球表面反射的光线估计出场景的光照。2012 年，Nishino 等人 [5]则更细致地分析了眼球的大致结构，并利用包含眼球的图像估计出场景的

中国知网 https://www.cnki.net

光照分布。不过该方法需要分辨率和清晰度较高的图像，而且在文中也指出，该方法并没有考虑对光照估计结果产生较大影响的因素，例如：瞳孔颜色、虹膜颜色等。由于人脸在图片中出现频率较高，也经常通过一张包含人脸的照片估计出光照的球谐函数（Spherical Harmonics，SH）表示，进而对人脸实现重光照(relight)，SH 作为光照的近似表示，可以使用较少的参数来模拟环境光，但是低阶的 SH 只能表示低频的环境光。2007 年，Wang 等人[6]提出一种基于马尔科夫随机场的能量最小化框架，意图从脸部图像中恢复出人脸的形状、反照率和光照。2013 年，Yao 等人[7]通过人手的亮度和法线，估出光照的低频表示 SH 系数，在图 1.3 展示了上述论文中常见的光照探测物—球、人眼、手和人脸，该类方法适用于光源较强情况，在光源强度较弱时，难以提取标志物表面图像中的光源信息，而且该类方法要求使用的图像中必须包含相应的标志物，这也限制了一些场景的使用。

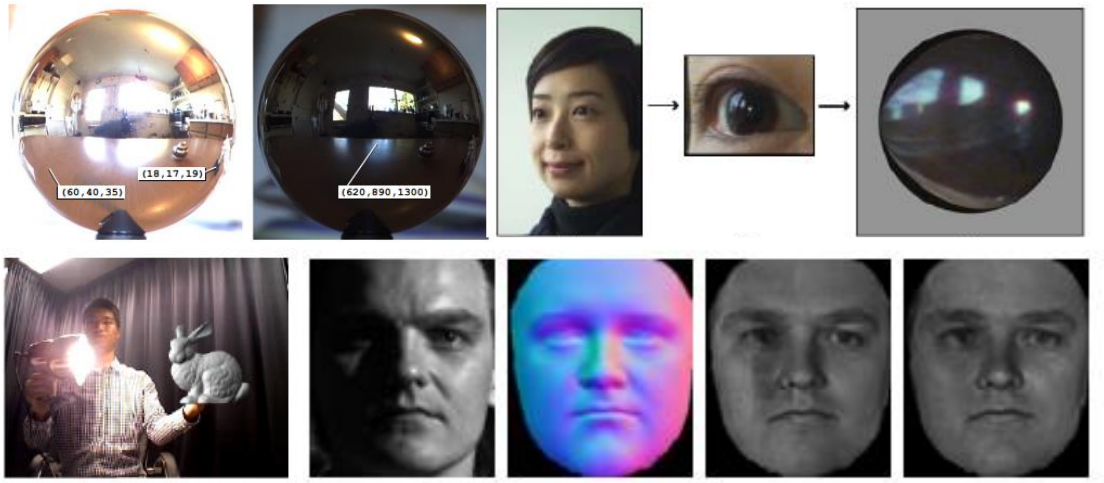

图 1.3 光照探测物

2. 基于辅助拍摄设备的光照估计方法

辅助拍摄设备通常有鱼眼、光场和深度相机，鱼眼相机可以提供全视角图像，光场相机可以提供光场信息，而深度相机能提供深度信息。2006 年，Pilet 等人[8]构建了一个三维估计系统，该系统由多个不同位置的相机和一个平面标定物组成。通过追踪该平面标定物并计算其中的高光和阴影，估计出场景的几何结构和光照信息。基于不同相机在同一时刻拍摄的平面标志物亮度只与法线和相机光圈有关的结论，建立光照模型并离线地计算高光、阴影等信息来在线恢复环境光照，实现了 AR 的光照一致性。2007 年，Madsen 等人[9] 设计一个 AR 渲染系统，其使用高动态范围环境图（High Dynamic Range，HDR）来表示

中国知网 https://www.cnki.net

真实场景照明，基于物理的方法来渲染虚拟对象投射的阴影，而不改变真实场景图像中已经存在的阴影，所提出的方法能实时估计真实场景的漫反射反照率，并在 GPU 加速渲染情况下有效地实现虚拟物体的重照亮和阴影投射。但是，HDR 环境贴图需要在指定位置提前使用 HDR 相机拍摄完成，对于现实生活中不断变化的光照信息并不适用。HDR 环境贴图除了可以使用上述方法拍摄之外，也可以使用鱼眼相机拍摄合成。2008 年，Yoo 等人[10]提出了一个由鱼眼镜头、中性衰减片(Neural Density Filter，ND）和普通相机构成的光照探测系统， 他们通过鱼眼镜头获取一个半球面，使用 ND 直接感知明亮区域，并通过阈值、中值分割处理后，提取多个点光源来实时模拟场景中的真实光源。也是在 2008 年，Cossairt 等人[11] 构建了一个由光场捕获、投影单元、视图摄像机和直接照明组成的光场传输系统。首先通过光场捕获得到光场信息，再通过投影单元将其投影到真实场景上，实现光场传输和限制物体位置的全局照明，但该系统只能在单光源较暗场景中使用。2011 年，Imai 等人[12]基于高维光谱成像系统的图像数据，比较了三种高光区域的检测方法，提出了一种包括自然光源和人工光源在内的光谱功率分布光照估计方法，并且通过实验指出利用亮度变化阈值进行高光检测的方法最适合用普通成像系统检测高光区域。但只适用于表面存在显著高光的物体。图 1.4 展示了上述一些方法光照估计系统使用的情景，从图中可以看出该类光照估计方法使用的设备往往比较复杂。

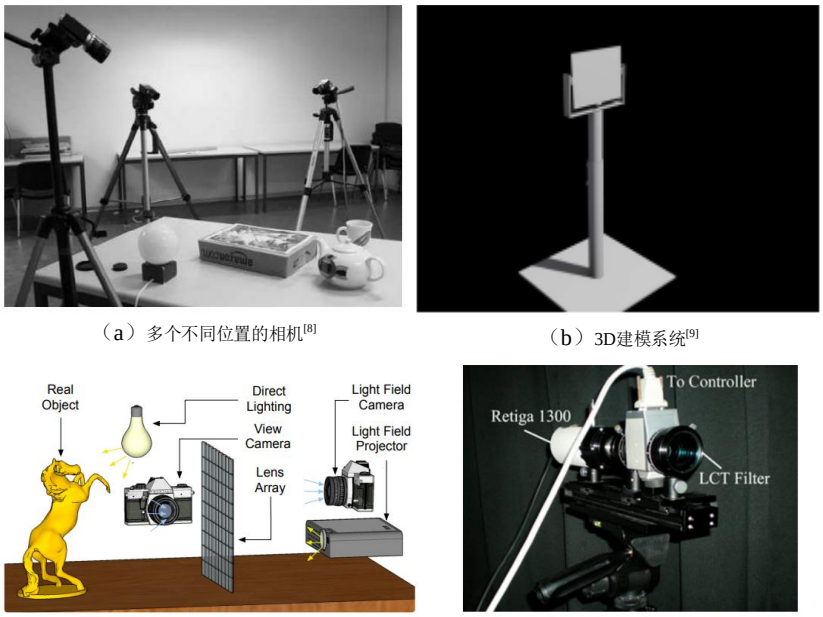

（a）多个不同位置的相机[8]　（b）3D建模系统[9]

（c）复杂拍摄系统[11]　（d）Imai等人[12]使用的拍摄系统

图 1.4 光照估计的特殊设备

中国知网 https://www.cnki.net

3. 基于图像分析的光照估计方法

基于图像分析的光照估计方法常使用附加的信息输入或者对输入图像进行本征属性分解，来获取足够估计光照的信息。深度信息、场景几何信息、反射率信息、先验知识等都属于附加的信息。2012 年，Gruber 等人[13]用任意的场景几何体进行表面重建和相机姿态估计，并使用场景重建后的材质反射率信息来进行估计场景的光照信息，但该方法假设光源都是在图像显示范围之外，因此图像中出现的光源被忽略。2013 年，Barron 等人[14]结合深度图像，从输入的图像中解析出该场景的光照分布、反照率和阴影等信息，但这种方法需要输入的图像中包括主要影响的光源，若不包括，则无法准确地估计出光照信息。2014 年，Karsch 等人[15]首先从单幅图像中估计出深度信息，再对图像进行本征属性分解来恢复场景的几何信息，最后从光照贴图数据库中筛选与当前场景光照接近的光照贴图来渲染虚拟物体。2015 年，Lombardi 等人[16]结合反射率先验信息提出了贝叶斯框架，得到了当前场景光照贴图的低维估计。随着 RGB-D 相机价格逐渐走低且便于携带，获取场景几何信息变得更加容易。2016 年，Zhang 等人[17]直接使用 RGB-D 相机扫描获取整个室内场景的深度信息，使用这些信息将场景重建为包含光源、材质、几何的三维场景，可以直接获得光源的位置，相比之前的方法，对光照的估计范围可以扩展到整个室内空间而不会局限于图像采集的视角范围内，而且还能对光源移除、增强等操作。2018 年，Monroy 等人[18]设计了一个基于双目 RGB-D 摄像机的增强现实系统，RGB-D 相机同时采集场景中的多帧彩色图像和深度图像并将其投影到包含 RGB+Depth 数据的二维环境地图，使用点云重建的方法，然后在漫反射表面和远距离照明的假设下，根据图像恢复指定位置附近的 4 阶 SH 系数近似表示的低频照明信息，从而在移动设备上实现实时的虚拟物体渲染。同年 Maier 等人[19]提出了一种使用 RGB-D 传感器进行 3D 重建的方法，将场景的 RGB-D 数据作为输入，并将其融合到有符号距离场 (Signed Distance Field，SDF) 中，估计空间变化的 SH，并将其用于联合优化场景的外观和几何形状，从而渲染 3D 模型。

基于图像分析的光照估计方法与辅助拍摄设备获取光照信息的方法相比，他们之间有一定的内在联系，因为基于图像分析的方法仍然需要使用特殊的硬件支持，最典型的就是 RDB-D 相机的使用，或者输入额外的场景信息的情况。但是在实际应用时，往往缺乏类似 RGB-D 相机这样的设备，因此该方法的实用

中国知网 https://www.cnki.net

性与基于辅助拍摄设备的光照估计方法一样受到硬件的制约。

4. 基于深度学习的光照估计方法

随着深度学习在各种任务上广泛使用且表现良好，研究人员也开始将深度学习用来解决光照估计的问题。这类方法往往需要大规模的数据训练神经网络，使网络模型学习输入数据与目标数据之间的隐性关系，当输入数据没有目标数据的时候，则可以使用训练好的模型预测出需要的目标数据。首次将深度学习利用在光照估计问题上是在 2012 年，Lalonde 等人[20]从图像的不同部分提取弱提示的组合，包括天空、垂直表面、阴影、图像中的凸出对象，虽然单个提示不能单独可靠地估计照明，但是每个提示都可以增强其他提示以产生更可靠的照明估计，最终估计可能的太阳位置的分布并能够合成天空模型，但是该方法依赖于上面提到的弱提示。与 Lalonde 等类似，Gardner 等人[21]从单个 2D LDR 图像生成一组描述 3D 区域光分布的位置、面积、强度和颜色照明参数，但是使用这些需要三维场景重建来制定要在其中模拟照明和比较灯光可见性的位置。后来，基于图像的方法开始慢慢盛行，Holdgeoffroy 等人[22]提出了基于卷积神经网络（Convolutional Neural Networks, CNN）的室外场景光照估计方法，利用 CNN 从单幅图像推断出室外场景的太阳位置、天空和相机参数，通过这些参数可直接生成 HDR 环境贴图，用于虚拟物体的渲染。Gardner 等人[23]直接从单个低动态范围图像（Low Dynamic Range，LDR）中恢复室内场景的 HDR 全景图像。但这两种方法都需要光源检测来推断 LDR 全景图中光源的范围和方向，从而建立一个粗糙的 HDR 环境地图用于训练，HDR 全景图是一种被广泛使用而且精度较高的光照表示模式。

为了高效地表示光照，有时候研究者们也愿意牺牲一定的精度，于是 Cheng 等人[24]和李等人[25]都是利用移动设备前后端拍摄的成对照片作为输入，预测出使用 4 阶 SH 系数近似的场景光照分布，但是存在一个问题，使用手机前后端同时拍摄照片的时候，难免会将拍摄者本人拍入画面。于是，很多研究者开始从单张图像入手，Sun 等人[26]利用单张图像输入并预测出 3 阶 SH 系数，但是其使用的卷积神经网络过于简单，仅仅只有 3 层卷积层和一层全连接层回归出 27 个 SH 参数。根据球谐函数理论，使用的阶数越高，得到的光照信息的精度也越高，所以，Garon 等人[27]将单个图像和该图像中的 2D 位置作为输入，输出该位置处照明的 5 阶 SH 系数。但是考虑到计算成本，SH 一般都不会使用很

中国知网 https://www.cnki.net

高的阶数，由于 SH 本身具有一定的局限性，渲染时对镜面材质不太友好。

另外一些基于深度学习的方法和传统方法类似，也会借助一些辅助信息或者是将深度学习方法运用到基于图像分析的方法中。Weber 等人[28]借助已知 3D 物体的几何结构，通过自动编码器对光照进行建模，恢复出场景的光照。Zhao 等人[29]借助额外的深度图像信息计算 3D 点云位置并提取出此位置的 2 阶 SH 系数。最近，很多方法不再局限于预测光照信息，也预测其他本征属性。Yu 等人[30] 通过 CNN 预测本征图像和 27 个 SH 系数近似的户外光照信息，但 SH 不善于表示局部光照。为此，Zhou 等人[31] 设计了一个由粗到细的网络结构 GLoSH，粗网预测全局 SH、反射率和法线，细网预测局部残差，全局 SH 模拟了整体照明，而局部 SH 则考虑了照明的空间变化，但包含了大量的参数。而 NIID-Net[32] 则没有使用参数形式的光照信息，而是通过有监督的训练， 基于 Retinex 理论分解出图像的光照集成图和本征属性图。Li 等人[33]基于微表面模型，从任意室内场景的单个 RGB 图像中，使用级联网络，获得完整的场景重建，分别估计图像的形状、非朗伯表面反射率材质、空间变化双向反射分布函数参数和球形高斯表示的光照信息，使用共享单编码器的多解码器网络结构逐级精炼，但是该网络需要经过七次训练。

基于图像分析的方法致力于不需要额外信息，直接从图片中估计场景光照，是解决光照估计问题最积极有效的方法，但是这类算法非常复杂，很难做到实时。后期很多研究者将深度学习方法加入其中，为基于图像分析的光照估计方法提供了解决思路，并且预测其他的场景信息与预测光照信息能相互促进，原因在于图像的形成是相机位姿信息、场景几何信息、图像材质信息以及光照信息共同作用的结果，逆向推出其中一些信息都有助于其他信息的预测。本文的方法正是将深度学习运用于图像分析中。

1.2.2 目前存在的问题

综上，基于深度学习的方法对于光照估计任务更加有效，大部分基于深度学习的方法不需要输入 RGB-D 相机拍摄的图片，也不需要重建几何场景。但将深度学习运用到光照估计中还存在以下问题：

1. 用于光照估计的图像都默认是专家拍摄的高质量图像，然而在现实生活中拍摄的图像可能存在很多不正确的颜色信息，例如光线微弱、逆光、噪声等，

中国知网 https://www.cnki.net

这些都会对光照估计造成一定的影响。

2. 目前的工作主要集中预测光照信息，较少工作会连同其他场景信息一起预测，但要运用到增强现实系统中，仅恢复出光照信息不能正确绘制虚拟物体投影到真实场景的阴影。

1.3 研究内容及章节安排

1.3.1 研究内容

针对目前存在的问题，本文提出了基于图像的深度逆向光照估计方法，从有限的场景视野图像中获得空间变化的光照信息，同时也获得了场景的其他几何和材质信息。主要研究内容如下：

1. 提出了融合多分支残差与仿射变换的低照度图像增强。首先利用光照估计模块获得低光图像的光照变量；其次通过光照仿射变换模块多次与光照编码参数融合恢复图像的光照；最后通过细节重建模块从原图像中学习更多的图像细节获得最终输出。这有助于下一步的光照估计任务开展。

2. 提出了材质和形状估计网络与球形高斯光照建模网络。先从基于微表面模型设计的材质和形状估计网络中得到场景的反照率图、法线图和粗糙度图，再将反照率图、法线图、粗糙度图和原图像与增强后的图像结合，作为球形高斯光照建模网络的输入，最终得到空间变化的照明信息。基于以上获得的信息渲染虚拟物体，提升虚实融合真实感，增强用户使用增强现实系统的体验感。

1.3.2 章节安排

本文共五章，各章内容如下：

第一章介绍 AR 与 VR 的区别，AR 的应用领域，光照估计的研究意义，根据国内外光照估计发展以及光照估计问题的研究现状，总结目前的解决方法中存在的问题并基于此提出本文的研究内容，最后阐述论文组织结构。

第二章首先总结了低照度图像增强的方法，接着分析并介绍了光照估计技术的基本理论、光照模型以及基于图像的光照表示方法，最后介绍光照估计中用到的神经网络。

第三章详细介绍融合多分支残差与仿射变换的低照度图像增强方法。从低照度图像存在的问题出发，设计了多个模块来分别融合解决存在的问题，并使

中国知网 https://www.cnki.net

用多种损失函数监督深度学习模型训练，最后通过定性、定量、运行效率以及消融实验验证算法的可行性。

第四章详细介绍基于图像的球形高斯光照估计。从图像的形成过程得到问题的求解方式，为实现光照一致性问题设计图像材质和形状模块以及球形高斯光照建模模块，并分别阐述每个模块的网络模型和损失函数，最后定性、定量分析本文结果，并将得到的光照信息运用到增强现实中验证方法的实用性以及有效性。

第五章对本文的内容进行总结，说明论文取得的成果与应用价值，并指需要改进的地方和展望未来研究方向。

中国知网 https://www.cnki.net

第二章 相关理论技术基础

2.1 低照度图像增强算法

低照度图像增强算法的目的是将输入图像恢复到正常照度，同时增强对比度。传统方法有：直接调整对比度和基于 Retinex 理论的低照度图像增强方法。但是这两种方法都默认假设图像拍摄于在噪声水平极低的情况，而现实生活场景中的低照度图像一般伴随着极高的噪声水平，因此，这两种方法不能很好地恢复低照度图像的细节和去除噪声，不能很好地处理现实生活场景中的低照度图像。本文第三章的低照度图像增强方法没有采用传统方法，而是基于深度学习设计了不同的模块来处理低照度图像。

2.1.1 直接调整对比度的低照度图像增强

该方法主要是设计不同的变换函数直接调整图像像素值，使图像中最亮的地方变得更亮，最暗的地方变得更暗。常用的对比度调整方法有线性拉伸变换、伽马（Gamma）变换和直方图均衡化。

1. 线性拉伸变换

线性拉伸变换采用线性函数对图像的 RGB 值进行变换，将图像的 RGB 值拉伸至[0，255]的整个区间，效果如图 2.1 所示，线性拉伸变换通常采用的函数是：

$$f(I) = 255 \times \frac{I - I_{\min}}{I_{\max} - I_{\min}} \tag{2.1}$$

其中 $I_{\max}$ 表示图像 I 的极大灰度值、而 $I_{\min}$ 表示极小灰度值。

（a）原图像　　（b）处理后

图 2.1 线性拉伸变换

中国知网 https://www.cnki.net

2. Gamma 变换

Gamma 变化是通过非线性变换（幂函数），使输出图像的 RGB 值与输入图像的 RGB 值呈幂函数关系。输入图像 I_{in} 和输出图像 I_{out} 之间的关系可以表示为：

$$I_{out} = cI_{in}^{\gamma} \tag{2.2}$$

其中 c 为缩放系数，一般取 1，γ 表示 Gamma 因子，控制了整个 Gamma 变化缩放的程度，一般取值 1/2.2、1、2.2。

（a）γ=1/2.2　　（b）γ=1　　（c）γ=2.2

图 2.2 不同 γ 系数下的变换结果

3. 直方图均衡化

直方图用来表示数字图像的亮度分布，统计图像像素灰度值就能得到灰度图。对于背景和前景都过亮或者是过暗的图像，可以利用直方图均衡化来增加图像的整体对比度。所谓均衡化就是将原图像的直方图变换成“均匀”分布的，如图 2.3 所示：

（a）原图像

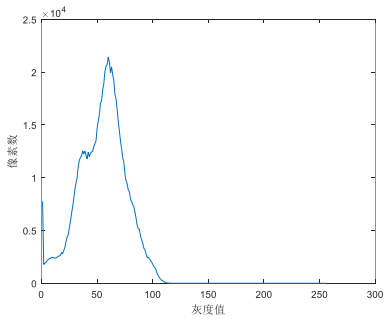

（b）处理后

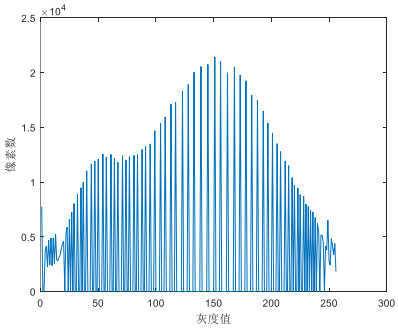

图 2.3 直方图均衡化处理前后的对比

中国知网 https://www.cnki.net

2.1.2 基于 Retinex 理论的低照度增强方法

Retinex 是由单词 retina（视网膜）与 cortex（皮层）合成，根据 Retinex 理论， 真实的世界是没有任何颜色的，所观察到的物体颜色是光和物质相互作用产生的，并且物体的颜色具有恒常性，不会随着入射光强度的变化而变化，由物体对于长、中、短波光线的反射能力所决定，因此物体表面的色彩具有高度的一致性，如图 2.4 所示：

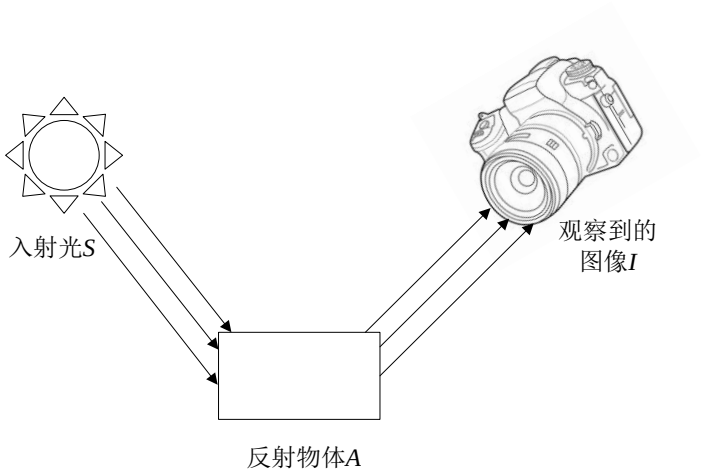

图 2.4 Retinex 假设

给定单张图像 I ，可以分解成反照率图像 A 和光照集成图像 S 。当入射光线照射到物体表面上，反射物体对该光线形成反射光并进入观察者的视觉系统，就形成了观察者所看到的图像，可表示为：

$$I = A * S \tag{2.3}$$

其中 $*$ 代表逐像素相乘。

这类低照度图像增强算法首先将图像分解，然后再对 S 处理，使其恢复到正常图像的光照信息 S_{normal} ，最后合成正常照度的图像 $I_{normal} = A * S_{normal}$ 。

2.2 光照基本理论

2.2.1 光照概念

现实世界中的物体被光线照射时，物体会吸收一部分光，另一部分光会被反射出去。只有当反射光线进入观察者的视觉系统时，才能看到并辨认出该物体的颜色。如果想模拟真实的光照生成一张具有照片真实感的图像，则需要考虑光源、散射和吸收以及着色三种物理现象。

中国知网 https://www.cnki.net

1. 光源

光源是光线产生的源点，在实际生活中，光源包括的三种光如图 2.5 所示：1）平行光，用来模拟从无限远处发射出来的光线，与自然界中的太阳光类似，光线都朝着同一个方向且光线间的距离大致相等；2）点光源光，用来模拟自然界中的人造灯光，比如路灯；3）环境光（Ambient），用来控制整体的环境，模拟所在环境投射到物体表面的光，白天的环境光和夜晚的环境光就会有显著的差别。

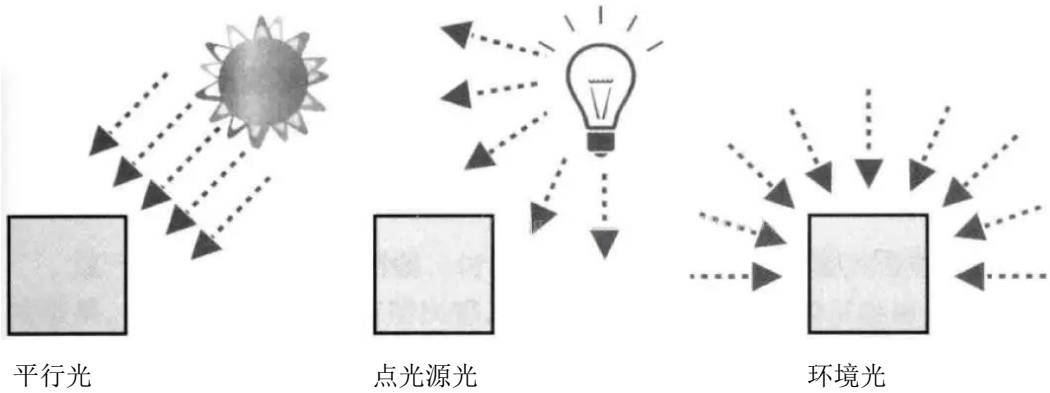

图 2.5 光源类型

2. 散射和吸收

从源点发射出的光线如果与某一物体相交，一部分光线会被该物体吸收，而另一部分光线会被散射出去，这就产生了吸收与散射。散射只改变光线的方向，密度和颜色不变，而吸收与散射刚好相反。散射的方向在物体内部称为折射或透射，在物体外部的称为反射，如图 2.6 所示。

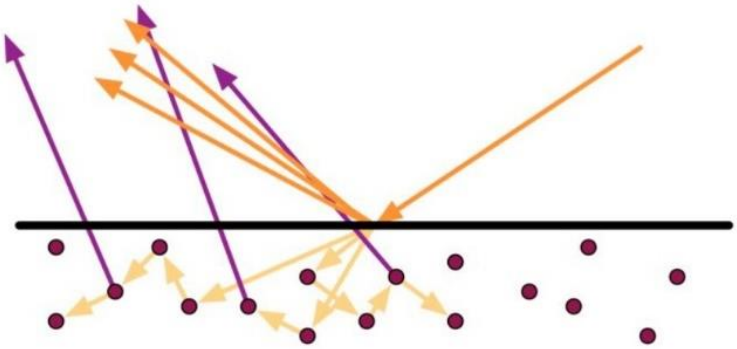

图 2.6 光线在散射时发生折射和反射现象

3. 着色

根据光源和光线方向，物体不同表面的明暗程度变得不一致。在三维图形学中还原这种效果，就叫着色（shading），着色是基于场景信息和光照信息使

中国知网 https://www.cnki.net

用光照模型计算光沿着一定的观察方向出射的过程。对于逆向绘制来说，着色是最关键的技术。

2.2.2 绘制方程

通常场景中某一点的光照度来自于以该点为中心，上半球面的光源发射出来的入射光。在渲染过程中，虚拟物体与场景的材质信息、几何信息和周围的环境光照信息紧密相关，在入射方向为 w_i，沿着 w_o 方向的出射光的绘制方程（Rendering Equation）[34]为：

$$L_O(w_o)=\int_{\Omega}L_i(w_i)f_r(w_i\rightarrow w_o)(n\cdot w_i)dw_i \tag{2.4}$$

其中 L_i 表示入射光，L_O 表示观察方向的出射光，$(n\cdot w_i)$表示宏观物体入射光和法线的夹角，f_r 是双向反射分布函数（Bidirectional Reflectance Distribution Function，BRDF），Ω 是以法线为中心轴，由入射光组成的半球面。

由于双向反射分布函数 f_r 相对抽象，所以针对这个函数的不同，研究者们给出了不同的光照模型，基本的光照模型和本文使用的光照模型本文将在 2.3 节中介绍，L_i 将在 2.4 节中介绍。

2.3 光照模型

光照模型是绘制真实感图像的重要基础，它确定物体上每一点或屏幕上每一像素处的几何信息如何与光进行交互，生成该点或者该像素处的光强度、明暗色调或者是颜色。在计算机图形学中，真实世界中的光照可由环境光、漫反射光、镜面反射光三种不同种类的光照叠加而得。

2.3.1 环境光照模型

环境光照模型是所有光照模型的基础，也是最简单的模型，该模型即只考虑环境光的影响，并且不会去精确的描述。环境光照模型可表示为：

$$L_a=k_aC_{light} \tag{2.5}$$

其中 k_a 代表物体表面对环境光的反射率，取值范围为[0，1]，也称为材质的反射系数；C_{light} 代表入射环境光的颜色和光；L_a 存储人眼所能看到从物体表面反射的环境光的亮度。仅使用环境光照模型的效果如图 2.7 所示：

中国知网 https://www.cnki.net

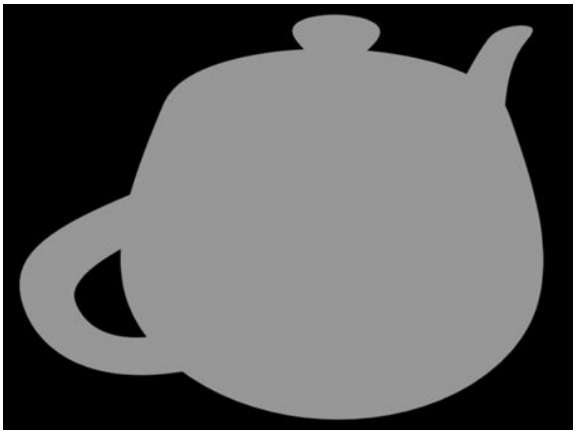

图 2.7 使用环境光照模型渲染的茶壶

2.3.2 漫反射模型

当光线接触到物体以后，若物体的表面是粗糙的，光线就会被该物体的表面无规律地向四面八方反射，这种现象被称为漫反射。一般选择 Lambert 模型来模拟光线接触到粗糙表面后的漫反射现象， Lambert 光照模型可以表示为：

$$L_{\text{diff}} = k_d C_{light}(n \cdot l) \tag{2.6}$$

其中 k_d 表示物体对光线的反射系数， C_{light} 是光线的颜色和强度， n 、l 分别为入射光线的单位向量和当前表面的法线单位向量，它们的点积 $n \cdot l = |n||l|\cos\theta$，$\theta$ 是 n 和 l 的夹角。

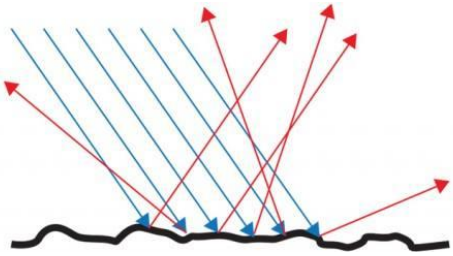

图 2.8 漫反射

2.3.3 高光反射光照模型

由于 Lambert 模型显示不出光泽，而生活中有很多物体具有镜面反射效果。因此引入 Phong 模型，Phong 模型由环境反射、漫反射和镜面反射三部分组成，Phong 光照模型可以表示为：

$$L_{spec} = k_s C_{light} \max(0, v \cdot r)^{m_{gloss}} \tag{2.7}$$

其中 C_{light} 表示入射光线的颜色和强度； v 和 r 分别表示视角方向单位向量和反射

中国知网 https://www.cnki.net

方向单位向量，他们的点积 $v \cdot r = |v||r|\cos\theta$，$\theta$ 是 v 和 r 的夹角；m_{gloss} 表示材质的光泽度，也被称为反光度，用于控制高光区域的“亮点”宽度，m_{gloss} 越大，亮点就越小；k_s 表示镜面反射系数；r 可以通过下式得到：

$$r = 2(n \cdot l)n - l \tag{2.8}$$

其中 n，l 分别为入射光线的单位向量和当前表面的法线单位向量，它们的点积 $n \cdot l = |n||l|\cos\theta$，$\theta$ 是 n 和 l 的夹角。

Blinn-Phong 光照模型引入一个新的矢量 m，用光源方向矢量 l 和视线方向矢量 v 的角平分线作为中间矢量 m，可用数学公式表示为：

$$m = \frac{v+l}{|v+l|} \tag{2.9}$$

在改善后的 Blinn-Phong 模型中，用中值单位向量与法线的夹角来代替原来 Phong 模型中的理想反射方向与实际方向的夹角，这样可以大大简化运算，各模型的效果对比如图 2.9 所示。

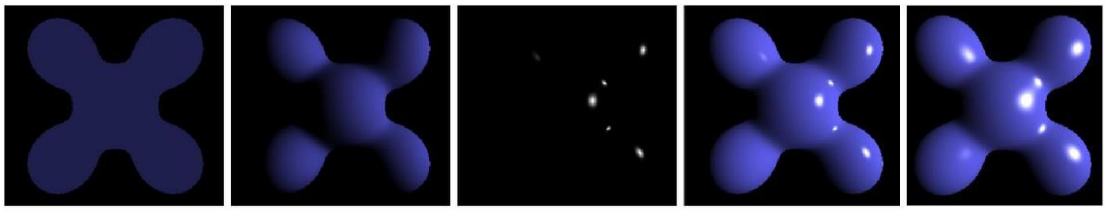

环境反射　　漫反射　　镜面反射　　Phong　　Blinn-Phong

图 2.9 Phong 光照模型的形成过程以及 Blinn-Phong 光照模型效果图

2.3.4 微表面模型

面对更加复杂的场景，Lambert 模型、Blinn-Phong 模型以及简单的理想反射、折射模型就不够用了，于是使用基于物理的材质模型来表达更复杂的场景，微表面模型应运而生。微表面模型将自然界中粗糙物体的宏观表面(macrosurface)视作由一个个微表面(microfacets)组成。

Cook-Torrance 模型[35]是最常用的微表面模型，对于沿 w_i 入射，沿 w_o 出射的光线，只有法向为 $w_h = \overline{w_i + w_o}$ 的微表面有贡献。取宏观表面的一个面积微元 $dA(n)$，在这个区域中，假设表面的法向为 n，Cook-Torrance 模型的 BRDF 可表示为：

$$f_r(w_i, w_o) = k_d f_d + k_s f_s \tag{2.10}$$

中国知网 https://www.cnki.net

其中：

$$f_d = \frac{A}{\pi} \tag{2.11}$$

$$k_s = F \tag{2.12}$$

$$f_s = k_s \frac{DG}{4(n \cdot v)} = \frac{FDG}{4(n \cdot v)} \tag{2.13}$$

$$k_d + k_s = 1 \tag{2.14}$$

$f_{lambert}$ 和 f_s 分别表示漫反射和镜面反射 BRDF 项，k_d 和 k_s 分别表示漫反射系数和镜面反射系数，系数 k_d 和 k_s 保证了能量守恒。菲涅尔项 F 、法线分布项 D 和几何项 G 的具体形式将在下面展开阐述。

1. 菲涅尔项 F

F 表示菲涅尔项，与反射、折射比例有关，取值范围为 0-1，用于描述反射率。使用 Schilick 近似菲涅尔项 F 的曲线如图 2.10 所示。其公式相当复杂，UE4[36] 给出了相对简化并且计算速度更快的版本：

$$F(v, w_h) = F_0 + (1 - F_0) 2^{-(5.55473(v \cdot w_h) + 6.98316)(v, w_h)} \tag{2.15}$$

其中 v 表示视线方向矢量，F_0=0.04。

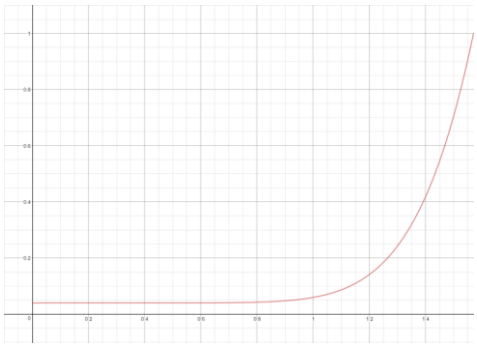

图 2.10 使用 Schilick 近似菲涅尔项的曲线

2. 法线分布项 D

D 是法线分布函数（Normal Distribution Function，NDF），用于描述微平面法线分布，物理含义为每单位立体角下所有法向为 w_h 的微平面的面积。 这里采用 Walter 等[37]提出的 GGX/Trowbridge-Reitz 作为法线分布函数，数学表达式为：

$$D(w_h) = \frac{\alpha^2}{\pi((n \cdot w_h)(\alpha^2 - 1) + 1)^2} \tag{2.16}$$

其中 $\alpha = roughness^2$，即粗糙度的平方。

中国知网 https://www.cnki.net

从式 2.16 知法线分布函数 D 可以在粗糙度上做参数化，通过粗糙度来描述微平面的凹凸程度，如图 2.11 所示。低粗糙度会产生锐利清晰的镜面反射，镜面波瓣会表现得狭窄细长，而高粗糙度会产生更宽的镜面波瓣。

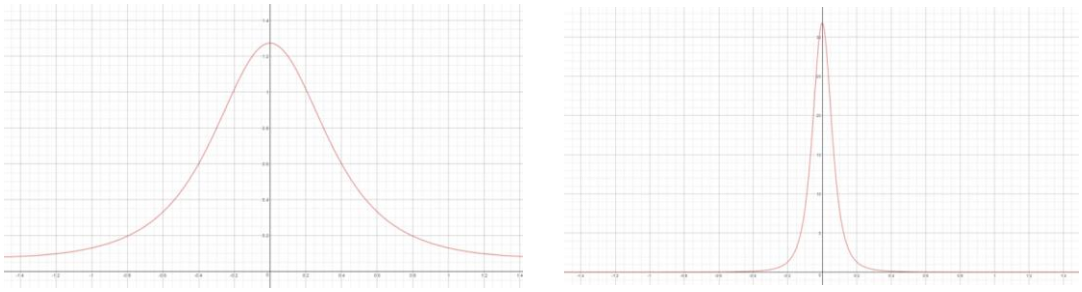

（a）0.5 粗糙度　　(b) 0.1 粗糙度

图 2.11 不同粗糙度表示的镜面波瓣

3. 几何项 G

G 是几何项，与微表面之间的遮挡有关，用于描述几何遮蔽（Geometry Obstruction）和几何阴影（Geometry Shadowing），为了表示微平面的自遮挡从而引起的光线损失（取值范围是 0-1），如图 2.12 所示，几何阴影表示入射光线无法照射到的微平面；几何遮蔽表示反射光线无法正常到达人眼。在 UE4[36]中采用了 Schlick-GGX 来进行建模，如公式 2.17 所示：

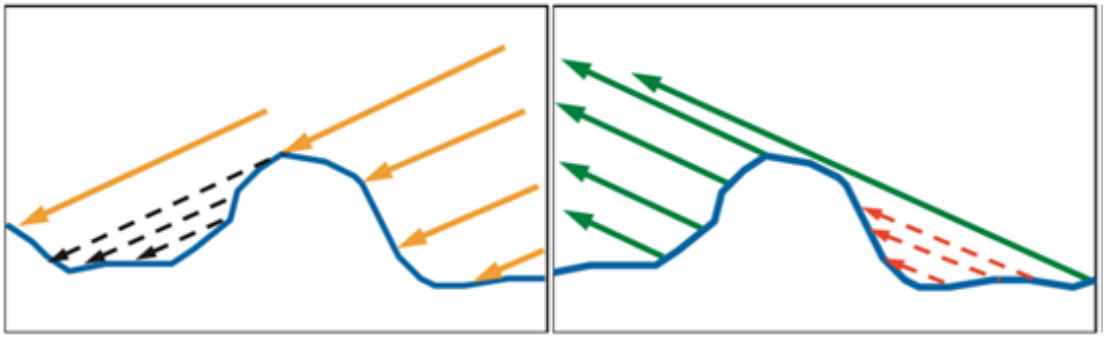

（a）几何阴影　　（b）几何遮蔽

图 2.12 微平面的自遮挡从而引起的光线损失

$$G(l,v)=G_1(l)G_1(v) \tag{2.17}$$

其中：

$$G_1(v)=\frac{n\cdot v}{(n\cdot v)(1-k)+k} \tag{2.18}$$

$$G_1(l)=\frac{n\cdot l}{(n\cdot l)(1-k)+k} \tag{2.19}$$

$$k=\frac{\alpha}{2} \tag{2.20}$$

中国知网 https://www.cnki.net

α 与式 2.16 中一样，都是表示粗糙度的平方。图 2.13 中展示了使用 Smith-GGX 函数作为几何项 G 的曲线，该图中粗糙度为 0.25，且法线与视线夹角为 0。

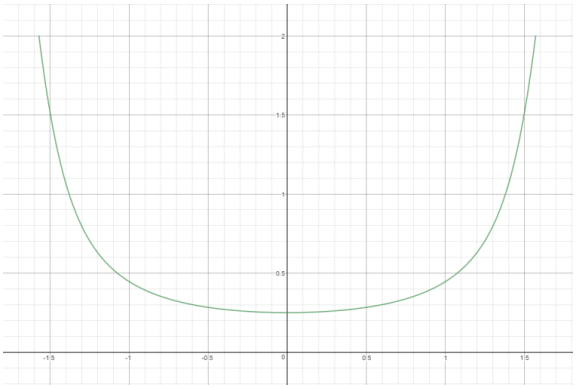

图 2.13 Smith-GGX 函数作为几何项 G 的曲线

本文也是采用微表面反射模型（Microfacet Model）来表示空间变化的 BRDF。

2.4 基于图像的光照表示方法

在增强现实应用中，通常采用基于图像照明（Image Based Lighting，IBL）[38]渲染虚拟物体，IBL 相当于一个无限大的球面光源在照明整个场景。辐射度由环境光照贴图（environment map）决定，于是公式 2.4 中的 L_i 被表示成如下形式：

$$L_i(w_i) = L_{env}(w_i) \tag{2.21}$$

使用基于图像的照明进行渲染可以使渲染效果更佳，通常有球形谐波函数表达和高动态范围（High Dynamic Range，HDR）光照贴图两种光照表示方法。

2.4.1 HDR 光照贴图

HDR 光照贴图是一种精度范围较高，且使用范围较广的光照表示方式。不同于 8 位 3 通道的 RGB 图像，HDR 光照贴图的颜色范围值很广，可以从 0 表示到非常大。这也就意味着 HDR 光照贴图可以更详细地表示每个像素位置的亮度值。IBL 中常常使用 HDR 光照贴图作为光源，在使用 HDR 渲染虚拟物体时，光照贴图上的每一个像素点都参与光源计算。

如果光照贴图是 2 维度的，那么首先要将 w_i 转化为纹理坐标，或者先将环境光照贴图（environment map）转化为立方体贴图（cubemap），则公式 2.21 转化为：

中国知网 https://www.cnki.net

$$L_i(w_i) = L_{env}(w_i) = texCube(w_i) \tag{2.22}$$

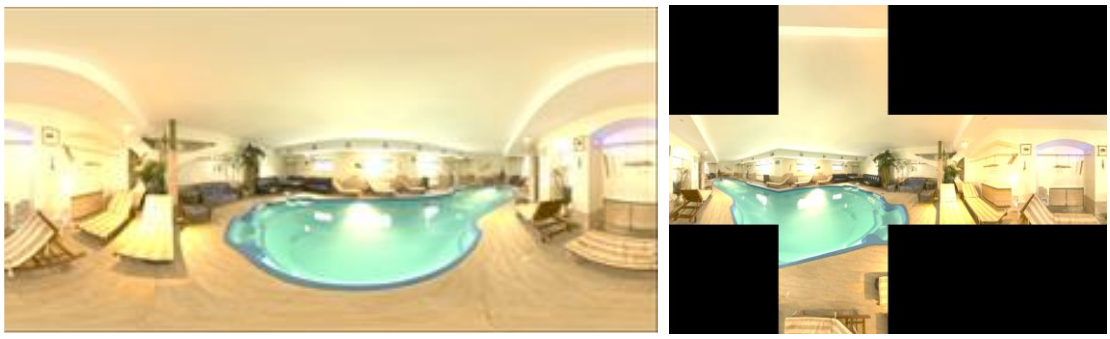

（a）全景光照贴图　　（b）立方体光照贴图

图 2.14 HDR 光照贴图

2.4.2 球形谐波函数

球形谐波函数（Spherical Harmonics，SH）是一种小巧、高效的光照表示方法，这种方法首先是对周围的环境光采样，再使用球谐系数来对光照近似表达，光照的低频部分可以使用少量的系数来近似，通常使用 3 阶的 9 组 SH 系数来近似，光照信息为 3 通道，共 27 个（$3^2\times3$）SH 系数，如图 2.16（a）所示，（b）图是使用（a）中的 27 个 SH 系数渲染的光照贴图。

1	3.0496	2.87707	2.17518
2	-0.177195	-0.0220391	0.0420297
3	0.25412	0.203421	0.218495
4	-0.00542547	-0.0795826	-0.156183
5	-0.109587	-0.146417	-0.106524
6	0.0831001	-0.0702455	-0.137297
7	0.0589351	-0.00655817	-0.0449865
8	-0.0232456	-0.0158759	-0.00820622
9	-0.0487875	-0.092447	-0.147515

（a）SH 系数

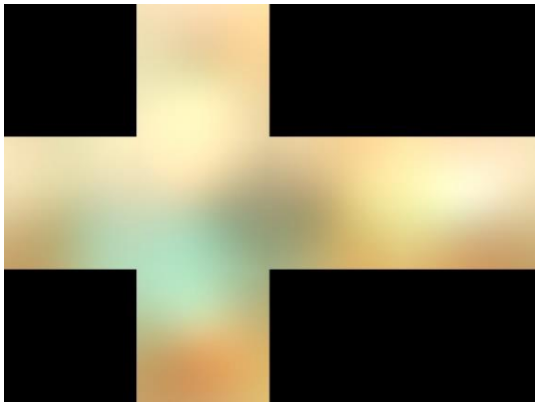

（b）SH 光照贴图

图 2.15 SH 光照

这种光照表示方法是以牺牲一部分精度为代价，来缩小估计参数量的规模，从而达到简化光照估计的目的；缺点是不能很好地保留光照分布的高频细节，虽然对光照分布中的高频细节不友好，但其光照精度依然足以渲染漫反射物体。

2.5 光照估计中用到的神经网络

目前，研究者们提出了多种卷积神经网络架构来解决光照估计问题，本小

中国知网 https://www.cnki.net

节将简要介绍与本文方法相关的卷积神经网络结构，包括 U-net[41]、深度残差网络(ResNet)[42]与 RepVGG[43]。

2.5.1 U-net

在 2015 年，Ronneberger 等人[41]提出了结构上相互对称的 U-net 网络，网络结构如图 2.16 所示。其对输入图像的计算过程类似于图像正逆渲染，因而基于此结构的网络在图像的光照估计上有着更为广泛地使用。该网络可以在小规模的数据集上训练并获得较好的泛化能力，这对于数据集紧张的光照估计任务无疑是福音。

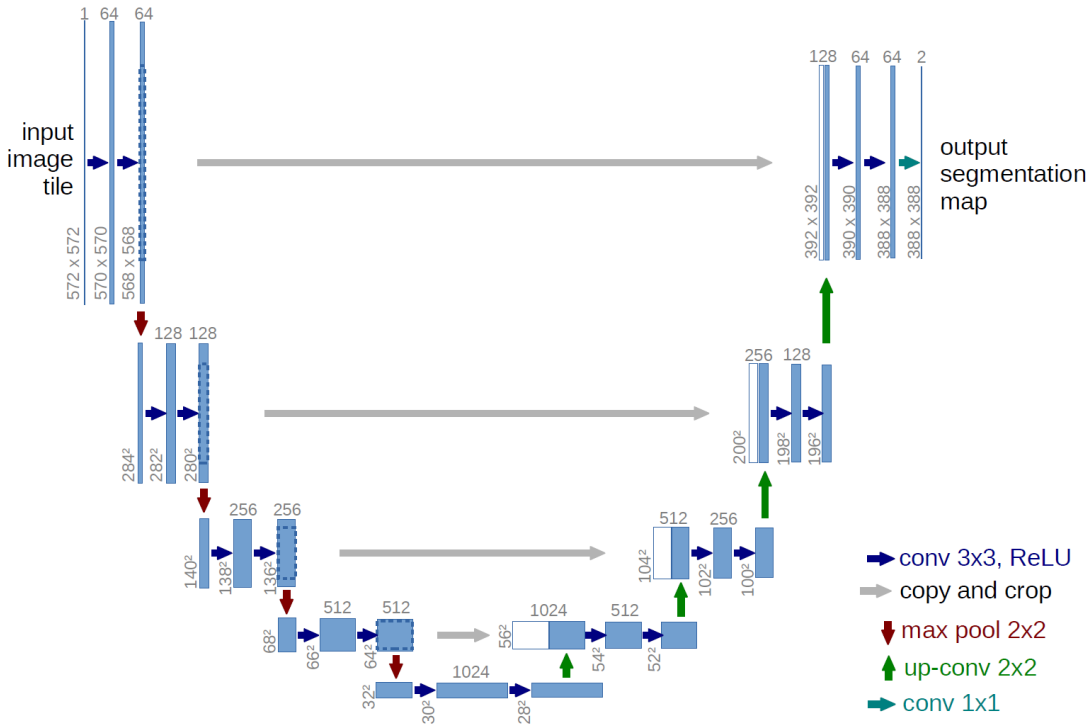

图 2.16 “U-net”网络结构

U-net 的主要贡献在 U 型结构上，网络结构全部由卷积层组成，并没有使用全连接层。从图 2.16 中可以看出，U-net 的结构类似于 Encoder-Decoder（编码器-解码器）结构。即 U-net 的下采样部分可以看作是一个编码器（Encoder），而 U-net 的上采样部分可以看作是一个解码器（Decoder）。编码器部分由四个模块组成，每个模块包含两个卷积层，模块之间执行最大池化运算，图像在每一个模块后都相当于进行了一次下采样操作，四个模块总共经历了四次下采样。解码器同样由四个模块组成，与卷积层一样每个模块同样由两个卷积层组成，不同的是，每个模块后进行的是上采样操作，每经过一个模块，图像的分辨率

中国知网 https://www.cnki.net

就比原来的要高一倍左右。U-net 的跳跃结构由灰色箭头表示，左侧下采样特征图直接与右侧上采样结果中分辨率相同的特征图进行拼接（concatenate），浅层的特征图与深层的特征图进行拼接可以进行信息互补，让图像保留了更多细节。

2.5.2 ResNet

计算机视觉中，在一定程度上，网络的深度是效果表现好的重要因素，然而超过了一定的限度，就会出现梯度弥散/梯度爆炸，这会成为训练深层次网络的一大障碍，使得网络无法收敛。有一些方法可以弥补，如归一初始化，各层输入归一化，使得可以收敛的网络的深度提升为原来的十倍。虽然网络收敛了，但网络却开始退化了，即增加网络层数却导致更大的误差。

在 2015 年，何凯明等人[42]正式提出了 ResNet，残差网络通过跳层连接（Skip Connection）增加了梯度的流动，从而使上千层网络的训练成为可能，并且残差网络的有效性主要得益于其减轻了神经网络的退化。ResNet 学习的是残差函数 $F(x)=H(x)-x$，如果 $F(x)=0$，那么就是 $H(x)=x$ 的恒等映射。事实上，跳过连接是恒等映射下的特殊情况，它没有引入额外的参数和计算复杂度。

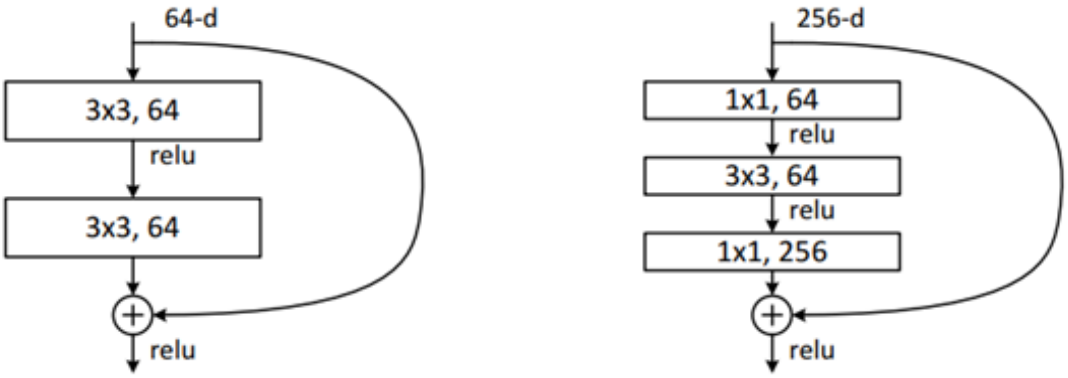

（a）ResNet34的残差块　　（b）ResNet-50/101/152的残差块

图 2.17 残差学习：残差块

每个残差块中包括两个 3×3 的卷积层和一个跳层连接，如图 2.17（a）所示。实际中，考虑计算的成本，对残差块做了计算优化，即将两个 3×3 的卷积层替换为 1×1+3×3+1×1，如图 2.17（b）所示。新结构中的中间 3×3 的卷积层首先在一个降维 1×1 卷积层下减少了计算，然后在另一个 1×1 的卷积层下做了还原，既保持了精度又减少了计算量。

2.5.3 RepVGG

中国知网 https://www.cnki.net

目前，已进入卷积网络各种超参精确到小数点后三位的时代，而堆几个卷积层就能涨点的快乐时代一去不复还，随着 ResNet[42]等模型提出后，研究重点纷纷转向各种多分支卷积网络架构，VGG[44]这样的“直筒型”简单架构鲜有问津。但科学技术总是螺旋式地上升，2021 年，Ding 等人[43]在七年前的架构 VGG[44]中注入了一个新想法，形成了 RepVGG，让七年前的模型再次跟上 SOTA。

RepVGG 是一个分类网路，该网络是在 VGG 网络的基础上进行改进，主要的改进点包括：1）在 VGG 网络的 Block 块中加入了 Identity 和残差分支，相当于把 ResNet 网络中的精华应用到 VGG 网络中；2）模型推理阶段，通过 Op 融合策略将所有的网络层都转换为 Conv3×3，便于模型的部署与加速。亮点有：网络训练和网络推理阶段使用不同的网络架构，训练阶段更关注精度，推理阶段更关注速度。图 2.18 展示了 RepVGG 架构。

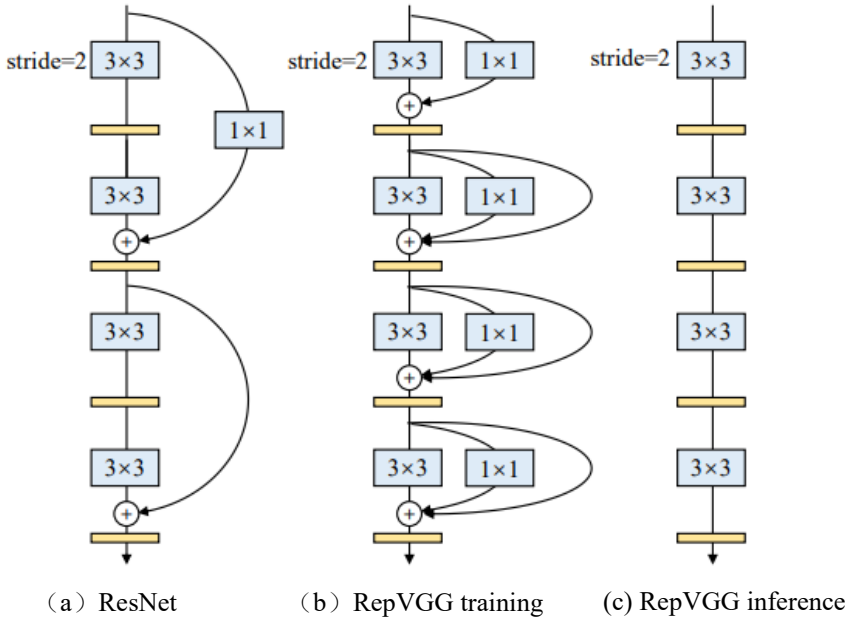

图 2.18 RepVGG 架构示意图

在图 2.18 中，（a）表示的是原始的 ResNet 网络，图 2.18（b）表示的是训练阶段的 RepVGG 网络架构，整个网络的主体结构和 ResNet 网络类似，两个网络中都包含残差结构。两个网络中的主要差异如下所述：1）RepVGG 网络中的残差块并没有跨层；2）整个网络包含 2 种残差结构，仅包含 Conv1×1 残差结构与不仅包含 Conv1×1 的残差结构，而且包含 Identity 残差结构。由于残差结构具有多个分支，就相当于给网络增加了多条梯度流动的路径，类似于模型集成的思路，不过这种思路更加简单和高效；3）模型的初始阶段使用了简单的残差结构，随着模型的加深，使用了复杂的残差结构，这样不仅仅能够在网络的

中国知网 https://www.cnki.net

深层获得更鲁棒的特征表示，而且可以更好的处理网络深层的梯度消失问题。（c）表示的是推理阶段的 RepVGG 网络，该网络的结构非常简单，整个网络均是由 Conv3×3+Relu 堆叠而成，易于模型的推理和加速。这样就可以同时利用多分支模型训练时的优势（性能高）和单路模型推理时的好处（速度快、省内存）。RepVGG 的关键在于多分支模型的构造和转换。

2.6 本章小结

本章介绍了低照度图像增强和光照估计的相关基础知识。首先介绍了图像增强的基础知识，然后介绍了增强现实中的光照理论，包括光照概念、基本光照模型与基于物理的复杂光照模型，分析了增强现实中的光照表示方法，最后介绍了相关的深度神经网络知识，包括 U-net、深度残差网络和 RepVGG。

中国知网 https://www.cnki.net

第三章 融合多分支残差与仿射变换的低照度图像增强方法

3.1 引言

为保证增强现实技术的光照一致性，需要通过光照估计技术获取真实场景的光照信息，从而使虚拟物体和真实场景能够融合。光照估计一般依赖于提取诸如阴影信息或者阴影的提示信息，并将这些信息与场景几何以及形状的估计相结合来恢复场景的照明分布情况。但是在现实生活中，图像在拍摄过程中会受到各种各样因素的影响，例如：光线微弱、逆光、噪声等，难以满足光照估计任务的需求。因为低照度图像几乎没有可见的细节、对比度低，并且图像的颜色暗淡，所以将低照度图像增强有助于准确地获取图像的光照信息。研究者们提出了许多方法来提高低照度图像的主客观质量。传统的方法（直方图均衡化和基于 Retinex）主要针对图像的对比度增强，不能解决图像的颜色和细节恢复问题，并且每次只能处理单张图像。

近期基于深度学习的方法受数据驱动同时学习调整图像的颜色、对比度、亮度和饱和度以产生更友好的增强效果。因此，本文受图像降噪[45]、细节保留[46]以及深度光照估计[47]的启发，借鉴了最新深度学习技术[43]的成功，提出融合多分支残差与仿射变换的低照度图像增强方法。本文方法的核心是针对不同的低照度图像中存在的问题运用不同的模块来处理，低照度图像中存在的问题是噪声、亮度、细节与颜色，于是将解决方案分成了三种模块，分别是光照估计模块、光照仿射变换模块和细节重建模块。主要思路是：1）由光照估计模块获得照明变量；2）光照仿射变换模块首先从照明变量中获得照明参数，再多次与光照编码参数融合恢复图像的照明；3）细节重建模块从原始输入图像中学习更多的图像细节获得最终增强图像。

3.2 网络模块与结构

网络的输入是低光彩色图像，最终输出是与输入图像相同分辨率的正常曝光清晰图像，整个网络架构如图 3.1 所示，算法处理步骤如表 3.1 所示。将图像增强问题分解为不同的子问题，可以通过多模块融合分别解决这些子问题以产生最终输出。网络架构由三种类型的模块组成，即：光照估计模块、光照仿射变换模块和细节重建模块，下面分别对这三个模块进行详细阐述。

中国知网 https://www.cnki.net

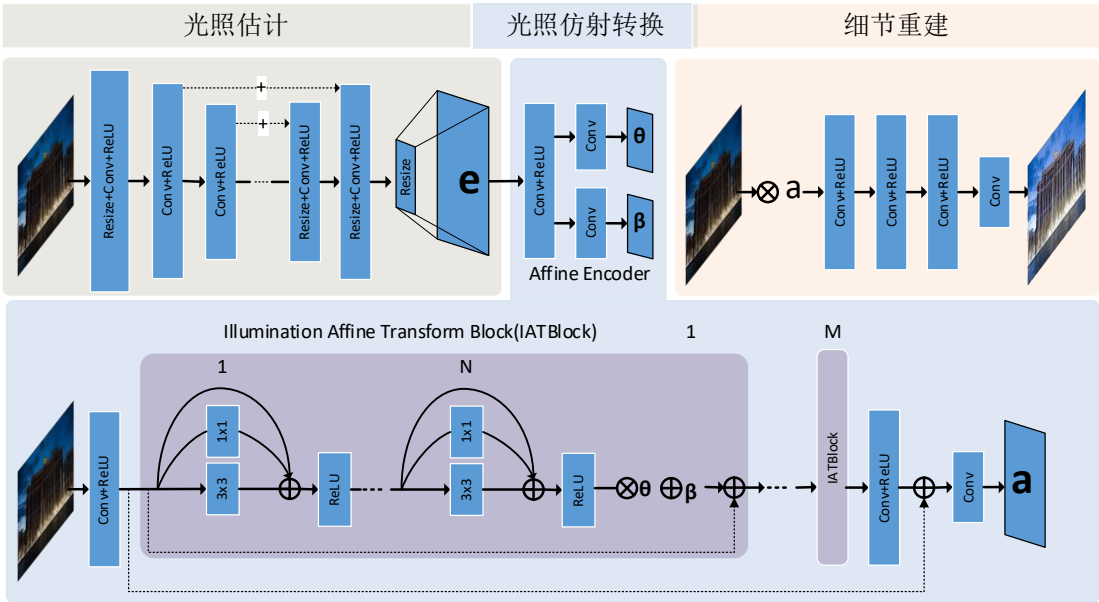

图 3.1 融合多分支残差与仿射变换的低照度图像增强网络架构

表 3.1 低光增强算法步骤

算法 3.1	低光增强算法
输入：	低光彩色图像 $I \in R^3$
输出：	正常曝光清晰图像 $E \in R^3$
1	e=光照估计模块(I)，$e \in R^{128}$
2	θ, β=光照仿射编码(e)，$\theta \in R^{64}, \beta \in R^{64}$
	∂=主干（I, θ, β），$\partial \in R^3$
3	E=细节重建（I, ∂）

3.2.1 光照估计模块

光照估计模块在结构上相互对称，可分为三个子步骤：将输入图像缩放到特定分辨率，再将其通过类似 U-net 的残差连接编解码器（Encoder-Decoder）网络进行照度预测，编码器（Encoder）由六个下采样块组成，解码器（Decoder）由六个上采样块组成，最后将其重新缩放到原始分辨率并获得照明变量。

首先，通过双线性插法将输入降采样为 96×96 的特征图，随后跟着带有 ReLU 的卷积层。然后，特征图通过一系列下采样块，下采样块由步长（stride）为 2 的卷积层和 ReLU 激活函数组成，所以，每经过一次下采样块，特征图的高和宽就降为原来特征图的一半，根据降采样后特征图的宽和高来设计下采样块的数量，以便编码器网络瓶颈层的感受野可以覆盖整个图像，感受野越大，得到的信息就越多。所以从 96×96 的特征图变化到 1×1 的特征图，共用到了六

中国知网 https://www.cnki.net

个下采样块，这种设计不仅可以减少所需的存储空间，而且有益于提升网络效率。经过与下采样块相同数量的对称上采样块之后，获得用于照明预测的 96×96 特征图。通过另一个上采样块，将特征图重新缩放到原始输入的大小。

残差跳层连接从下采样模块引入到与下采样分辨率相同的镜像上采样模块。下采样块的输出通过跳层连接传递到上采样块的特征图并与该上采样块特征图进行累加操作，残差跳层连接迫使网络学习残差而不是实际预测像素值。在上采样块中，需要通过反卷积来与常规卷积相反的作用，即实现分辨率的增加，但本文并没有使用常规的卷积，而是使用调整大小卷积层[48]来替换常规的反卷积层。使用调整大小卷积层的目的是，它不仅能避免伪影的棋盘格图案，使图像平滑，而且还不限制输入图像的大小。调整大小卷积层由一个双线性插值操作，一个步长为 1 的卷积层和一个 ReLU 激活函数组成。

光照估计模块中所有卷积层都采用 3×3 卷积核，并且除最后一层特征图的输出的通道数为 3 外，其余卷积层的输出通道都是 64。

3.2.2 光照仿射变换模块

光照仿射变换模块又可分为仿射编码部分和主干部分。仿射编码部分的作用是接受来自光照估计模块输出的光照变量，并输出照明仿射参数 θ 和 β。主干部分首先使用一个卷积层提取原始输入的特征，并将其送入 M 个级联的光照仿射变换块，随后与第一个卷积层输出的特征图采用残差学习方案[45]，该操作的目的主要是学习噪声而不是清晰的图像，最后输出 3 通道的光照仿射变换图。该部分除了特殊说明的卷积层外，都采用卷积核等于 3×3 、步长为 1 且特征图输出通道数等于 64 的卷积层。仿射编码部分网络结构采用卷积核为 1×1 且步长等于 1 的卷积层，第一个卷积层带有 ReLU 激活函数且其特征图输出通道数等于 128，接下来是两个并列特征图输出通道数为 64 的卷积层，两个卷积层的输出通道数加起来刚好是 128。

主干主要是基于 M 个级联的光照仿射变换块（Illumination Affine Transform Block，IATBlock）。为了有效融合照明信息，本文使用了光照仿射变换，它可以将仿射变换应用于特征图，表示为：

$$F_O = \theta \otimes F_i + \beta \tag{3.1}$$

其中：F_i 表示变换前的特征图，而 F_O 表示变换后的特征图；$\otimes$ 表示逐元素相

中国知网 https://www.cnki.net

乘。在光照仿射变换块中，通过将仿射参数θ和β运用于仿射变换来调整最后一个卷积层的输出，并与其他光照仿射变换块共享仿射参数θ和β。

光照仿射变换块由 N 个级联多分支独立并行残差结构[43]构成。训练时的多分支残差块是由卷积核为 3×3 的卷积分支、卷积核为 1×1 卷积分支和输入本身构造，表示为：

$$y = x + f_{1\text{x}1}(x) + f_{3\text{x}3}(x) \tag{3.2}$$

但是可以通过重构参数删除分支，经过训练后，可以运用简单的代数变换将式 3.2 等价地转化为 $f_{3\times3}(x)$，因为一个恒等分支可以看作是退化的 1×1 卷积分支，而 1×1 卷积分支又可以看作是退化的 3×3 卷积分支，因此可以构造一个单一的 3×3 卷积分支 $f_{3\times3}(x)$ 具有原始的 3×3 卷积分支 $f_{3\times3}(x)$，1×1 卷积分支 $f_{1\times1}(x)$ 和输入本身 x 的训练参数。其中 $f_{3\times3}(x)$ 由一个卷积核等于 3×3 卷积层实现，其参数由一系列代数变换后的卷积层导出。相对于 ResNet[42]的残差块，多分支独立并行残差结构不仅内存消耗低，而且可以自由地配置每个卷积层，并进行修剪后在测试过程中获得更好的性能效率折衷。

3.2.3 细节重建模块

考虑到原始输入数据包含更多的图像细节，因此可以为细节恢复提供帮助，并且将浅层的特征图与深层的特征图融合，可以进行信息互补，减轻神经网络的退化，从而增强网络的表达能力。使用级联（concatenate）而不是跳层连接来组合光照仿射变换模块输出的特征图α和原始输入图像的特征图，目的是可以完全保留原始信息和照明照仿射变换处理后的信息，并将其传输到一系列的卷积层再进行细节增强。级联层之后是除最后一层外都带有 ReLU 激活函数，卷积核为 3×3 且特征输出通道数为 128 的 4 个卷积层，最后一层的特征输出通道数为 3。细节重建模块将输入的图像信息与仿射变换后得到的照明信息组合在一起，最终生成具有更多图像细节的增强型清晰结果。

3.3 损失函数

为了从主观评价和客观评价方面改善图像质量，使用均方误差和平均绝对误差等常见误差指标不足以解决问题。因此，进一步考虑结构信息，人眼感知和图像的区域差异。其计算公式为：

中国知网 https://www.cnki.net

$$Loss = L_1 + L_{Str} + L_{VGG/i} + L_{Region} \tag{3.3}$$

其中 L_1、L_{Str}、$L_{VGG/i}$ 和 L_{Regine} 分别表示 L1 损失、结构损失、感知损失和区域损失，接下来将对这些损失函数展开解释。

3.3.1 L1 损失

L1 损失也称为绝对误差损失（Mean Absolute Loss，MAE Loss），其以绝对误差作为距离，L1 损失函数具有稀疏性，常常被作为正则项添加到损失函数中来约束参数的稀疏性。学习低照度图像 I 的增强后图像 E 与相应的正常曝光 ground-truth 图像 G 之间的差距，损失函数可以写：

$$L_1 = \frac{1}{N}\sum_{i=1}^{N}\left\|(E_i - G_i)\right\|_1 \tag{3.4}$$

其中 N 表示训练样本的数量。

3.3.2 结构损失

在低光图像增强任务中，不需要被用来增强处理的图像处于特定的光照条件下。 例如，给定一张在白天拍摄的自然图像，添加或减去少量数字来更改图像的所有像素值，图像结构几乎不会改变，而峰值信噪比（Peak Signal to Noise Ratio，PSNR）会报告很大的差异。对于低光图像增强，保留纹理更为重要，并且允许亮度随正常曝光图像（ground-truth）情况而波动。因此，结构相似性（Structural Similarity，SSIM）值应该更适合该任务，增强图像 E 与相应的正常曝光 ground-truth 图像 G 的 SSIM 值由以下定义计算：

$$SSIM(E,G) = \frac{2\mu_E\mu_G + C_1}{{\mu_E}^2 + {\mu_G}^2 + C_1} \cdot \frac{2\sigma_{EG} + C_2}{{\sigma_E}^2 + {\sigma_G}^2 + C_2} \tag{3.5}$$

其中 μ_E、μ_G 分别表示图像 E 和 G 的均值，${\sigma_E}^2$、${\sigma_G}^2$ 分别表示图像 E 和 G 的方差。σ_{EG} 代表图像 E 和 G 协方差。C_1，C_2 为常数，目的是在分母为 0 时维持稳定。通常取 $C_1 = (K_1 * L)^2$，$C_2 = (K_2 * L)^2$，一般地 K_1=0.01，K_2=0.03，L=255（L 表示像素值的动态范围，一般都取 255）。

$SSIM(E,G)$ 的值属于（0，1]范围内，因为值等于 1 表示两张图片完全相同，则使用 $1-SSIM(E,G)$ 计算增强图像 E 与相应的正常曝光 ground-truth 图像 G 的

中国知网 https://www.cnki.net

结构损失，关于 SSIM 的结构损失函数定义如下：

$$L_{Str} = \frac{1}{N}\sum_{i=1}^{N}(1 - SSIM(E,G)) \tag{3.6}$$

其中 N 为训练样本的数量。

3.3.3 人眼感知损失

对于图像风格化、图像超分辨率重建等任务来说，早期研究都使用了图像像素空间的 L2 损失，但 L2 损失与人眼感知损失的图像质量并不匹配，恢复出来的图像往往细节表现不佳。在相关的研究中，L2 损失逐渐被人眼感知损失取代。人眼感知损失也被称为 Perceptual 损失，与 L2 损失的不同之处在于，其所计算的空间不再是图像空间，而是特征空间。低照度图像增强与图像风格化以及图像超分辨率等任务类似，所以本文也使用人眼感知损失来改善同样的问题。参考 SRGAN[49]中的想法，并使用相似的策略来指导模型的训练。基本思想是采用特征提取，如果增强图像与 ground-truth 是相似，则经过特征提取后也应相似。

由于在大型数据集上训练的 VGG[44]具有良好的结构和行为表现，因此选择 VGG19 网络作为特征提取器。特别地，基于预训练的 VGG-19 网络的第三个模块中 ReLU 激活层的输出来定义人眼感知损失。为了测量增强图像的表征与 ground-truth 之间的差异。感知损失的定义如下：

$$L_{VGG/i} = \frac{1}{W_i H_i C_i}\left\|\phi_i(E) - \phi_i(G)\right\|_2^2 \tag{3.7}$$

其中 E 和 G 分别表示增强图像和 ground-truth，而 W_i，H_i，C_i 描述 VGG19 网络中各个特征图的尺寸。此外，ϕ_i 表示 VGG-19 网络中第 i 个卷积层提取的特征图，i 取 4，$\|\cdot\|_2$ 表示 L2 范数。

3.3.4 区域损失

L1 损失、结构损失和人眼感知损失函数都是将图像作为一个整体，但对于弱光增强任务而言，需要将更多的注意力投到弱光区域，才能更好地改善图像的光照情况。因此本文参考了 MBLLEN[50]中的想法，定义了区域损失，目的是平衡图像中低光区域和其他区域之间的增强程度。主要思路是将低光区域与图

中国知网 https://www.cnki.net

像的其他部分分开。本文遵照 MBLLEN 方法的设定，在所有像素中选择前 40% 最暗的像素来近似图像的低光区域，剩余部分作为高光区域。最后，区域损失定义如下：

$$L_{Region} = w_L \frac{1}{m_L n_L} \|E_L - G_L\|_2^2 + w_H \frac{1}{m_H n_H} \|E_H - G_H\|_2^2 \tag{3.8}$$

其中 E_L 和 G_L 是增强图像和 ground-truth 的低光区域，而 E_H 和 G_H 是图像的其余部分，$w_L = 4$，$w_H = 1$，因为计算区域损失是将图像转化为灰度图后再计算的，因此 $m_L n_L$ 表示弱光图像的大小，而 $m_H n_H$ 表示其余部分图像的大小，$\|\cdot\|_2$ 表示 L2 范数。

3.4 实验结果及分析

3.4.1 实验前提

本文的实验前提分为四个部分，分别是数据集简介、网络训练参数配置、定量评价方法和实验对比方法介绍。

1. 数据集简介

本文实验的数据集来源于 MBLLEN[50]基于 PASCAL VOC 图像数据集合成的大量低光图像。其中训练集有 16925 张，验证集 56 张和测试集 144 张，合成方法是对普通图像的每个通道进行随机 Gamma 调整以产生低光图像，处理过程可以表示为 $I_{out} = C \times I_{in}^{\gamma}$，其中 C 是一个常数，由图像中最大像素强度决定，γ 服从均匀分布 U (2，3.5)。并且还考虑了噪声，将峰值等于 200 的泊松噪声添加到低光图像中，合成分辨率为 256×256 的彩色数据集。

为了验证本文网络模型的鲁棒性，实验还选用了一个包括多个场景类别的数据集 MIT-Adobe FiveK[51]，并使用经过专家 B 调整后照片作为 ground-truth，整个数据集总的包括 5000 张数据集，随机地从中挑选 700 张作为测试集和验证集，其中测试集和验证集均分这 700 张数据集，剩下的 4300 张作为训练集使用，MIT-Adobe FiveK 中所有图像均被裁剪为 400×600 的分辨率，并转换为便携式网络图形（Portable Network Graphics，PNG）格式。

本文使用了几何变换方法对图像进行增强，包括翻转，旋转，裁剪等操作

中国知网 https://www.cnki.net

来增加训练图像的多样性。在送入网络之前，两个数据集所有像素值均被规范至[0，1]之间。

2. 网络训练参数配置

训练低照度图像增强网络的硬件平台、操作系统、语言环境、深度学习架构、优化器、学习率、训练迭代次数等参数如表 3.2 所示。另外设置光照仿射变换块 M=5，多分支残差并行块 N=5，这是通过多次消融实验（小节 3.4.4）后获得的最佳配置。

表 3.2 低照度增强网络的训练细节

项目	配置
硬件平台	显卡 A100-SXM4
操作系统	ubuntu 18.04 64 位
语言环境	Anaconda 配置的 Python3.6
深度学习架构	TensorFlow-gpu 2.4
优化器	Adam 优化器，β1 = 0.9，β2 = 0.999
批大小	16
初始学习率	0.002
学习率衰减	每经过一个 epoch，学习率乘以 0.99
训练迭代次数	50 个 epoch

3. 定量评价方法简介

本文使用均方误差、峰值信噪比、结构相似性、信息保真度准则[52]、视觉信息保真度[53]和自然图像评价员[54]六种图像质量评价指标对本文的结果进行综合评价，接下来对这六种图像质量评价进行介绍。

1) 均方误差

均方误差（Mean Squared Error，MSE）也被称为 L2 损失或欧氏距离，它以误差的平方和作为距离。假设有尺寸为 H 、W 的增强图片 E 与目标图片 G ，其中 $E_{i,j,k}$ 、$G_{i,j,k}$ 分别代表图片 E 、G 的 k 通道中（i, j ）位置的像素值，定义两张图片的均方误差为：

$$\mathrm{MSE} = \frac{1}{HWC}\sum_{i=1}^{H}\sum_{j=1}^{W}\sum_{k=1}^{C}(E_{i,j,k} - G_{i,j,k})^2 \tag{3.9}$$

2) 峰值信噪比

中国知网 https://www.cnki.net

峰值信噪比（Peak Signal to Noise Ratio，PSNR），是一种在计算机视觉中广泛用于图像质量的客观评价方法，在图像增强任务中用于衡量增强后的图像与正常曝光图像之间的差异。PSNR 值的单位是 dB，常常借助均方误差 MSE 帮助定义，PSNR 值越大，表明增强后的图像质量越好，两张图片的 PSNR 定义为：

$$\mathrm{PSNR} = 10 \cdot \log_{10}(\frac{I_{\max}{}^{2}}{\mathrm{MSE}}) = 20 \cdot \log_{10}(\frac{I_{\max}}{\mathrm{MSE}}) \tag{3.10}$$

其中 $I_{\max}$ 表示图像中像素点的最大值，如果是 8 位图像，$I_{\max}$=255。

3) 结构相似性

结构相似性（Structural Similarity，SSIM），是衡量图像相似度的指标之一，对于图像的绝对误差，比 PSNR 更加敏感。SSIM 值的范围属于（0，1]，和 PSNR 指标一样，值越大就表明增强图像越接近目标图像。公式如式 3.5 所示。

4) 信息保真度准则

信息保真度准则 IFC（Information Fidelity Criterion，IFC）通过计算增强图像与目标图像之间的互信息来衡量增强图像的质量优劣。在低照度任务中，信息保真度一定程度地拓展了图像与人眼之间的联系，但是该方法与 PSNR 指标一样对于图像的结构信息不敏感。

5) 视觉信息保真度

视觉信息保真度（Visual Information Fidelity，VIF）与 IFC 一样，都是通过计算增强图像与目标图像之间的互信息实现。

6) 自然图像评价员

尽管图片的 PSNR 或 SSIM 值很高，但图像的纹理细节却不一定符合人眼的视觉习惯。因此，Anish 等人[54]在 2012 年提出了一种更有效的图像重建质量的指标自然图像评价员（Natural Image Quality Evaluator，NIQE）。这是一种完全脱离了对目标图像依赖的质量评价方法，因为无依赖，因此应用较为广泛。NIQE 基于一组“质量感知”特征，并将其拟合到多元高斯（Multivariate Gaussian，MVG）模型中。质量感知特征源于一个简单但高度正则化的自然图像统计（Natural Scene Statistic，NSS）模型。则增强图像的 NIQE 指标为：增强图像中提取的 NSS 特征的 MVG 模型与自然图像中提取的质量感知特征的 MVG 模型之间的距离。

4. 实验对比方法介绍

中国知网 https://www.cnki.net

虽然本文方法是基于深度学习技术实现的，但为了验证本文方法的有效性，不仅与最近基于深度学习技术的方法 GLADNet[46]、RetinexNet[55]、MBLLEN[50]和 DeepUDP[47]进行比较，还与非深度学习的方法 MF[56]、LIME[57]和 BIMEF[58]进行比较。为了更加公平地比较，本文使用作者提供的公开源码和推荐的参数设置来生成结果。对于 GLADNet、RetinexNet 和 MBLLEN，进一步在合成数据集和 MIT-Adobe FiveK 数据集[51]上重新训练他们的模型，目的是使他们的模型产生可能的最佳结果。对于 DeepUDP 方法，由于作者公开的源码中不包括训练部分的代码，但提供了训练好的模型，直接下载他们训练好的模型进行测试。

3.4.2 主观评定

图 3.2 至图 3.5 中展示了本文的方法与其他七种方法的比较结果。在合成数据集上测试的结果如图 3.2、图 3.3 所示，在 MIT-Adobe FiveK 数据集上测试的结果如图 3.4、图 3.5 所示。为了表示经过本文方法处理后的图像拥有更少的噪声，于是在两个数据集中都加入了 5%的高斯噪声，其中在合成数据集和 Fivek 数据集上加入噪声后的结果如图 3.3、图 3.5 所示。为了使细节对比更加明显，本文还将结果中的部分细节进行放大展示，被选中的放大展示的区域在 Input 图像中用白框圈出。

图 3.2 对合成低光图像增强的视觉比较

中国知网 https://www.cnki.net

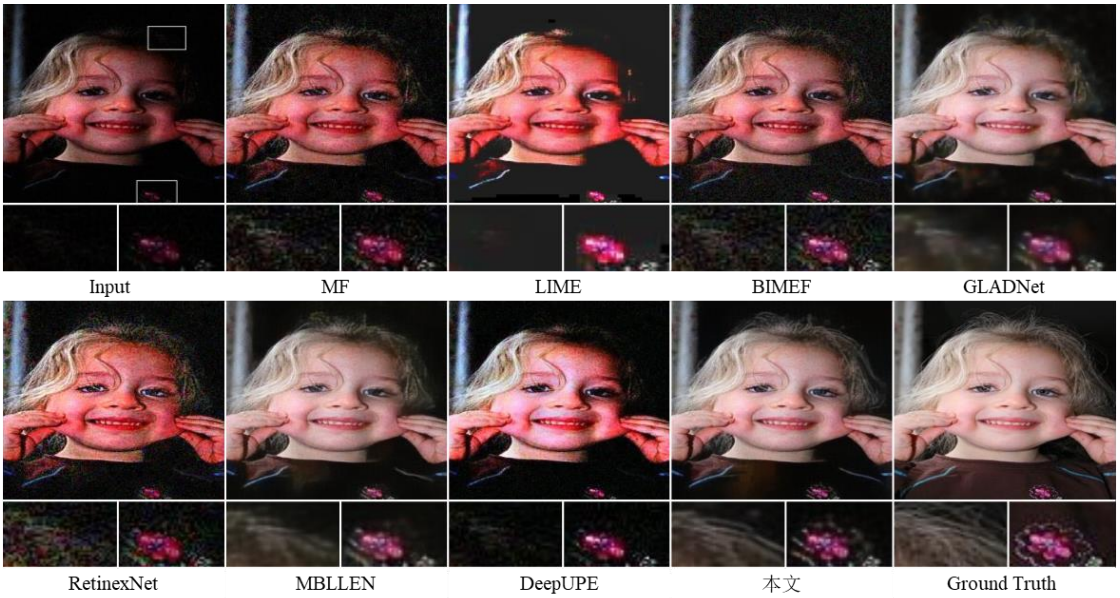

图 3.3 对合成低光图像（带有噪声）增强的视觉比较

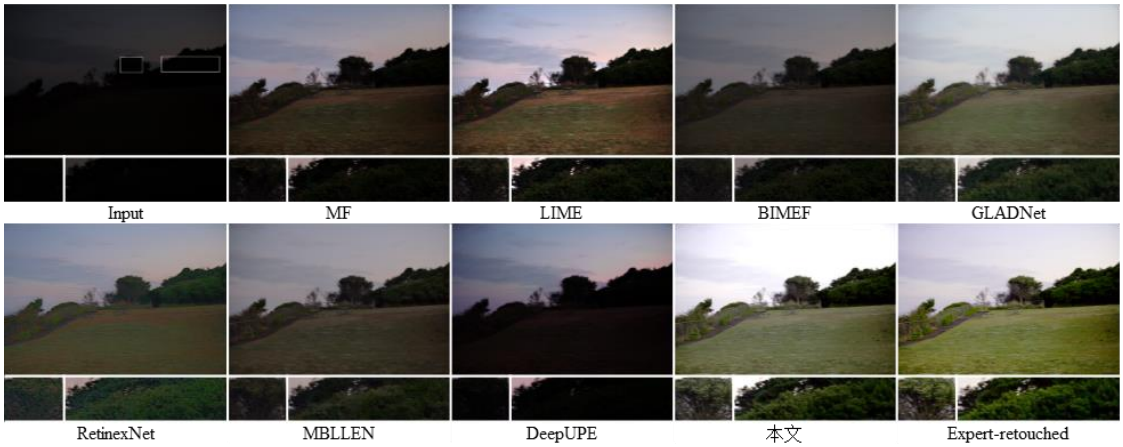

图 3.4 对 MIT-Adobe FiveK 增强的视觉比较

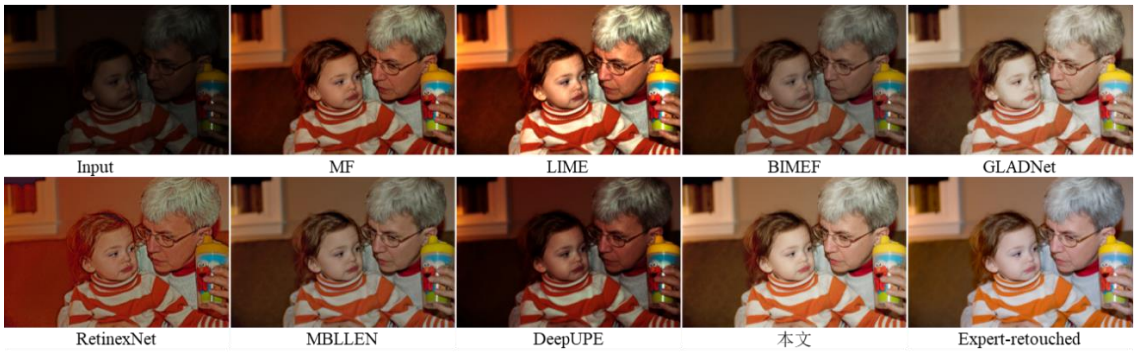

图 3.5 对 MIT-Adobe FiveK（带噪声）增强的视觉比较

通过比较四组图像，可以看出本文的方法可以得到比其他方法更好的视觉效果，包括增强后的图像颜色更加自然，拥有良好的亮度、对比度和更少的伪影和噪声，使得图像看起来更加清晰。

中国知网 https://www.cnki.net

3.4.3 客观评定

在下文表中，“↑”表示数值越高结果越好，“↓”表示数值越低结果越好，其中加黑、斜体分别表示最佳、次佳结果。对本文低照度图像增强方法的结果使用定量评价指标 PSNR 、SSIM 、IFC 、VIF、NIQE 和 MSE 进行评价，结果如表 3.3 至表 3.6 所示，从这四个表中可以看出，无论是在合成的低光图像数据集（包括添加噪声）还是 MIT-Adobe FiveK 数据集（包括添加噪声），本文几乎取得了最佳的结果，唯独在评价指标 NIQE 下没有完全取得最佳，但是与最佳结果并没有很大的差距。

表 3.3 对合成低光图像增强的定量评价

方法	PSNR↑	SSIM↑	IFC↑	VIF↑	NIQE↓	MSE↓
MF	17.635	0.671	2.817	0.388	5.194	0.0204
LIME	15.799	0.634	2.701	0.338	6.405	0.0273
BIMEF	19.050	0.739	3.068	0.427	4.945	0.0154
GLADNet	*26.111*	0.868	3.649	0.503	4.231	*0.0031*
RetinexNet	18.832	0.691	2.628	0.334	5.552	0.0143
MBLLEN	25.603	*0.902*	*3.739*	*0.519*	*4.065*	0.0050
DeepUPE	17.484	0.626	2.963	0.399	5.267	0.0200
本文	**26.724**	**0.908**	**3.879**	**0.526**	**4.008**	**0.0027**

表 3.4 对合成低光图像（带噪声）增强的定量评价

方法	PSNR↑	SSIM↑	IFC↑	VIF↑	NIQE↓	MSE↓
MF	17.545	0.642	2.460	0.328	7.641	0.0203
LIME	17.707	0.696	2.283	0.333	6.537	0.0182
BIMEF	18.887	0.701	2.631	0.357	6.246	0.0152
GLADNet	*25.601*	0.883	3.282	0.476	4.345	0.0033
RetinexNet	18.414	0.612	2.358	0.298	9.537	0.0155
MBLLEN	25.533	*0.888*	*3.360*	*0.486*	**4.008**	0.0035
DeepUPE	17.413	0.641	2.651	0.357	5.550	0.0204
本文	**26.103**	**0.892**	**3.439**	**0.496**	*4.141*	**0.0031**

在表 3.3 中，PSNR 、SSIM 、IFC 、VIF（下文简称前四个指标）比次佳的结果提高了 0.613、0.6%、0.14 和 4.3%，NIQE 、MSE（下文简称后两个指标）比次佳的结果降低了 0.057 和 0.4‰。在表 3.4 中，前四个指标比次佳的结果提高了 0.502、0.4%、0.079 和 1.0%，后两个指标比次佳的结果降低了-0.133 和 0.2‰。在表 3.5 中，前四个指标比次佳的结果提高了 1.927、2.9%、0.965 和

中国知网 https://www.cnki.net

5.3%，后两个指标比次佳的结果降低了-0.089 和 1.4‰。在表 3.6 中，前四个指标比次佳的结果提高了 1.416、1.4%、0.999 和 5.0%，后两个指标比次佳的结果降低了-0.148 和 0.9‰。

表 3.5 对 MIT-Adobe FiveK 增强的定量评价

方法	PSNR↑	SSIM↑	IFC↑	VIF↑	NIQE↓	MSE↓
MF	18.376	0.874	5.833	0.499	5.211	0.207
LIME	16.379	0.825	5.889	0.506	5.320	0.0276
BIMEF	18.591	0.882	7.085	0.519	4.838	0.0226
GLADNet	*24.575*	*0.920*	5.634	0.483	4.562	*0.0040*
RetinexNet	18.013	0.853	4.540	0.403	5.299	0.0183
MBLLEN	20.165	0.810	*7.212*	*0.527*	**4.358**	0.0129
DeepUPE	17.801	0.802	6.406	0.478	4.872	0.0259
本文	**26.502**	**0.949**	**8.177**	**0.576**	*4.473*	**0.0026**

表 3.6 对 MIT-Adobe FiveK（带噪声）增强的定量评价

方法	PSNR↑	SSIM↑	IFC↑	VIF↑	NIQE↓	MSE↓
MF	18.376	0.874	5.834	0.499	5.211	0.207
LIME	17.280	0.777	3.649	0.405	4.465	0.0238
BIMEF	18.590	0.882	*7.084*	0.520	4.837	0.0226
GLADNet	*24.445*	*0.918*	5.521	0.476	*4.541*	*0.0041*
RetinexNet	17.119	0.842	4.798	0.405	5.334	0.0222
MBLLEN	20.074	0.909	7.178	*0.526*	**4.399**	0.0136
DeepUPE	17.800	0.802	6.406	0.477	4.871	0.0259
本文	**25.861**	**0.946**	**8.177**	**0.576**	4.547	**0.0032**

表 3.7 内存性能表现和测试运行时间

方法	params/M	time/s
MF	-	0.575
LIME	-	1.2906
BIMEF	-	0.1757
GLADNet	0.931	0.0328
RetinexNet	**0.444**	**0.0288**
MBLLEN	0.450	0.0753
DeepUPE	0.998	0.047
本文	1.801	0.0918

除了对结果质量的比较，本文还在 MIT-Adobe FiveK 数据集上对比不同算

中国知网 https://www.cnki.net

法的测试运行时间以及内存性能表现，通过参数量来描述所需内存，结果如表 3.7 所示。由于 MF、LIME 和 BIMEF 方法没有使用到深度学习技术，所以这三个方法的参数量为空。本文方法的数量和运行时间虽然都没有达到最优，但其参数量和时间的增加在可接受范围内。

3.4.4 消融实验

低照度图像增强网络模型共由光照估计、光照仿射变换和细节重建三个模块构成，虽然各个模型是为了解决不同的问题而设计的，但是为了了解到底是哪一个模块对低照度图像增强的贡献最大，所以在 MIT-Adobe FiveK 数据集[51]上依次对光照估计、光照仿射变换和细节重建模块融合进行了实验，实验结果如表 3.8 所示。Our-1 表示仅使用光照估计模块进行低照度图像增强后的结果，Our-2 表示光照估计模块加上光照仿射变换模块对自照度图像增强后的结果，本文表示三个模块共同的结果。此外，为了找到最佳的光照仿射变换块的数量 M，对 M 进行控制变量实验，也就是表中的 Our-2 (M=1 至 7)，经过实验分析，最终设置 M=5。从表 3.8 中可以得出，光照仿射变换模块对整个低照度图像增强网络起到的作用最明显。

表 3.8 本文方法不同模块对 MIT-Adobe FiveK 增强的定量评价

方法	PSNR↑	SSIM↑	IFC↑	VIF↑	NIQE↓	MSE↓
Our-1	20.448	0.683	0.735	0.254	12.776	0.0103
Our-2(M=1)	26.089	0.947	8.083	0.575	4.559	0.0030
Our-2(M=2)	26.132	0.947	8.197	0.577	4.552	0.0030
Our-2(M=3)	26.249	0.948	8.204	**0.579**	4.570	0.0030
Our-2(M=4)	26.325	0.947	8.262	0.574	4.556	0.0029
Our-2(M=5)	26.351	0.948	**8.272**	**0.579**	4.549	0.0028
Our-2(M=6)	26.345	0.947	8.258	0.576	4.547	0.0028
Our-2(M=7)	26.348	0.948	8.162	0.577	4.539	0.0027
本文	**26.502**	**0.949**	8.178	0.576	**4.473**	**0.0026**

3.5 本章小结

由于图像在拍摄中容易受到各种因素的影响，拍摄的图像可能存在光线微弱、逆光、噪声等问题，对进行光照估计任务不利，于是提出了融合多分支残差与仿射变换的低照度图像增强方法，针对低照度图像，设计了三个模块来解决它们，分别是光照估计模块、光照仿射变换模块和细节重建模块。为了从主

中国知网 https://www.cnki.net

客观方面都能提高图像的质量，运用了 L1 损失、结构损失、人眼感知损失和区域损失。并在两个数据集上进行实验，使用主观评价与各种评价指标评价本文的方法，结果表明，本文方法对低照度图像进行增强的效果提升最明显，能从不同方面改善图像质量，包括亮度、对比度增强，去除伪影和噪声，同时也提高了增强后图像的精度。

中国知网 https://www.cnki.net

第四章 基于图像的球形高斯光照估计

4.1 引言

从视野范围有限的图像中估计出整个场景的照明分布是一个复杂的问题。因为一副图像是照明分布（Illumination）、场景几何形状（Shape）、物体的材质信息（Material）以及相机参数（Camera）等多个信息相交互的结果，可表示为：

$$\text{Image}=\text{ComplexInteraction}(\text{Illumination, Material, Shape, Camera}) \tag{4.1}$$

在基于图像的光照估计方法中，一般都假设视点固定，则可从原图像，物体材质和形状推出光照，即 $(\text{Image, Material, Shape}) \rightarrow \text{Illumination}$，然而，在物体材质（Material）以及几何形状（Shape）信息未知的情况下，从图像（Image）逆向推出光照（Illumination）依然是一个棘手的问题。

为了降低问题求解难度，传统方法常常增加输入信息的数量或简化光照模型的规模。一部分工作尝试借用额外的输入信息辅助估计场景光照，例如深度信息、几何信息、额外的输入图片、先验知识等等，这类方法对于输入信息有一定的要求。另一部分工作通过使用低维的光照表示模型来简化光照估计问题，例如使用球形谐波函数（Spherical Harmonis，SH）、球面高斯函数（Spherical Gaussian，SG）来拟合场景光照、使用小波函数近似场景光照、使用有限的点光源几何近似场景光照等等。无论是增加输入信息还是使用简化的光照模型，传统的光照估计方法均具有一定的局限性。

近年来，深度学习在多种计算机视觉上运用广泛，用于分割、识别、分类的神经网络层出不穷。一些研究者也尝试将深度学习方法应用在光照估计问题中，和传统方法类似，使用基于深度学习求解光照估计的问题有时也会借助一些额外的信息。但将传统方法中复杂的、难以求解的算法步骤替换为用深度学习的求解后，往往能取得更好的结果，这得益于规模不断扩大、质量不断增加的训练数据集。同时也会使用与传统方法中相同的光照表示模型，例如球形谐波（Spherical Harmonics，SH）函数[24~27, 31]，球面高斯（Spherical Gaussian，SG）函数[33, 59]。然而 SH 是一种全局表示，对其参数的变化过于敏感，低阶的球形谐波函数只能表示非常低频的信号，但使用高阶的 SH 函数能保存高频信息时会产生振铃和伪影现象，因为当一侧有强光时，在另一侧就会产生负的波瓣，其值就会非常低甚至是负值。与 SH 函数不同，本文使用具有局部支持的 SG 函

中国知网 https://www.cnki.net

数，并且可以通过参数调整很好地模拟照明中的高频细节，同时由低维 SG 函数表示的环境光照也可直接重建完整的光照贴图。

因此，本文基于深度学习技术， 从单个有限视野 LDR 照片中推测 SG 参数，不仅如此，还结合图像分析方法将光照估计作为其目标之一，连同其他的目标信息一并预测出来，比如几何信息（法线），材质（反照率，粗糙度）等。联合预测图像的其他本征属性可以在几个目标之间相互促进，同时提高光照预测的效果。原因是图像的形成是场景信息与光照信息的结合，将场景的其它属性预测出来可以为光照预测提供很好的先验知识，这些先验知识不仅可以降低网络预测难度，还可以提高网络预测效果，总体的研究方案如图 4.1 所示。

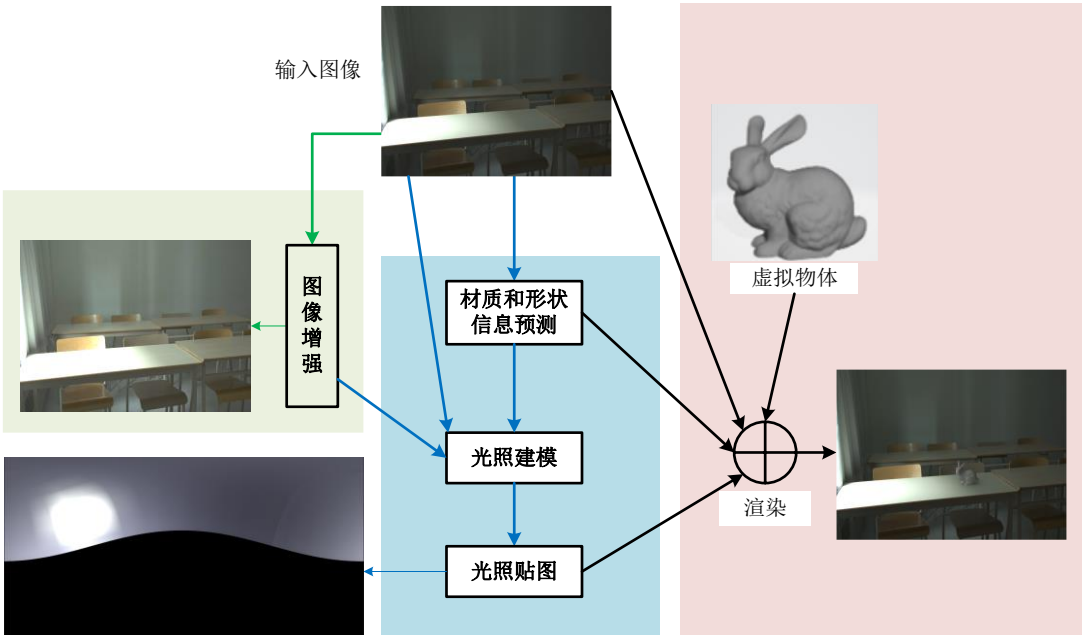

图 4.1 方案概览

与本文方法不同，一些工作[32, 60, 61]尝试对图像进行本征属性分解，本征图像分解是逆向渲染的子问题，在假设场景信息的情况下，单个图像被分解为反照率图和着色图，本征图像分解方法不会显式恢复几何形状或照明，而是将它们组合在一起作为着色。相比之下，本文并不假设场景信息，对于漫反射图像和镜面反射图像都可以表示，在 AR/VR 中有更广泛的应用。

令 A、N 和 R 分别表示空间变化的漫反射反照率、法线和粗糙度，$l_{i,j}=l(\varphi_i,\theta_j)$ 是在上半球上采样的一组光方向，光照贴图 L_i，v 为观察方向，dw 是一个微分立体角，漫反射图像 I_d 和镜面反射图像 I_s 可表示为：

中国知网 https://www.cnki.net

$$\begin{cases} I_d = \sum_{i,j} f_d(v, l_{i,j}; A) L_i \cos(\theta_j) dw \\ I_s = \sum_{i,j} f_s(v, l_{i,j}; R, N) L_i \cos(\theta_j) dw \end{cases} \tag{4.2}$$

本文使用基于物理驱动的微表面模型（microfacets）来表示所有场景的信息，关于微表面模型更详细的内容请参见 2.3.4 节，该模型可表示为：

$$f(l, v; A, N, R) = k_d f_d(v, l; A) + k_s f_s(v, l; N, R) \tag{4.3}$$

$$f_d(v, l; A) = \frac{A}{\pi} \tag{4.4}$$

$$f_s(v, l; N, R) = \frac{D(w_h, R) F(v, w_h) G(l, v, N, R)}{4(N \cdot l)(N \cdot v)} \tag{4.5}$$

结合式 4.2 与 4.3 可知，要实现一幅图像的逆向渲染，需要得到这幅图像的反照率 A 法线 N 粗糙度 R 和光照贴图 L，因此，本文通过基于深度神经网络学习到的先验知识来解决这个问题，设计了两个模块，使用材质和形状估计模块（MSNet）推测反照率、法线、粗糙度，球形高斯光照建模模块（SGNet）推测可转化成光照贴图的参数。算法处理步骤如表 4.1 所示。

表 4.1 光照估计算法步骤

算法 4.1	光照估计算法
输入：	彩色图像 I，增强图像 E，$I \in R^3, E \in R^3$
输出：	光照贴图 L，$L \in R^{WH \times 3 \times 8 \times 6}$
1	伽马矫正，$I = I^{1/2.2}$
2	$\overline{A}, \overline{N}, \overline{R} = \mathrm{MSNet}(I)$，$\overline{A} \in R^3, \overline{N} \in R^3, \overline{R} \in R^1$
3	$\overline{\alpha_i}, \overline{\lambda_i}, \overline{u_i} = \mathrm{SGNet}(I, E, \overline{A}, \overline{N}, \overline{R})$，$\overline{\alpha_i} \in R^{36}, \overline{\lambda_i} \in R^{12}, \overline{u_i} \in R^{36}$
4	线性转换，$\overline{\alpha_i} = \tan(\frac{\pi}{2}\overline{\alpha_i}), \overline{\lambda_i} = \tan(\frac{\pi}{2}\overline{\lambda_i})$
5	扩展维度，$\overline{\alpha_i}[12,3,w,h,1,1] = \overline{\alpha_i}[36,w,h]$， $\overline{\lambda_i}[12,1,w,h,1,1] = \overline{\lambda_i}[12,w,h]$，$\overline{u_i}[12,3,w,h,1,1] = \overline{u_i}[36,w,h]$
6	扩展维度，$\overline{\alpha_i}[12,3,w,h,8,16] = \overline{\alpha_i}[12,3,w,h,1,1]$， $\overline{\lambda_i}[12,1,w,h,8,16] = \overline{\lambda_i}[12,1,w,h,1,1]$， $\overline{u_i}[12,3,w,h,8,16] = \overline{u_i}[12,3,w,h,1,1]$
7	$L = \sum_{i=1}^{n} \alpha_i e^{\lambda_i (u_i \cdot l_{i,j} - 1)}$，$l_{i,j} \in R^{12,3,W,H,8,16}$

中国知网 https://www.cnki.net

4.2 图像材质和形状估计

本文将 I 视为单张 Gamma 矫正的低动态范围输入图像，Gamma 矫正方法参考 2.1.1 节，A、N、R 分别是 ground-truth 的反照率、表面法线和粗糙度图像，则使用 $\overline{A}$、$\overline{N}$、$\overline{R}$ 代表材质和形状估计模块 MSNet 的预测输出。材质和形状估计模块可表示为：

$$\overline{A}, \overline{N}, \overline{R} = \mathrm{MSNet}(I) \tag{4.6}$$

4.2.1 网络模型

由于图像的材质和形状与原始的输入图像有着紧密的联系，而 U-net[41]网络能够很好地保持网络中浅层特征与深层特征的联系，于是本文使用一种基于 U 型网络的结构来预测输入图像 I 的材质和形状，该网络的名称是 MSNet，其网络结构和处理流程如图 4.2 所示，更详细的参数参照表 4.2。受 Li 等人[33]的启发，本文设计了一个基于残差跳级连接的编解码器网络，使用单个共享编码器捕捉图像的材质和形状之间的相关性，使用三个解码器从单个共享编码器中获得漫反射反照率 $\overline{A}$、粗糙度 $\overline{R}$ 和法线 $\overline{N}$。

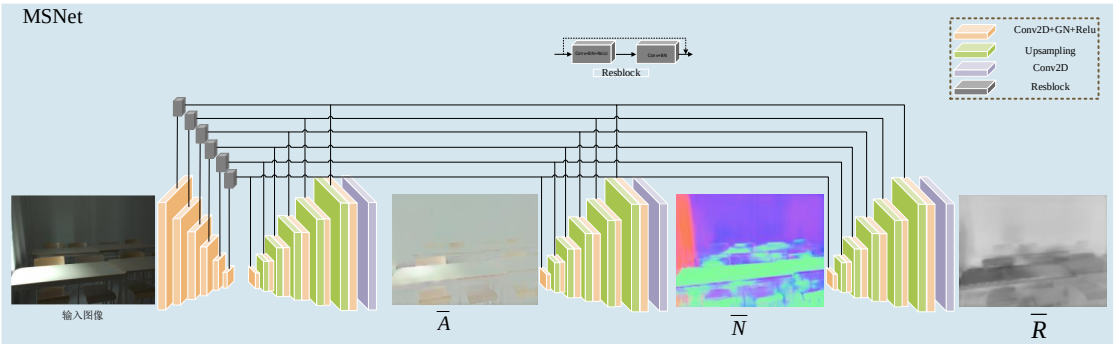

图 4.2 材质和形状估计模块（MSNet）网路结构

编码器中使用了 6 个卷积层，前 5 个卷积核大小为 4，步长为 2，所以在前 6 个卷积层中，每经过一个卷积层，分辨率就降为原来的二分之一。

在解码器中，使用双线性插值来实现上采样，即作为上采样层，每个解码器是由 6 个上采样层和 7 个卷积层组成，3 个解码器的前 6 层结构一致，唯一的区别是最后一个卷积层的输出不一致，反照率 $\overline{A}$ 和法线 $\overline{N}$ 的输出通道为 3，粗糙度 $\overline{R}$ 为 1。与传统的 U 型结构最大的区别的是，本文使用残差跳层连接代替简单的跳层连接，这种结构类似于多分支拓扑[43]，多分支拓扑在许多基准网络[42, 44]中表现优异，使用类似于多分支拓扑的残差跳层连接用于更好地保留细节，

中国知网 https://www.cnki.net

残差块的跳层连接是相加（add），其他特征融合方法是拼接(concatenate)，总共使用了 6 个残差块（Resblock），这 6 个残差块的输入分别是编码器中 E_X6、E_X5、E_X4、E_X3、E_X2、E_X1，为了使残差块的输出与解码器中的输出所占比重一样，本文设置残差块的输出通道数与输入通道数相同，其中解码器的输出 D_X1、D_X2、D_X3、D_X4、D_X5 分别与残差块 E_X5、E_X4、E_X3、E_X2、E_X1 拼接（concatenate）在一起。

无论是编码器还是解码器中的卷积层，本文没有使用批处理归一化（Batch Normalization，BN），而是使用了分组归一化(Group Normalization，GN)，因为 GN 在很小的批次（batch size）时比 BN 更稳定的，由于本文训练使用的输入数据集是 HDR 图像，设置的 batch size 比较小，选用 GN 更为合适。除此之外，每个卷积层的后面都带有 ReLU 激活函数，当然编码器的最后一层除外。

表 4.2 MSNet 网络结构

	操作	卷积核	输出分辨率	输出通道	步长	填充
	输入	-	320×240	3	-	-
E_X1	Conv2D+GN+ReLU	4×4	160×120	64	2	0
E_X2	Conv2D+GN+ReLU	4×4	80×60	128	2	0
E_X3	Conv2D+GN+ReLU	4×4	40×30	256	2	0
E_X4	Conv2D+GN+ReLU	4×4	20×15	256	2	0
E_X5	Conv2D+GN+ReLU	4×4	10×7	512	2	0
E_X6	Conv2D+GN+ReLU	3×3	10×7	1024	1	0
	Resblock	-	10×7	1024	1	1
D_X1	Conv2D+GN+ReLU	3×3	10×7	512	1	1
	Concatnate	-	10×7	1024	-	-
	Upsampling	-	20×15	-	-	-
D_X2	Conv2D+GN+ReLU	3×3	20×15	256	1	1
	Concatnate	-	20×15	512	-	-
	Upsampling	-	40×30	-	-	-
D_X3	Conv2D+GN+ReLU	3×3	40×30	256	1	1
	Concatnate	-	40×30	512	-	-
	Upsampling	-	80×60	-		
D_X4	Conv2D+GN+ReLU	3×3	80×60	128	1	1
	Concatnate	-	80×60	256	-	-
	Upsampling	-	160×120	-	-	-
D_X5	Conv2D+GN+ReLU	3×3	160×120	64	1	1
	Concatnate	-	160×120	128	-	-
	Upsampling	-	320×240	-	-	-
D_X6	Conv2D+GN+ReLU	3×3	320×240	64	1	1
D_X7	Conv2D	3×3	320×240	3/3/1	1	1

中国知网 https://www.cnki.net

4.2.2 损失函数

为了更好地训练 MSNet，本文对于法线和粗糙度使用 L2 损失，反照率使用 L1 损失，使用 L_N、L_R、L_A 分别表示法线、粗糙度和反照率的损失。此外，除了对像素反照率值进行监控外，还采用了多尺度梯度项，并引入反照率一致性项 $L_{consist}$ 来监督反照率估计，损失函数中使用了输入图像的第一个通道的两个分割掩模（M_1, M_2），M_1 的值从 0.49 到 0.51，M_2 的值超过 0.9 的部分：

$$L_{MS} = \alpha_A L_A + \alpha_N L_N + \alpha_R L_R \tag{4.7}$$

其中:

$$L_N = \left\| (N - \overline{N}) \odot (M_1 + M_2) \right\|_2^2 \tag{4.8}$$

$$L_R = \left\| (R - \overline{R}) \odot M_2 \right\|_2^2 \tag{4.9}$$

$$L_A = \left\| (A - \overline{A}) \right\|_1 + 9.0 \times \sum_m \left\| \nabla A_m - \overline{\nabla A_m} \right\|_1 + 9.0 \times L_{consist} \tag{4.10}$$

$$L_{consist} = \sum_{i \in \forall k} \left\| (A_i - A_k) - (\overline{A_i} - \overline{A_k}) \right\|_1 \tag{4.11}$$

其中 α_A，α_N，α_R 分别表示反照率损失 L_A、法线损失 L_N、粗糙度损失 L_R 的权重；m 代表不同尺寸的图像；$L_{consist}$ 被用来关注更相似于标签的反照率像素；$\forall k$ 是每次迭代随机选择的一个关键像素，$\forall k = \{i \mid \|A_i - A_k\|_1 < \xi_A\}$，$\xi_A$ 是一个微分阈值。

在训练好 MSNet 后，本文估计输入图像 I 的材质（$\overline{A}$、$\overline{R}$）和形状（$\overline{N}$），作为训练 SGNet 的先验。

图 4.3 蒙特卡洛积分、2 阶球谐函数与球面高斯渲染结果

4.3 球形高斯光照建模

中国知网 https://www.cnki.net

渲染虚拟信息与真实环境场景匹配需要预测图像中每个像素的空间变化照明。球面谐波是一种紧凑的照明表示，但当一侧有强光时，在另一侧就会产生负的波瓣，表现出振铃现象，如图 4.3 所示，当环境中出现大面积的明亮光源区域时，球面高斯的效果明显更胜一筹。于是，本文用一组均匀分布在球体上的 SG 函数对室内照明进行建模。 在数学上，SG 函数定义为：

$$G(v,\alpha,\lambda,u)=\alpha e^{\lambda(u\cdot v-1)} \tag{4.12}$$

其中 $v\in S^2$ 是沿球体的方向；$\alpha\in R^3$ 是波瓣的振幅或者强度，是波瓣波峰顶部的高度值，控制 RGB 不同颜色通道的变化；$\lambda\in(0,+\infty)$ 是波瓣的带宽，增加 λ 时，波瓣会变得更纤细，也就意味着越是远离波瓣轴衰减的越快；u 是波瓣的轴向或方向，控制波瓣在球面的位置并且指向波瓣的中心。

给定一组权重 $W=\{\alpha_1,\cdots,\alpha_n\}$，一组带宽 $\Lambda=\{\lambda_1,\cdots,\lambda_n\}$，以及一组轴中心 $C=\{u_1,\cdots,u_n\}$，对于任意球面函数 $L(v)$，计算其积分可以得到球面高斯的总“能量”， 对光照的计算很有用，例如环境照明，可以在 SG 展开中表示为：

$$L(v)\approx\sum_{i=1}^{n}G(v;\alpha_i,\lambda_i,u_i)=\sum_{i=1}^{n}\alpha_i e^{\lambda_i(u_i\cdot v-1)} \tag{4.13}$$

每个球形高斯瓣由 6 维参数 $\{\alpha_i,\lambda_i,u_i\}$ 表示，考虑到性能和准确性之间的权衡，本文使用 n=12 球面高斯波瓣近似（72 个参数）SG 函数。

由于照明可以通过求解过度约束的方程组从图像、材料和形状进行估计，因此本文设计了一个球形高斯网络（SGNet）来预测高斯参数 α_i、λ_i、u_i，该网络的输入是 MSNet 的输出、原图像与经过第三章增强过的图像 E 拼接（concatenate），一同构成 13 通道的输入，只有粗糙图像 $\overline{R}$ 是单通道，其它都是 3 通道。可表示为：

$$\overline{\alpha_i},\overline{\lambda_i},\overline{u_i}=\mathrm{SGNet}(I,E,\overline{A},\overline{N},\overline{R}) \tag{4.14}$$

4.3.1 网络模型

本文的 SGNet 使用了一个与 MSNet 相似的网络结构，大体的结构如图 4.4 所示，更详细的网络结构参见表 4.3。也是使用共享单个编码器的三个解码器来分别获得球形高斯参数 α_i、λ_i、u_i，唯一不同的是编码器连接到解码器不再经

中国知网 https://www.cnki.net

过残差块，而是直接跳过连接。

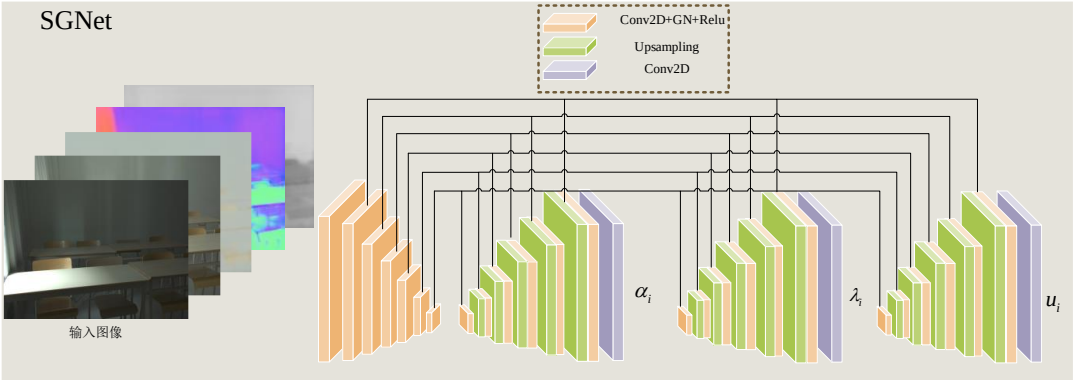

图 4.4 球形高斯光照建模模块（SGNet）的网络结构

表 4.3 SGNet 网络结构

	操作	卷积核	输出分辨率	输出通道	步长	填充
	输入		320×240	13		
	Conv2D+GN+ReLU	4×4	160×120	64	2	0
E_X1	Conv2D+GN+ReLU	4×4	80×60	128	2	0
E_X2	Conv2D+GN+ReLU	4×4	40×30	256	2	0
E_X3	Conv2D+GN+ReLU	4×4	20×15	256	2	0
E_X4	Conv2D+GN+ReLU	4×4	10×7	512	2	0
E_X5	Conv2D+GN+ReLU	4×4	5×3	512	2	0
E_X6	Conv2D+GN+ReLU	3×3	5×3	1024	1	0
D_X1	Conv2D+GN+ReLU	3×3	5×3	512	1	1
	Concatnate	-	5×3	1024	-	-
	Upsampling	-	10×7	-	-	-
D_X2	Conv2D+GN+ReLU	3×3	10×7	512	1	1
	Concatnate	-	10×7	1024	-	-
	Upsampling	-	20×15	-	-	-
D_X3	Conv2D+GN+ReLU	3×3	20×15	256	1	1
	Concatnate	-	20×15	512	-	-
	Upsampling	-	40×30	-	-	-
D_X4	Conv2D+GN+ReLU	3×3	40×30	256	1	1
	Concatnate	-	40×30	512	-	-
	Upsampling	-	80×60	-	-	-
D_X5	Conv2D+GN+ReLU	3×3	80×60	128	1	1
	Concatnate	-	80×60	256	-	-
	Upsampling	-	160×120	-	-	-
D_X6	Conv2D+GN+ReLU	3×3	160×120	128	1	1
D_X7	Conv2D	3×3	160×120	36/36/12	1	1

中国知网 https://www.cnki.net

在编码器中使用了 7 个卷积层，前 6 个卷积核大小为 4，步长为 2，所以在前 6 个卷积层中，每经过一个卷积层，分辨率就降为原来的二分之一，最后一层卷积核大小为 3，步长为 1，并且所有层的填充为 0，输出通道数依次为 64，128，256，256，512，512，1024。在解码器中，同样使用双线性插值来作为上采样层，每个解码器是由 6 个上采样层和 7 个卷积层组成，3 个解码器的前 6 层结构一致，唯一的区别是最后一个卷积层的输出不一致，振幅 α_i 和轴中心 u_i 的输出通道为 $3\times n$，带宽 λ_i 为 n，此处的 n 来源于式 4.13，取值为 12，前 6 层的输出通道数依次为 512，512，256，256，128，128，所有层的卷积核大小为 3，并且所有层的填充为 1。编码器中经过了 6 次下采样，但解码器中只经过 5 次上采样，所以最后的特征分辨率与输入图像的分辨率并不一致，因为本文的方法只是近似地表示光照信息。使用了普通的跳过连接来保留更多的细节，解码器的输出 D_X1、D_X2、D_X3、D_X4、D_X5 分别与编码器 E_X5、E_X4、E_X3、E_X2、E_X1 拼接（concatenate）在一起。无论是编码器还是解码器中的卷积层，都和 MSNet 中一样，后面都带有 GN 和 ReLu，当然最后一层除外。

4.3.2 损失函数

使用重建损失 L_{rec} 和渲染损失 L_{ren} 来计算 SGNet 损失 L_{SG}，在计算损失之前，将球面高斯参数转成高动态范围光照贴图，因为本文的标签数据是高动态范围环境贴图。对于光照估计任务，监督环境贴图对于保存高频细节非常重要，因此使用对数编码损失构建重建损失 L_{rec}。为了模拟真实的场景外观，本文参考[33]，模拟图像形成过程构造渲染损失 L_{ren}，以指导网络的训练，基本思想是通过对半球上空间变化的双向反射分布函数 f_r 和高动态范围光照贴图 L_i 的乘积进行数值积分来实现，f_r 对于不同的图像类型，表现形式不一样，本文使用微表面模型来表示 f_r，具体的理论基础可参考 2.3.4 节。SGNet 的损失函数 L_{SG} 如下：

$$L_{SG} = \alpha_{rec} L_{rec} + \alpha_{ren} L_{ren} \tag{4.15}$$

其中:

$$L_{rec} = \left\| (\log(L_i+1) - \log(\overline{L_i}+1)) \odot M_2 \right\|_2^2 \tag{4.16}$$

中国知网 https://www.cnki.net

$$L_{ren} = \left\| (I - c_s \overline{I_s} - c_d \overline{I_d}) \odot M_1 \right\|_2^2 \tag{4.17}$$

$$\overline{L_i} = L(l_{i,j};\{\alpha_i, \tan(\frac{\pi}{2}\lambda_i), \tan(\frac{\pi}{2}u_i)\}) = \sum_{i=1}^{n} \alpha_i e^{\lambda_i (u_i \cdot l_{i,j} - 1)} \tag{4.18}$$

$$\overline{I_s} = \sum_{i,j} f_s(v, l_{i,j}; \overline{A}, \overline{N}) L_i \cos(\theta_j) dw \tag{4.19}$$

$$\overline{I_d} = \sum_{i,j} f_d(v, l_{i,j}; \overline{R}, \overline{N}) L_i \cos(\theta_j) dw \tag{4.20}$$

其中α_{rec}、α_{ren}分别表示重建损失L_{rec}和渲染损失L_{ren}的权重，掩膜M_1和M_2与 4.3.2 节的一致，c_s和c_d是使用最小二乘回归计算的正比例因子，设$l_{i,j} = l(\varphi_i, \theta_j)$是在上半球上采样的一组光方向，本文采样了 16×8 个照明方向，通过式 4.13 可得到球面高斯计算的环境贴图L_i，v为观察方向，dw是一个微分立体角，通过渲染方程计算得漫反射图像$\overline{I_d}$和镜面反射图像$\overline{I_s}$；$\overline{A}$、$\overline{N}$、$\overline{R}$来自于 MSNet 的输出。

4.4 实验与结果分析

4.4.1 实验前提

本文的实验前提分为四个部分，分别是数据集简介、网络训练参数配置、定量评价方法和实验对比方法介绍。

1. 数据集介绍

1) 训练数据集

反照率图像的 ground-truth 可以从真实拍摄的 IIW[60]数据集中获得，但法线、粗糙度和光照贴图只能来自合成的 OpenRooms[62]数据集。对于这种情况，本文使用了一种在不同数据集上训练并进行微调的替代方法。首先在合成的 OpenRooms 数据集上训练 MSNet。之后，在真实拍摄的 IIW 数据集上对 MSNet 进行微调训练，即 Finetune，并在训练时固定法线和粗糙度解码器的权重，Finetune 时使用了 Li 等[33]在 IIW 上挑选出的 4184 张图片序列。本文的 MSNet 和 SGNet 都是在 OpenRooms 数据集上训练的，该数据集都是高动态范围图像，消耗内存大，训练时只是使用了其中的一部分数据，总共 19703 张图片序列。在训练过程中，预处理时将图像的大小调整为 320×240，并将像素值从[0，255]

中国知网 https://www.cnki.net

线性缩放到[0，1]。随机水平翻转图像以扩充数据。

2) 测试数据集

本文使用了 Narihira 等人[63]划分的 IIW 测试集来评估反照率图像的分解情况，总共有 1023 张。除此之外，使用的测试数据集还有 SAW[64]数据集，SAW 数据集包含 6677 张真实室内场景图像，是由来自于 IIW 数据集的 5228 张图像和来自 NYUv2 数据集[65]的 1149 张图像组成，本文使用了 NIID-Net 方法挑选的测试集来对光照图进行测试，总共有 1699 张。

2. 网络训练参数配置

训练 MSNet 和 SGNet 的硬件平台、操作系统、语言环境、深度学习架构、优化器、学习率等参数如表 4.4 所示。由于 MSNet 和 SGNet 都是在合成数据集上训练的，而对于 MSNet 网络的训练，可以找到真实的反照率图像[60]，所以本文运用真实数据来微调 MSNet 网络中反照率部分的权重，本文将微调部分命名为 Finetune。关于每个网络更详细的权重、迭代次数(epochs)、批次（batch）大小等如表 4.5 所示。

表 4.4 MSNet 和 SGNet 的训练细节

项目	配置
硬件平台	显卡 A100-SXM4
操作系统	ubuntu 18.04 64 位
语言环境	Anaconda 配置的 Python3.7
深度学习架构	Pytorch 1.7
优化器	Adam 优化器，β1 = 0.9，β2 = 0.999
初始学习率	0.0001
学习率衰减	每经过一个 epoch，学习率乘以 0.5

表 4.5 训练 MSNet 和 SGNet 的超参数

方法	α_A	α_N	α_R	α_{rec}	α_{ren}	epochs	batch
MSNet	6	1.0	0.5			13	16
Finetune	0.35	-	-	-	-	1	4
SGNet				10	1.0	14	8

3. 定量评价方法

1) 加权人为分歧率

中国知网 https://www.cnki.net

本文使用了 Narihira 等人[63]划分的 IIW 测试集，该测试集对于每一对像素（A_i, A_j），数据集上都标注了像素 i 的反照率强度比像素 j 的反照率强度更亮、相等或更暗，可引入人类感知误差度量评估反照率图像，该评估方法是加权人为分歧率（Weighted Human Disagreement Rate，WHDR）用来衡量算法不同意人类判断的百分比，由每个判断对点对（i, j）的置信度 $C_{i,j}$ 加权，WHDR 的值越低代表效果越好：

$$\mathrm{WHDR}_{\delta}(J, A) = \frac{\sum_{i,j} C_{i,j}(J_{i,j} \neq \overline{J_{i,j}}(A;\delta))}{\sum_{i,j} C_{i,j}} \tag{4.21}$$

其中：

$$\overline{J_{i,j}}(A;\delta) = \begin{cases} 1, \text{if } \dfrac{A_i}{A_j} > 1+\delta \\ 0, \text{其他} \\ -1, \text{if } \dfrac{A_j}{A_i} > 1+\delta \end{cases} \tag{4.22}$$

$$J_{i,j} = \begin{cases} 1, A_i^h > A_j^h \\ -1, A_i^h < A_j^h \end{cases} \tag{4.23}$$

$J_{i,j}$、$\overline{J_{i,j}}$ 分别表示人为判断和机器判断，δ 是一个阈值，低于该阈值时相对反照率的变化被忽略不计。

2) 平均精度

为了更好地评估一个模型的准确率，研究者们提出了单个类别平均精度（Average Precision，AP），求精度（Precision）在召回率（Recall）值为{0, 0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.8, 0.9, 1}时（总共 11 个水平上）的平均值：

$$\mathrm{AP} = 1/11 \sum \mathrm{Recall} \in \{0, 0.1, \ldots, 1\} \mathrm{Precision}\left(\mathrm{Recall}\right) \tag{4.24}$$

其中：

$$\mathrm{Precision} = \mathrm{TP} / \left(\mathrm{TP} + \mathrm{FP}\right) \tag{4.25}$$

$$\mathrm{Recall} = \mathrm{TP} / \left(\mathrm{TP} + \mathrm{FN}\right) \tag{4.26}$$

假设检测一张图片存在的物体，检测算法框出 300 个框，正确检测出物体 A 的框有 50 个，实际上图片中有 150 个物体 A，则 TP（True positive）=50，TP+FP

中国知网 https://www.cnki.net

（False positive）=300，TP+FN（False negative）=150。Recall 和 Precision 之间是呈负相关，如果大幅度增加检测框，比如增加 100 万个框，此时 TP 上升，（TP+FN）不变，（TP+FP）明显上升，那么 Recall 增大、Precision 下降。于是引入 AP，计算精度-召回率（precision-recall）曲线所围成的面积作为平均精度 AP。

SAW 数据集为某些像素提供平滑或非平滑的照明标签，因此光照估计被当作二分类问题。对于尺度不变性，Li 和 Snavely[61]提出在对数域中进行判断，如果像素 i 满足 $\left\|(\nabla \log \bar{L})_i\right\|_2 < \delta_{smooth}$，则其分类为具有平滑照明。除了未加权精度（unweighted precision，P(u)）[61]，Li 和 Snavely[66]还提出了挑战精度（challenge precision，P(c)），当使用 P(c)评估集成光照时，如果像素位于输入图像强度和照明强度都平滑的容易区域，则该像素的权重较小。此外，针对不同的照明平滑度阈值 δ_{smooth} 计算 precision-recall 对，然后计算 AP(u)和 AP(c)。

4. 实验对比方法

本文在 IIW 的测试集和 SAW 数据集上与 NIID-Net[32]、Li[33]（下文简称 Li20）、CGIntrinsics[61] 和 Li 和 Snavely[66]方法（下文简称 Li18）比较了图像的本征属性分解效果，由于 Li18 方法以 hdf5 格式提供了 IIW 测试集的反照率预测，因此视觉比较没有该方法。本文预测的光照信息与 Li20 都是通过高斯编码的，与上面这些方法直接预测照明图的不同，因此需要将高斯参数编码成光照集成图，会对图像进行一定的放大。而且该图像是 3 通道的彩色图像，而其他方法是 3 通道的灰度图，为了更好比较，将彩色图像转化为灰度图。

对于增强现实应用的比较，本文在对光照估计方法的相关方法文献调研后，考虑到部分方法未公开源码或者是与本文得到的光照信息不一致，故选取了具有代表性的 3 种基于深度学习的方法进行对比，分别是 2020 年在 CVPR 上发表的 Li20 方法、Garon [27]等人（下文简称 Garon）2019 年在 CVPR 上发表的方法和 Gardner [23]等人（下文简称 Gardner）的从单幅图像预测室内照明的方法。由于 Garon 方法和 Gardner 方法都没有公开源码，但在 Garon 方法的项目中包括了 Garon 方法和 Gardner 方法渲染虚拟物体插入场景以及 ground-truth 的结果，因此本文直接使用他们渲染好的结果进行对比。

中国知网 https://www.cnki.net

4.4.2 主观评定

本文在 IIW/SAW 数据测试集上进行了可视化的比较，如图 4.5 所示（与输入图像在同一行的表示预测的反照率，第二行表示预测的光照集成图像），对于 Li20 方法，本文使用作者推荐的比较方法，即在 IIW 数据集上进行微调的 cascade0，本文在图 4.5 中展示的也是在 IIW 数据集上微调后的结果。从图中可观察到，CGIntrinsics 方法预测的纹理颜色通常比原始输入图像更暗，Li20 方法和 CGIntrinsics 方法都不能将反照率图和光照区分开（第二行中的棋盘格），而 NIID 方法能将光照图与反照率图很好地分解，但是出现了颜色偏离。

CGIntrinsics 方法只是将图像分解为反照率与光照集成图，并没有对法线进行分解，本文在图 4.6（与输入图像在同一行的表示预测的反照率图，第二行表示法线图，第三行表示粗糙度图，第四行表示预测的光照集成图）中与另外两种方法增加了法线的对比，此外，由于 Li20 与本文都预测了粗糙度图，所以也增加了粗糙度图的对比，NIID-Net 没有预测用空白表示。从图中可以观察到，Li20 方法的反照率图没有很好地去除第一行地板上的光，而且第五行的反照率图中出现了许多光影。NIID-Net 方法产生更准确的结果，而且很擅长分解光照图，其中最明显的是在最后一行中，将强光和背光的地方清晰地展现在结果中，但反照率还是会出现偏离。

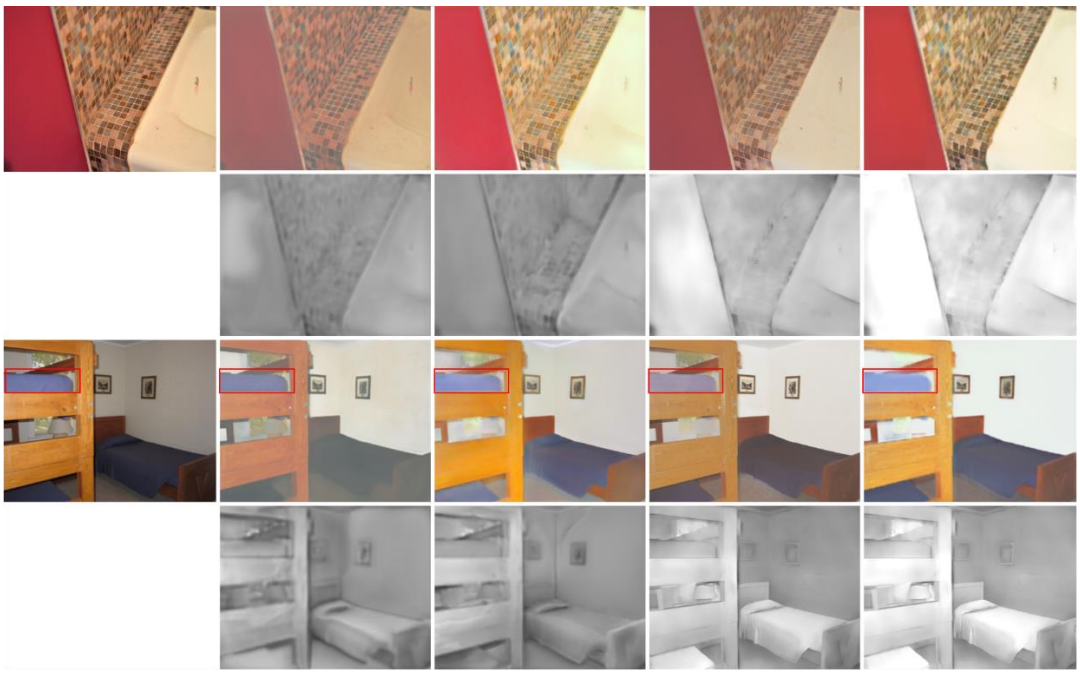

输入图像　　CGIntrinsics　　Li20　　NIID-Net　　本文

图 4.5 IIW/SAW 数据集上的可视化比较

中国知网 https://www.cnki.net

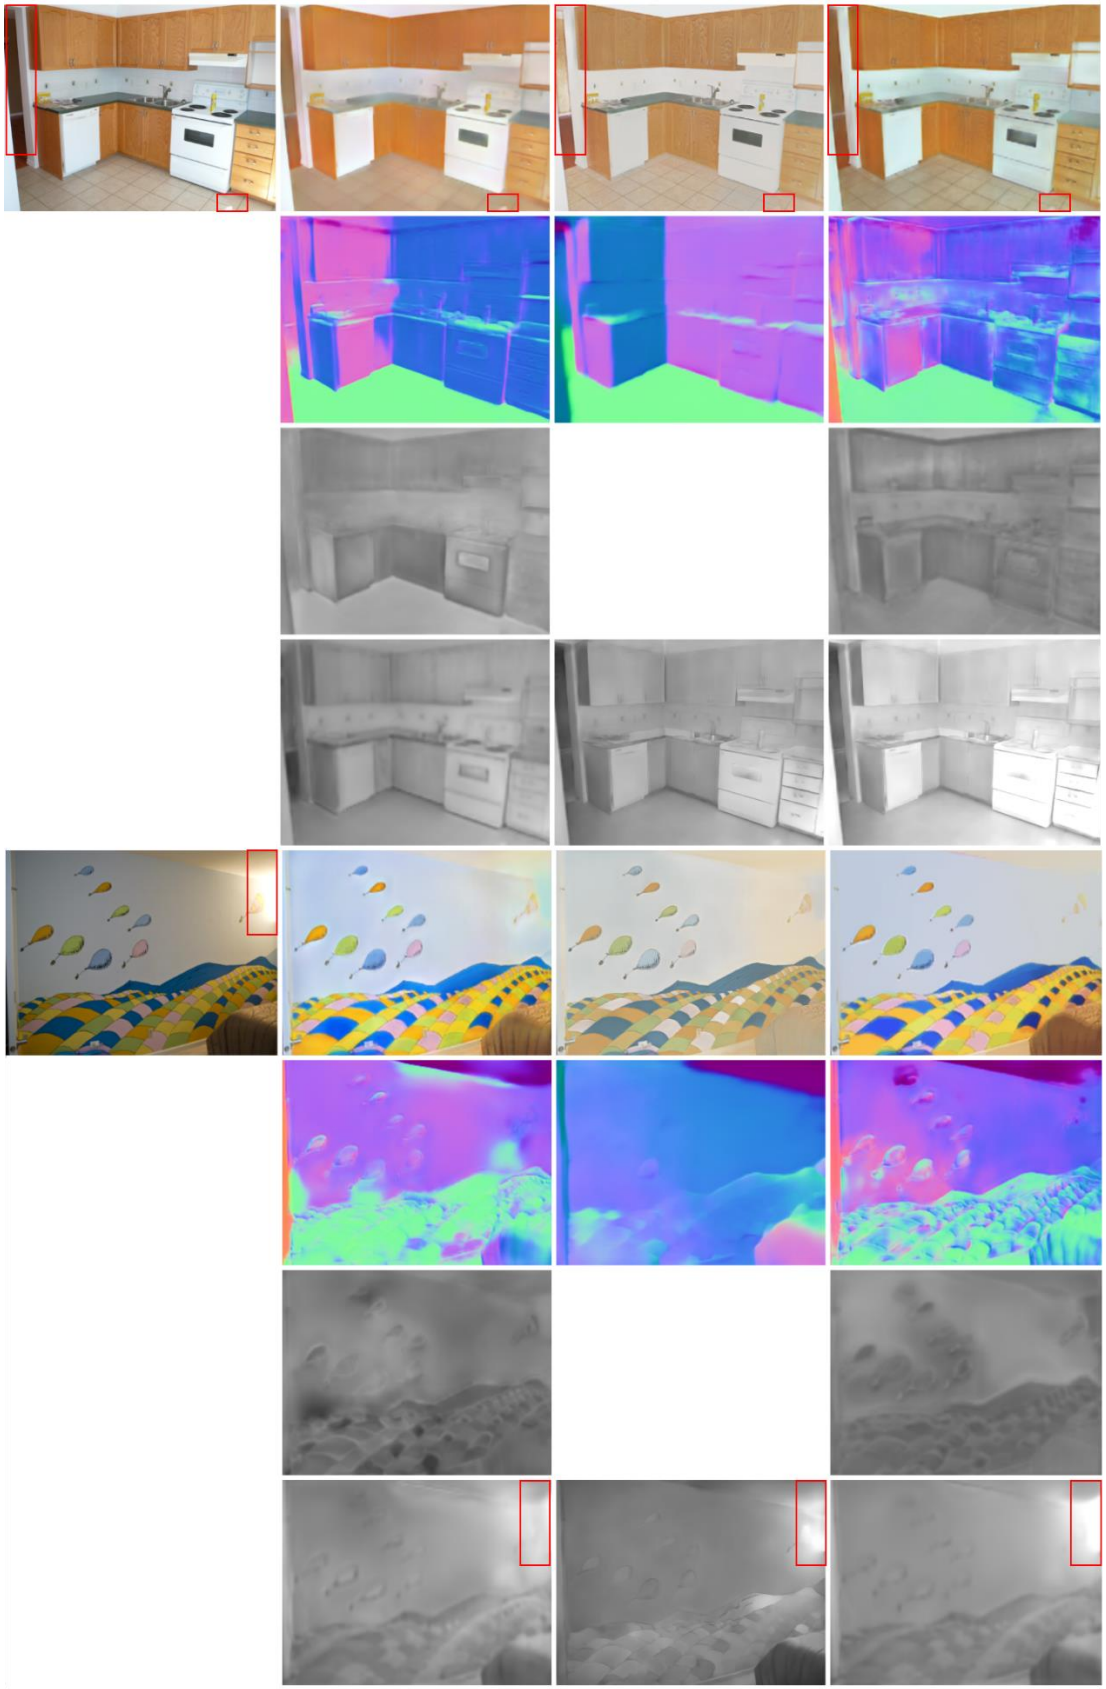

输入图像 Li20 NIID-Net 本文

图 4.6 在 IIW/SAW 数据集上的比较

中国知网 https://www.cnki.net

4.4.3 客观评定

本文在表 4.6 中对比了不同方法反照率图像的 WHDR 值，并且列出这些方法所使用的数据集，因为这些方法虽然都在同一数据集上做了评估，但是他们的训练集却各有不同，目的是在注重结果的过程中，也应观察相应的数据集，因为一个网络模型的好坏除了网络结构，损失函数的设计之外，他们所用的数据集也扮演着很重要的角色。从表 4.6 中可以看出，本文的效果是最佳的，但是 NIID-Net 方法仅仅比本文稍逊一些，而且他们使用的数据集中并没有 IIW 数据集，通过分析，一方面是他们的网络结构和损失函数，另一方面是他们所使用的 CGI 数据集是在 IIW 和 SAW 数据集上增强得到的。在下表中，“↑”表示数值越大结果越好，“↓”表示数值越低结果越好。

表 4.6 IIW、SAW 测试集上的结果

方法	训练集	WHDR(%) (↓)	AP(u)(%)(↑)	AP(c) (%)(↑)
CGIntrinsics	CGI+IIW+SAW	36.44	85.74	86.25
Li18	BT	20.25	97.74	91.86
NIID-Net	CGI	16.80	**99.12**	**98.40**
Li20(cascade0)	OpenRoom	27.66	77.36	73.68
Li20(cascade0+finetune)	OpenRoom+IIW	17.69	77.28	72.43
Li20(cascade1)	OpenRoom	24.37	77.21	73.45
Li20(cascade1+finetune)	OpenRoom+IIW	19.31	77.99	74.16
本文	OpenRoom	21.14	76.46	73.05
本文(finetune)	OpenRoom+IIW	**16.73**	77.34	74.79

光照图像使用 AP(u) 和 AP(c) 进行评估，如表 4.6 所示，本文光照图的 AP(u) 和 AP(c)值都不高，但它的可视化效果却看起来不错，原因是本文得到的光照图的大小是 160×120，而评估 AP(u) 和 AP(c)值时，需要将图像缩放至原图像大小，相同的图像分辨率（Pixels Per Inch，PPI）被放大以后图像的输出分辨率（Dots Per Inch，DPI）就会变低，因为此时每英寸像素变少，清晰度明显下降，图像也就会变得模糊。而在可视化的展示的时候都是将图像缩小至很小，PPI 不变，图像被缩小后 DPI 都在增加，虽然本文的 DPI 没有其他方法的 DPI 高，但是差别很小时人眼会将之忽略，所以其可视化效果也就不错。本文预测的光照分辨率相对较低，但是这足以恢复高频的光照效果，这点可以在图 4.6 的最后一行观察到。

中国知网 https://www.cnki.net

由于平均值仅能表示一组数据趋势的力量，而中位数反应的是一组数一般的力量，所以本文还将这些方法的情况用箱线图表示出来，如图 4.7 所示，联合中位数和均值更能反应这些方法的优良性，其中（a-i）从左到右分别是表 4.6 中第一列从上到下的 9 种方法。此外，还对比运行时间，由于运用的是 Li18 方法直接给的测试输出数据，所以在图 4.8 中只对比了其余的 8 种方法的平均 WHDR 值和平均运行时间。

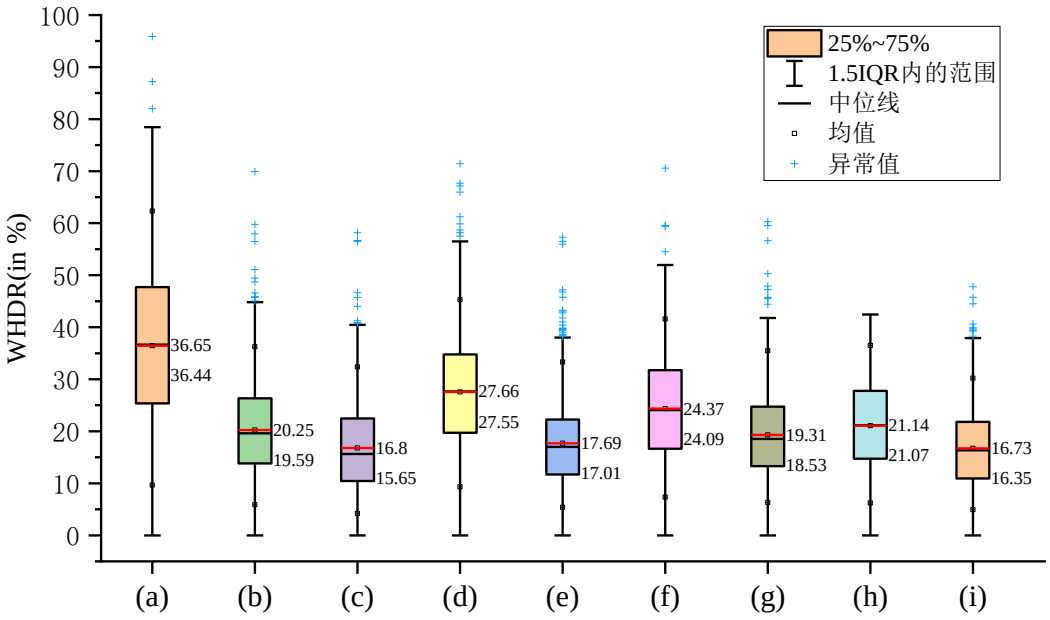

图 4.7 不同方法求解反照率图的性能对比

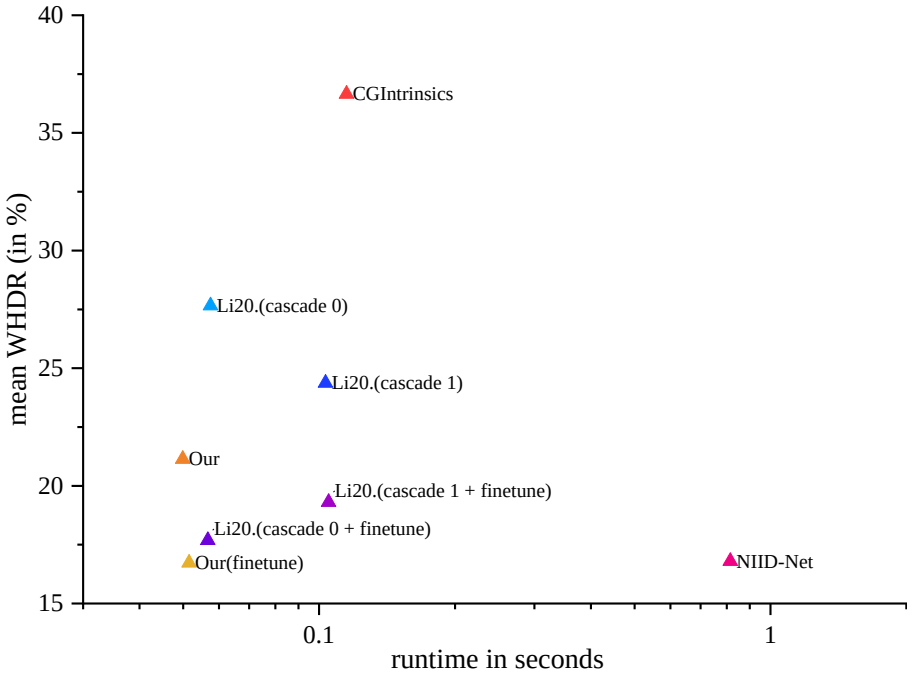

图 4.8 运行时间与平均 WHDR 值

中国知网 https://www.cnki.net

4.4.4 增强现实应用

给定真实图像，本文方法可以插入多个具有照片级真实感着色、镜面反射和全局光传输效果的兔子模型，这是高质量增强现实应用的关键。为了简化演示，本文在 Laval 室内数据集[27]上，使用 MSNet 模型估计的形状、材质，SGNet 模型估计的照明，并将得到的照明编码成光照贴图，基于以上得到的信息，选择场景的平面区域来插入虚拟物体，并使用编码好的光照贴图重新照亮虚拟物体，如图 4.9 所示。在图 4.9 第二排和最后一排中可以观察到，即使是复杂的视觉效果，例如来自场景其他部分的阴影和反射，也会准确地渲染在插入的兔子模型上。

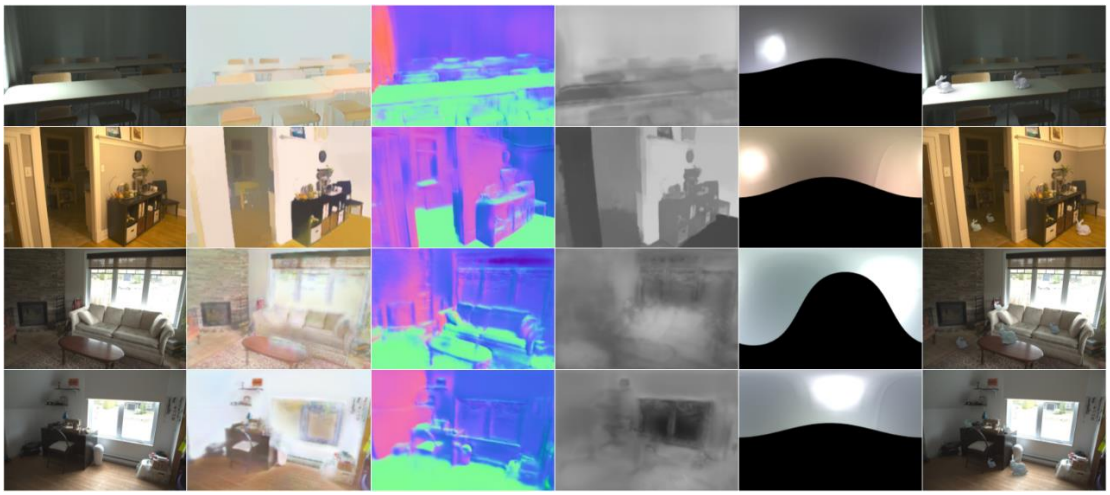

(a)　(b)　(c)　(d)　(e)　(f)

图 4.9 Laval 室内数据集的效果

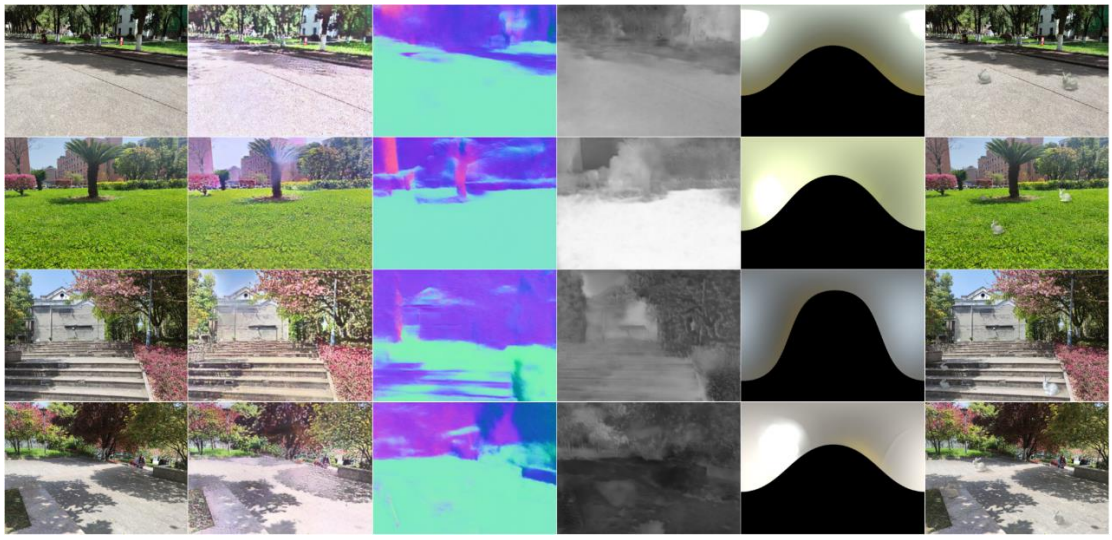

(a)　(b)　(c)　(d)　(e)　(f)

图 4.10 室外数据集的效果

中国知网 https://www.cnki.net

除了选用 Laval 室内数据集，还将本文的方法用在拍摄于校园的一些图像上，由于图 4.9 全部是室内数据集，为了展示本文方法也能运用于室外，特地拍了校园室外数据，如图 4.10 所示。将虚拟兔子放置在阴凉位置与太阳暴晒位置还是有明显的区别，尤其是在第二排的苏铁树下的兔子如果不仔细看，很难发现它隐藏于此，而在草坪上的兔子则很快被发现。图中（a-f）从左到右分别表示输入图像、反照率图、法线图、粗糙度图、光照贴图，基于以上信息，本文渲染虚拟物体加入到（a）中得到效果图（f），其中（b）至（d）是 MSNet 模块的输出结果，光照贴图（e）是由 SGNet 模块输出的球形高斯参数编码而来。

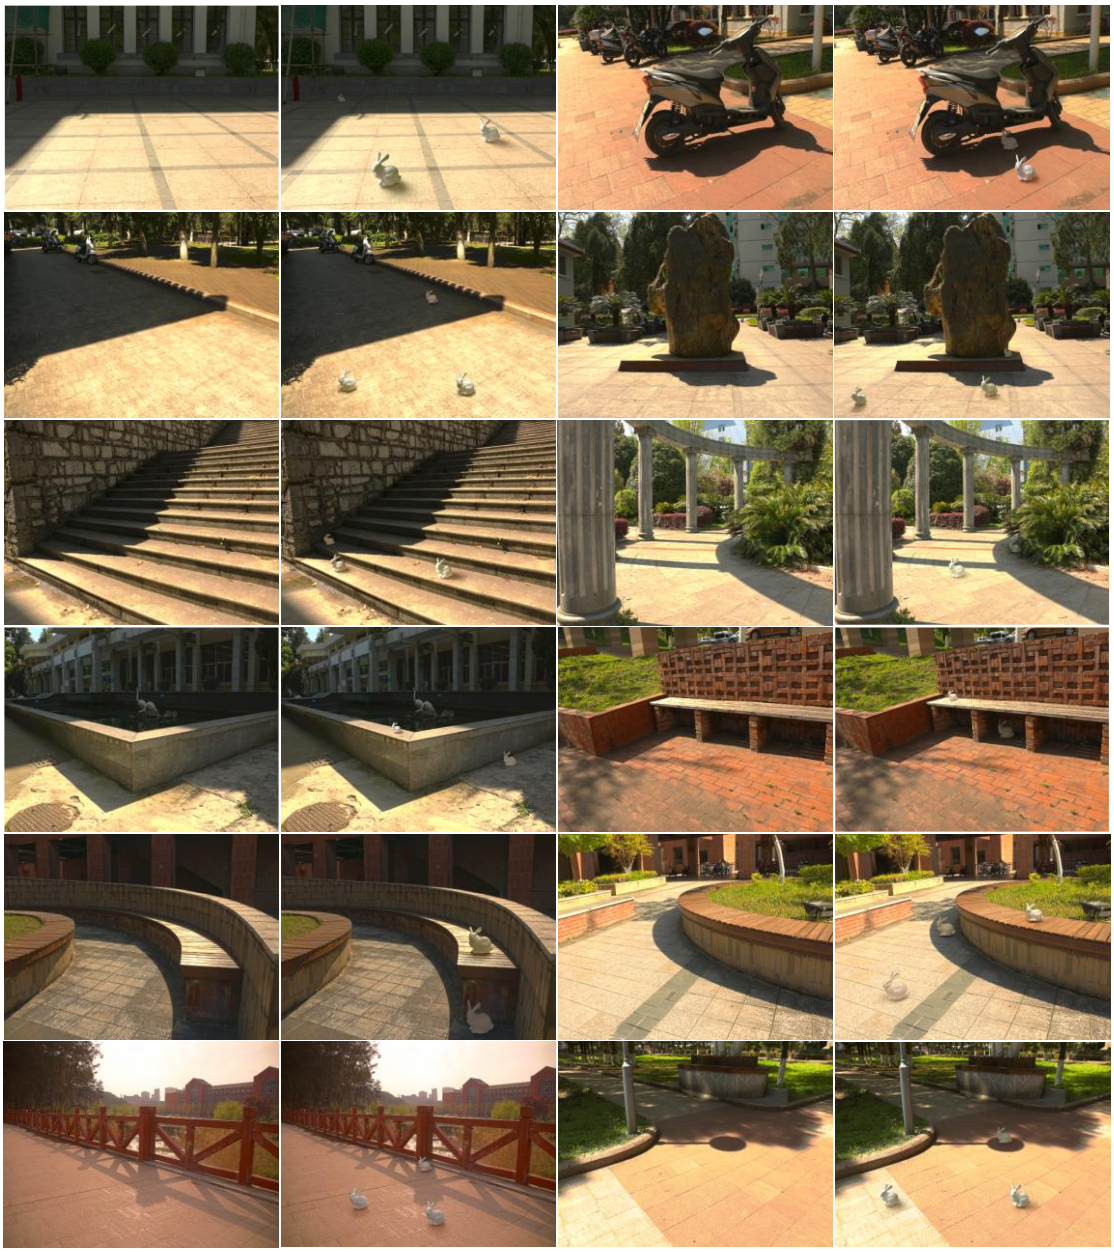

HDR 图像　　重照亮结果　　HDR 图像　　重照亮结果

图 4.11 室外 HDR 数据集的结果

中国知网 https://www.cnki.net

图 4.10 渲染的结果中虽然有明暗对比，但虚拟模型向真实场景中投射的阴影微乎其微。这是由于图 4.10 中的图像都是用手机拍摄，存在明显噪声，且因为本文的模型都是使用HDR图像训练，而且图4.9中Laval室内数据集也是HDR图像，所以其效果较好。为了更好地展示效果，本文也使用相机拍摄不同曝光度的图像合成 HDR 图像，共拍摄了五组不同的曝光图像（曝光值分别取-2、-1、0、1、2）来合成一张 HDR 图像，其结果如图 4.11 所示，可以看出，使用 HDR 图像预测的结果可以很明显的看出虚拟模型投射的阴影。本文也尝试了室内拍摄合成的 HDR 预测结果，如图 4.12 所示。综合图 4.9、图 4.11 和图 4.12，可以看出使用本文方法在校园合成 HDR 数据集和 Laval 室内 HDR 数据集都能取得很好的效果。

HDR 图像　　重照亮结果

图 4.12 室内 HDR 图像结果

Gardner　Garon　Li20　本文　ground-truth

图 4.13 不同方法在真实数据集中插入虚拟物体对比结果

中国知网 https://www.cnki.net

本文在图 4.13 中展示了通过在半球上整合该照明和 BRDF 的乘积而获得的图像非常接近真实图像（ground-truth），并且正确渲染了高频镜面反射高光，还与其他方法进行了比较。Gardner[23]方法在光线充足的区域，渲染的兔子比背光区域更暗，基本上无法观察到空间变化的照明效果。Garon[27]在最后两张图像中产生的兔子插入结果比 Gardner 方法更准确，但是他们的方法在光照上没有明显的变化，这使得在同一场景中插入兔子在不同区域的光照差异不大（例如，第一行墙上的兔子和第一张桌子底下的兔子一样暗，第二行洗漱池下兔子的亮度接近池上兔子），因为该方法预测 5 阶球面谐波表示的光照，而球形谐波很难模拟图像空间变化的光照。Li20 方法在中间的两幅图像中表现良好，但在第一幅图像中，所有兔子模型几乎都是相同的照明，而且在最后一幅图像中存在错误的渲染情况，有一只正对着光线兔子比所有其它兔子都暗。总体而言，本文方法重照亮的兔子更接近 ground-truth，插入的兔子模型具有真实的着色、由于场景遮挡而产生的阴影，甚至有来自场景的反射。

4.4.5 消融实验

从式 4.2 中可知，只需要原图像以及图像的材质和形状就可以反推出图像所受的光照情况，本文在预测光照时还加了第三章方法增强后的图像，为了了解添加增强后的图像对本文算法的贡献如何，在校园拍摄的数据集上进行了消融实验，效果如图 4.14 所示。

原图像　　10 通道输入结果　　13 通道输入结果

图 4.14 10 通道与 13 通道分别作为 SGNet 输入后图像插入的结果

中国知网 https://www.cnki.net

未使用第三章输出（3 通道）作为 SGNet 输入，则其输入为 10 通道，其中原始输入（3 通道），反照率（3 通道），法线（3 通道），粗糙度（单通道）。从图中可以看出，未使用增强后的图像作为输入的虚拟兔子插入结果偏亮，而且其投向真实场景的阴影强度也弱许多。

4.5 本章小结

本章通过基于深度神经网络学习到的先验知识来解决逆向光照估计问题，设计了材质和形状估计模块和球形高斯光照建模模块，并使用材质和形状估计模块（MSNet）推测反照率、法线、粗糙度，球形高斯光照估计模块(SGNet)推测可转化成光照贴图的参数，最后将本文方法用到增强现实中来重照亮插入的虚拟兔子。

中国知网 https://www.cnki.net

第五章 总结与展望

5.1 总结

增强现实将计算机生成的虚拟信息融合到真实场景中，要想产生更好的视觉效果，需要获得真实场景的光照分布。本文利用深度学习方法增强低照度图像，同时利用深度学习方法从单图像中估计材质和形状，基于以上先验信息进一步逆向求解空间变换的光照，这些先验信息不仅可以降低光照网络预测难度，还可以提高网络预测效果，并且在增强现实应用中验证了光照估计的有效性。本文的主要贡献如下：

1. 针对图像在拍摄过程中容易受到光线微弱、逆光、噪声等因素的影响，存在几乎没有可见的细节、对比度低、颜色暗淡的低照度图像。本文提出了融合多分支残差与仿射变换的低照度图像方法，该方法由三个模块组成，分别是光照估计模块、光照仿射变换模块和细节重建模块。这三个模块相互协助解决低照度图像存在的问题，还使用了结构损失、人眼感知损失和区域损失从不同角度改善图像质。为了验证本文算法的鲁棒性，在两个数据集上进行实验，并利用主观评价与多种评价指标对结果进行佐证，本文方法对低照度图像进行增强的效果提升最明显，低光图像经本文方法增强后色彩自然，具有更好的亮度、对比度以及更少的伪影和噪声。为实现增强现实系统中的光照一致性提供前提条件。

2. 针对获取光照信息需要逆转图像形成的问题，本文利用微表面模型和球形高斯函数理论，提出了材质和形状估计网络（MSNet）和球形高斯光照建模网络(SGNet)。基于共享编码器的残差多解码器 MSNet 网络，经过大规模的数据训练后从单图像中预测出输入图像的材质和形状（反照率、法线和粗糙度），MSNet 中除了使用 L1、L2 损失缩小各预测信息与目标信息的差距外，还引入反照率一致性损失函数很好地保留了图像材质的色彩。基于共享编码器的多解码器 SGNet 模块，结合材质和形状估计网络的输出、原始图像与经过低照度增强的图像构成 13 通道的输入，估计出可转化成光照贴图的球形高斯参数，SGNet 使用渲染损失和重建损失来提高光照信息估计的有效性，渲染损失巧妙地利用了 SG 函数积分具有一个闭式解的特性，而重建损失模拟图像的形成过程，进而在训练中对渲染结果和重建结果进行监督，指导网络的优化，极大地提高了光

中国知网 https://www.cnki.net

照估计的准确性。

将本文获得的光照、材质与形状信息应用到增强现实中，不但实现了虚拟物体的重光照，还绘制了虚拟物体向真实场景投射的阴影，展示了本文方法得到的光照信息可以较好地用来提高虚拟信息与真实世界的视觉一致性，增强用户的真实感与体验感。

5.2 展望

本文仍然存在需要改进的地方：

1. 本文将球形高斯参数编码成光照图时，使用客观指标评价其效果并不好，原因在于本文恢复的光照图分辨率比其他图像小得多，比较需要将图像放大了与其他图像大小一致，导致每英寸像素变少。因此在未来的工作中，可以考虑与本征图像分解结合，提高光照图的分辨率。

2. 本文在 480×640 图像中渲染虚拟物体插入，在使用 NVIDIA GeForce MX130 GPU 上的渲染器需要 1-1.5 分钟，这对于实现实时增强现实系统耗时过长。因此在未来的工作中，可以寻求更加轻量和高效的网络来实现本文的方法，还可以在更好的 GPU 上来部署渲染工作。

3. 使用本文的方法也有一些光照信息恢复得不准确，可以考虑将视频作为光照估计问题的输入，视频往往包含了更丰富的信息。目前较少有使用深度学习从视频中估计光照的方法，这是一个值得探索的研究方向。

中国知网 https://www.cnki.net

致谢

时光荏苒，三年的求学生活慢慢拉上帷幕，一去不复还！三年的研究生生活让我对贵大校园充满了无限的不舍与眷恋，同时也让我褪去了胆怯，成长为一个有担当、负责任的青年。在这三年中，我有过憧憬、欣喜、迷惘、悲伤和奋斗，经历了很多，但是收获颇丰。在此，我深深地感谢这几年给予我帮助和关怀的每一个人，没有你们就没有今天的我。在此，谨向三年来所有指导，帮助和关心过我的师友及亲人表示衷心的感谢!

首先要感谢我的导师黄初华老师。黄老师对待科学研究严谨踏实，对待学生认真负责，为人谦和，在科研学习中给予我极大的指导与帮助，让我研究生期间的理论学习更加充实和丰富。诲人不倦，润物细无声，还教会了我许多做人的做事的道理以及对待人生的态度，在黄老师的教导下，不仅让我学习了很多专业知识，学会自我反思并进行总结，也锻炼了我分析问题并解决问题以及对科学研究严谨认真的态度。黄老师谆谆教导，对我影响颇深，将成为我未来学习、工作和生活的一盏明灯。师恩如海，铭记于心。

其次，感谢实验室团队的李诚师兄、张羽师姐、蒋雪源师兄，虽然此时你们已经毕业，但是依然还记得你们的指引，因为你们，我的研究生生活少了很多迷茫；感谢崔虎、陈青梅同学，非常幸运能够在学习和生活中与你们交流探讨，互相帮助，因为有你们，我的研究生生活更加丰富精彩；感谢张振锋师弟、陈一凡师弟、李亚男师妹、肖瑶师妹、张若雨师弟、高文飞师弟和詹方毅师弟，因为你们，我的研究生生活变得更加温暖；感谢我的室友张圆梦、刘文静、洪瑶同学以及 19 级计算机科学与技术班的所有同学，因为你们，我的研究生生活变得更加有充实。感谢你们对我这三年的支持、理解、包容与陪伴，这将是我人生中浓墨重彩的一笔。

特别感谢我的家人。感谢一直以来的无私的关怀和支持，以及毫无保留的付出，让我能安心地在学校完成学业。

最后感谢各位论文评审、答辩的专家教授，祝愿科研更上一层楼，生活幸福美满；感谢贵州大学提供的良好学习环境以及丰厚的学习资源，祝愿母校贵州大学光辉历程更辉煌，人才辈出代代强!

学生：黄仁婧

2022 年 6 月于贵州大学

中国知网 https://www.cnki.net

参考文献

[1] 刘万奎, 刘越. 用于增强现实的光照估计研究综述[J]. 计算机辅助设计与图形学学报, 2016, 28(02): 197-207.

[2] Debevec Paul. Rendering synthetic objects into real scenes: bridging traditional and image-based graphics with global illumination and high dynamic range photography[C]// Computer Graphics Proceedings, Annual Conference Series, ACM SIGGRAPH. New York: ACM Press, 1998: 189-198.

[3] Debevec P, Graham P, Busch J, et al. A single-shot light probe[M]. ACM SIGGRAPH 2012 Talks. 2012: 1-1.

[4] Tsumura Norimichi, Dang Minh Nguyet, Makino Takao, et al. Estimating the directions to light sources using images of eye for reconstructing 3D human face[C]// Society for Imaging Science and Technology, 2003: 77-81.

[5] Shim Hyunjung. Faces as light probes for relighting[J]. Optical Engineering, 2012, 51(7): 77002.

[6] Wang Yang, Liu Zicheng, Hua Gang, et al. Face re-lighting from a single image under harsh lighting conditions[C]// IEEE, 2007: 1-8.

[7] Yao Yasuhiro, Kawamura Harumi, Kojima Akira. The hand as a shading probe[M]. ACM SIGGRAPH 2013 Posters. 2013: 1-1.

[8] Pilet Julien, Geiger Andreas, Lagger Pascal, et al. An all-in-one solution to geometric and photometric calibration[C]//2006 IEEE/ACM International Symposium on Mixed and Augmented Reality. IEEE, 2006: 69-78.

[9] Madsen C., Laursen Rune. A scalable GPU-based approach to shading and shadowing for photo-realistic real-time augmented reality[M]. Institute for Systems and Technologies of Information, Control and Communication, 2007, 252-261.

[10] Yoo Jae Doug, Lee Kwan H. Real time light source estimation using a fish-eye lens with nd filters[C]//2008 International Symposium on Ubiquitous Virtual Reality. IEEE, 2008: 41-42.

[11] Cossairt Oliver, Nayar Shree, Ramamoorthi Ravi. Light field transfer: global illumination between real and synthetic objects[J]. ACM Transactions on Graphics (TOG), 2008, 27(3): 1-6.

[12] Imai Yoshie, Kato Yu, Kadoi Hideki, et al. Estimation of multiple illuminants based on specular highlight detection[C]//International workshop on computational color imaging. Springer, Berlin, Heidelberg, 2011: 85-98.

[13] Gruber Lukas, Richter-Trummer Thomas, Schmalstieg Dieter. Real-time photometric registration from arbitrary geometry[C]// 2012 IEEE international symposium on mixed and augmented reality (ISMAR). IEEE, 2012: 119-128.

[14] Barron Jonathan T., Malik Jitendra. Intrinsic scene properties from a single rgb-d image[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2013: 17-24.

[15] Karsch Kevin, Sunkavalli Kalyan, Hadap Sunil, et al. Automatic scene inference for 3d object compositing[J]. ACM Transactions on Graphics (TOG), 2014, 33(3): 1-15.

[16] Lombardi Stephen, Nishino Ko. Reflectance and illumination recovery in the wild[J]. IEEE transactions on pattern analysis and machine intelligence, 2015, 38(1): 129-141.

[17] Zhang Edward, Cohen Michael F., Curless Brian. Emptying, refurnishing, and relighting indoor spaces[J]. ACM Transactions on Graphics (TOG), 2016, 35(6): 1-14.

中国知网 https://www.cnki.net

[18] Monroy Rafael, Hudon Matis, Smolic Aljosa. Dynamic environment mapping for augmented reality applications on mobile devices[J]. arXiv preprint arXiv:1809.08134, 2018.

[19] Maier Robert, Kim Kihwan, Cremers Daniel, et al. Intrinsic3D: High-quality 3D reconstruction by joint appearance and geometry optimization with spatially-varying lighting[C]// Proceedings of the IEEE international conference on computer vision. 2017: 3114-3122.

[20] Lalonde Jean-François, Efros Alexei A., Narasimhan Srinivasa G. Estimating the natural illumination conditions from a single outdoor image[J]. International Journal of Computer Vision, 2012, 98(2): 123-145.

[21] M. Gardner, Y. Hold-Geoffroy, K. Sunkavalli, et al. Deep Parametric Indoor Lighting Estimation[C]// 2019 IEEE/CVF International Conference on Computer Vision (ICCV). Seoul, Korea (South): 2019: 7174-7182.

[22] Y. Hold-Geoffroy, K. Sunkavalli, S. Hadap, et al. Deep outdoor illumination estimation[C]// 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Honolulu, HI, USA: IEEE Press, 2017: 2373-2382.

[23] Gardner Marc-André, Sunkavalli Kalyan, Yumer Ersin, et al. Learning to Predict Indoor Illumination from a Single Image[J]. ACM Transactions on Graphics, 2017, 36.

[24] Cheng Dachuan, Shi Jian, Chen Yanyun, et al. Learning Scene Illumination by Pairwise Photos from Rear and Front Mobile Cameras[J]. Computer Graphics Forum, 2018, 37(7): 213-221.

[25] 李诚. 面向增强现实的深度光照估计研究[D]. 贵州大学, 2020.

[26] Y. K. Sun, D. Li, S. Liu, et al. Learning Illumination from a Limited Field-of-View Image[C]// 2020 IEEE International Conference on Multimedia & Expo Workshops (ICMEW). 2020: 1-6.

[27] M. Garon, K. Sunkavalli, S. Hadap, et al. Fast Spatially-Varying Indoor Lighting Estimation[C]// 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Long Beach, CA, USA: 2019: 6901-6910.

[28] H. Weber, D. Prévost, J. Lalonde. Learning to Estimate Indoor Lighting from 3D Objects[C]// 2018 International Conference on 3D Vision (3DV). Verona, Italy: 2018: 199-207.

[29] Zhao Yiqin, Guo Tian. PointAR: Efficient Lighting Estimation for Mobile Augmented Reality[C]// 16th European Conference on Computer Vision. Glasgow, UK: Springer International Publishing, 2020: 678-693.

[30] Y. Yu, W. A. P. Smith. InverseRenderNet: Learning Single Image Inverse Rendering[C]// 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 3150-3159.

[31] Zhou H, Yu X, Jacobs D W. Glosh: Global-local spherical harmonics for intrinsic image decomposition[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 7820-7829.

[32] Luo Jundan, Huang Zhaoyang, Li Yijin, et al. NIID-Net: Adapting Surface Normal Knowledge for Intrinsic Image Decomposition in Indoor Scenes[J]. IEEE Transactions on Visualization and Computer Graphics, 2020, 26(12): 3434-3445.

[33] Li Zhengqin, Shafiei Mohammad, Ramamoorthi Ravi, et al. Inverse rendering for complex indoor scenes: Shape, spatially-varying lighting and svbrdf from a single image[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 2475-2484.

[34] Kajiya James T. The rendering equation[C]// Proceedings of the 13th annual conference on Computer graphics and interactive techniques. 1986: 143-150.

中国知网 https://www.cnki.net

[35] Cook Robert L., Torrance Kenneth E. A reflectance model for computer graphics[J]. ACM Transactions on Graphics (ToG), 1982, 1(1): 7-24.

[36] Karis Brian, Games Epic. Real shading in unreal engine 4[J]. Proc. Physically Based Shading Theory Practice, 2013, 4(3): 1.

[37] Walter Bruce, Marschner Stephen R., Li Hongsong, et al. Microfacet Models for Refraction through Rough Surfaces[J]. Rendering techniques, 2007, 2007: 18th.

[38] Debevec Paul. Image-based lighting[M]. ACM SIGGRAPH 2006 Courses. 2006: 4-es.

[39] Mcculloch Warren S., Pitts Walter. A logical calculus of the ideas immanent in nervous activity[J]. The bulletin of mathematical biophysics, 1943, 5(4): 115-133.

[40] Rosenblatt Frank. The perceptron: a probabilistic model for information storage and organization in the brain.[J]. Psychological review, 1958, 65(6): 386.

[41] Ronneberger Olaf, Fischer Philipp, Brox Thomas. U-net: Convolutional networks for biomedical image segmentation[C]// International Conference on Medical image computing and computer-assisted intervention. Springer, 2015: 234-241.

[42] K. He, X. Zhang, S. Ren, et al. Deep Residual Learning for Image Recognition[C]// 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 770-778.

[43] Ding Xiaohan, Zhang Xiangyu, Ma Ningning, et al. Repvgg: Making vgg-style convnets great again[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 13733-13742.

[44] Simonyan Karen, Zisserman Andrew. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.

[45] Zhang Kai, Zuo Wangmeng, Chen Yunjin, et al. Beyond a Gaussian Denoiser: Residual Learning of Deep CNN for Image Denoising[J]. IEEE Transactions on Image Processing, 2017, 26(7): 3142-3155.

[46] Wang Wenjing, Wei Chen, Yang Wenhan, et al. GLADNet: Low-Light Enhancement Network with Global Awareness[C]// Proceedings of IEEE International Conference on Automatic Face & Gesture Recognition. Xi'an, China: IEEE Press, 2018: 751-755.

[47] Wang Ruixing, Zhang Qing, Fu Chiwing, et al. Underexposed Photo Enhancement Using Deep Illumination Estimation[C]// Proceedings of IEEE/CVF Conference on Computer Vision and Pattern Recognition. Long Beach, CA, USA: IEEE Press, 2019: 6849-6857.

[48] Wang Limin, Qiao Yu, Tang Xiaoou. Action recognition with trajectory-pooled deep-convolutional descriptors[C]// Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 4305-4314.

[49] Ledig Christian, Theis Lucas, Huszár Ferenc, et al. Photo-realistic single image super-resolution using a generative adversarial network[C]// Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 4681-4690.

[50] Lv Feifan, Lu Feng, Wu Jianhua, et al. MBLLEN: Low-Light Image/Video Enhancement Using CNNs[C]// British Machine Vision Conference (BMVC). Newcastle, UK: BMVA Press, 2018: 220-232.

[51] Bychkovsky Vladimir, Paris Sylvain, Chan Eric, et al. Learning photographic global tonal adjustment with a database of input / output image pairs[C]// Proceedings of IEEE Conference on Computer Vision and Pattern Recognition. Providence, RI, USA: IEEE Press, 2011: 97-104.

中国知网 https://www.cnki.net

[52] Sheikh Hamid R., Bovik Alan C., De Veciana Gustavo. An information fidelity criterion for image quality assessment using natural scene statistics[J]. IEEE Transactions on image processing, 2005, 14(12): 2117-2128.

[53] Sheikh Hamid R., Bovik Alan C. Image information and visual quality[J]. IEEE Transactions on image processing, 2006, 15(2): 430-444.

[54] Mittal Anish, Soundararajan Rajiv, Bovik Alan C. Making a “completely blind” image quality analyzer[J]. IEEE Signal processing letters, 2012, 20(3): 209-212.

[55] Wei Chen, Wang Wenjing, Yang Wenhan, et al. Deep Retinex Decomposition for Low-Light Enhancement[C]// British Machine Vision Association. Northumbria Students Union, Newcastle upon Tyne, UK: BMVC Press, 2018: 155-167.

[56] Fu Xueyang, Zeng Delu, Huang Yue, et al. A fusion-based enhancing method for weakly illuminated images[J]. Signal Processing, 2016, 129: 82-96.

[57] Guo Xiaojie, Li Yu, Ling Haibin. LIME: Low-Light Image Enhancement via Illumination Map Estimation[J]. IEEE Transactions on Image Processing, 2017, 26(2): 982-993.

[58] Ying Zhenqiang, Li Ge, Gao Wen. A bio-inspired multi-exposure fusion framework for low-light image enhancement[J]. arXiv preprint arXiv:1711.00591, 2017.

[59] Li Mengtian, Guo Jie, Cui Xiufen, et al. Deep spherical Gaussian illumination estimation for indoor scene[M]. Proceedings of the ACM Multimedia Asia, 2019, 1-6.

[60] Bell Sean, Bala Kavita, Snavely Noah. Intrinsic images in the wild[J]. ACM Transactions on Graphics (TOG), 2014, 33(4): 1-12.

[61] Li Zhengqi, Snavely Noah. Cgintrinsics: Better intrinsic image decomposition through physically-based rendering[C]// Proceedings of the European Conference on Computer Vision (ECCV). 2018: 371-387.

[62] Li Zhengqin, Yu Ting-Wei, Sang Shen, et al. Openrooms: An open framework for photorealistic indoor scene datasets[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 7190-7199.

[63] Narihira Takuya, Maire Michael, Yu Stella X. Learning lightness from human judgement on relative reflectance[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2015: 2965-2973.

[64] Kovacs Balazs, Bell Sean, Snavely Noah, et al. Shading annotations in the wild[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 6998-7007.

[65] Silberman Nathan, Hoiem Derek, Kohli Pushmeet, et al. Indoor segmentation and support inference from rgbd images[C]// European conference on computer vision. Springer, 2012: 746-760.

[66] Li Zhengqi, Snavely Noah. Learning intrinsic image decomposition from watching the world[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 9039-9048.

中国知网 https://www.cnki.net

附录

作者在攻读硕士学位期间参与项目及成果：

1. 参与国家自然科学基金 1 项；
2. 参与贵州省自然科学基金 1 项；
3. 以第一作者身份在《计算机应用研究》期刊发表中文核心论文 1 篇；
4. 以第二作者身份于《计算机工程与应用》期刊发表中文核心论文 1 篇。
5. 以第一作者身份于《Journal of Electronic lmaging》期刊在审 1 篇。

中国知网 https://www.cnki.net

图版

图 1.1 真实环境与虚拟环境的连续体图.....1
图 1.2 增强现实应用示意图.....2
图 1.3 光照探测物.....4
图 1.4 光照估计的特殊设备.....5
图 2.1 线性拉伸变换.....11
图 2.2 不同γ系数下的变换结果.....12
图 2.3 直方图均衡化处理前后的对比.....12
图 2.4 Retinex 假设.....13
图 2.5 光源类型.....14
图 2.6 光线在散射时发生折射和反射现象.....14
图 2.7 使用环境光照模型渲染的茶壶.....16
图 2.8 漫反射.....16
图 2.9 Phong 光照模型的形成过程以及 Blinn-Phong 光照模型效果图.....17
图 2.10 使用 Schilick 近似菲涅尔项的曲线.....18
图 2.11 不同粗糙度表示的镜面波瓣.....19
图 2.12 微平面的自遮挡从而引起的光线损失.....19
图 2.13 Smith-GGX 函数作为几何项 G 的曲线.....20
图 2.14 HDR 光照贴图.....21
图 2.15 SH 光照.....21
图 2.16 “U-net”网络结构.....22
图 2.17 残差学习：残差块.....23
图 2.18 RepVGG 架构示意图.....24
图 3.1 融合多分支残差与仿射变换的低照度图像增强网络架构.....27
图 3.2 对合成低光图像增强的视觉比较.....35
图 3.3 对合成低光图像（带有噪声）增强的视觉比较.....36
图 3.4 对 MIT-Adobe FiveK 增强的视觉比较.....36
图 3.5 对 MIT-Adobe FiveK（带噪声）增强的视觉比较.....36
图 4.1 方案概览.....42

中国知网 https://www.cnki.net

图 4.2 材质和形状估计模块（MSNet）网路结构 44
图 4.3 蒙特卡洛积分、2 阶球谐函数与球面高斯渲染结果 46
图 4.4 球形高斯光照建模模块（SGNet）的网络结构 48
图 4.5 IIW/SAW 数据集上的可视化比较 54
图 4.6 在 IIW/SAW 数据集上的比较 55
图 4.7 不同方法求解反照率图的性能对比 57
图 4.8 运行时间与平均 WHDR 值 57
图 4.9 Laval 室内数据集的效果 58
图 4.10 室外数据集的效果 58
图 4.11 室外 HDR 数据集的结果 59
图 4.12 室内 HDR 图像结果 60
图 4.13 不同方法在真实数据集中插入虚拟物体对比结果 60
图 4.14 10 通道与 13 通道分别作为 SGNet 输入后图像插入的结果 61

中国知网 https://www.cnki.net

表版

表 3.1 低光增强算法步骤.....27
表 3.2 低照度增强网络的训练细节.....33
表 3.3 对合成低光图像增强的定量评价.....37
表 3.4 对合成低光图像（带噪声）增强的定量评价.....37
表 3.5 对 MIT-Adobe FiveK 增强的定量评价.....38
表 3.6 对 MIT-Adobe FiveK（带噪声）增强的定量评价.....38
表 3.7 内存性能表现和测试运行时间.....38
表 3.8 本文方法不同模块对 MIT-Adobe FiveK 增强的定量评价.....39
表 4.1 光照估计算法步骤.....43
表 4.2 MSNet 网络结构.....45
表 4.3 SGNet 网络结构.....48
表 4.4 MSNet 和 SGNet 的训练细节.....51
表 4.5 训练 MSNet 和 SGNet 的超参数.....51
表 4.6 IIW、SAW 测试集上的结果.....56

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net